

Wstęp do Data Mining

Aneta Ptak-Chmielewska

Instytut Statystyki i Demografii

aptak@sgh.waw.pl

struktura wykładu

- Co to jest Data Mining?
- Rozwój Data Mining
- Rodzaje danych i problemy z danymi
- Metody i techniki Data Mining
- Przykłady zastosowań
- Metodologia SEMMA
- Tworzenie wykresów w SAS Enterprise Miner
- Dodatkowa zakładka – Utility
- Credit Scoring
- Business Intelligence
- Tekst Mining

Co to jest Data Mining?

Eksploracja dużych zbiorów danych w celu odkrycia nieznanych wcześniej powiązań, wzorców i trendów, które mogą być użyte w celu podejmowania lepszych decyzji.

Wydobywanie z danych ukrytej, wcześniej nieznanej i potencjalnie użytecznej informacji. Wykorzystuje systemy eksperckie, techniki statystyczne i wizualizację danych w celu odkrycia wiedzy i prezentacji jej w sposób łatwo zrozumiały dla człowieka

Międzydyscyplinarna dziedzina, łącząca techniki uczenia maszynowego, rozpoznawania wzorców, statystyki, baz danych i wizualizacji w celu uzyskania informacji z dużych baz danych.

Istnieje wiele terminów związanych z problemem:

- Eksploracja danych
- Odkrywanie wiedzy w bazach danych
- Eksploatacja danych
- Drążenie danych

Jednak najczęściej, zarówno w polskiej literaturze, na konferencjach, jak i wśród praktyków używana jest nazwa angielska: **Data Mining**.

Rozwój Data Mining

- Rozwój metod **Data Mining** jest związany z rozwojem **technik komputerowych, procedur statystycznych i ekonometrycznych, metod organizacji i zarządzania oraz wnioskowania w warunkach niepewności**.
- To właśnie rozwój tych metod spowodował, że coraz częściej punktem wyjścia w procesach decyzyjnych są dane, a nie hipotezy badawcze lub modele teoretyczne.
- Czynniki sprzyjające rozwojowi metod Data Mining:
 - gwałtowny wzrost wielkości zbiorów danych,
 - przechowywanie danych w hurtowniach danych, tak aby całe przedsiębiorstwo miało dostęp do używanej bazy danych,
 - dostęp do danych z Internetu i intranetu,
 - rozwój pakietów oprogramowania do eksploracji danych,
 - zawrotny wzrost mocy obliczeniowej komputerów i pojemności pamięci,
 - nacisk konkurencji na zwiększanie udziału rynku w globalnej ekonomii.
- Data Mining wymaga dużych zasobów komputerowych.
- **Historycznie:** większość danych była zbierana dla celów naukowych
- **Obecnie:** większość to dane biznesowe, operacyjne. Dane są dostępne przy okazji (*opportunistic*)

Rodzaje danych

Dane	Eksperymentalne	Przy okazji
Cel	Badania naukowe	Operacyjny
Wartość	Naukowa	Komercyjna
Utworzenie	Aktywne, kontrolowane	Pasywne, obserwowane
Rozmiar	Mały	Duży
Jakość	Dobra	Słaba, (dużo błędów)
Stan	Statyczne	Dynamiczne

Problem z danymi

Obecnie problemem nie jest brak danych i informacji. Problemem jest brak wystarczającej liczby analityków, wykwalifikowanych w przetwarzaniu tych danych w wiedzę.

Wymagana jest wiedza specjalistów z wielu dziedzin

- **Problem** (*domain expert*) - rozumie określony problem biznesowy lub naukowy, terminologię, silne i słabe strony bieżącego rozwiązania,
- **Dane** (*data expert*) - rozumie dane, ich strukturę, rozmiar, format,
- **Metody analityczne** (*analytical expert*) - rozumie możliwości i ograniczenia metod, które mogą być zastosowane do problemu.


Użytkownicy danych na ogół nie są naukowcami. System służy im do podejmowania ważnych decyzji biznesowych

Najczęstsze zadania eksploracji danych:

- Opis,
- Szacowanie (estymacja),
- Przewidywanie (predykcja),
- Klasyfikacja,
- Grupowanie,
- Odkrywanie reguł asocjacji i sekwencji.

Przykłady zastosowań

- Bankowość i finanse – przewidywanie problemów braku spłacalności kredytów; wykrywanie fraudów np. ubezpieczenia, wyłudzenia; pranie brudnych pieniędzy.
- Telekomunikacja – poprawa jakości usług, obsługa i przewidywanie awarii.
- Medycyna – ocena przypadków medycznych i klasyfikacja do badań lub dalszej diagnozy na podstawie opisanych objawów.
- Biznes – badanie lojalności klientów czyli przeciwdziałanie „churn” tj. odejściu klientów do konkurencji.



Proces modelowania opiera się na następujących krokach:

- **Sample** – próbkowanie (wczytanie zbioru danych, losowanie próby w przypadku dużych baz danych, podział zbioru na: treningowy, walidacyjny i testowy)
- **Explore** – eksploracja danych (analiza opisowa i graficzna zbioru za pomocą miar statystycznych i wykresów, techniki eksploracyjne – zależności w zbiorze: analiza sekwencji, asocjacji, grupowanie)
- **Modify** – modyfikacja i przekształcenia danych (przygotowanie danych do analizy, usuwanie zmiennych, transformacja zmiennych, tworzenie nowych zmiennych, filtrowanie, wykrywanie outliersów, uzupełnianie braków danych)
- **Model** – modelowanie (tworzenie modeli predykcyjnych: drzewa decyzyjne, sieci neuronowe, modele regresyjne)
- **Assess** – ocena skuteczności i jakości modelu (porównywanie wyników dla różnych modeli, prognozowanie zmiennej zależnej na nowym zbiorze danych)
- Dodatkowo zakładka **Utility** umożliwia łączenie zbiorów, włączenie kodu 4GL, modyfikację metadanych a **Credit Scoring** umożliwia budowę kart scoringowych i wykorzystanie ich w procesie kredytowym.

Sample (sampling) – próbkowanie

Podstawowe opcje (Node - węzeł) w zakładce **Sample** to:

- **Append** – dołączanie zbiorów eksportowanych z różnych ścieżek w jednym diagramie, można również połączyć zbiory: treningowy, walidacyjny i testowy tworząc nowy zbiór treningowy.
- **Data Partition** – pozwala na podział zbioru na zbiory: treningowy, walidacyjny i testowy. Wykorzystywane jest losowanie proste lub proste warstwowe bez zwracania.
- **File Import** – pozwala na konwersję zewnętrznych plików płaskich, arkuszy xls i tabel baz danych na pliki rozpoznawane przez EM jako źródłowe pliki danych SAS.
- **Filter** – zakłada filtry na zbiór treningowy, oraz opcjonalnie na zbiór walidacyjny i testowy. Może być wykorzystany do wyłączenia pewnych obserwacji jak np. outliersów lub błędnych danych.
- **Input data** – reprezentuje zbiór danych wybrany do analizy i dostarcza szczegółów o zmiennych zawartych w zbiorze.
- **Merge** – pozwala na łączenie zbiorów danych za pomocą klucza, pozwala na łączenie jeden do jednego i na zasadzie dopasowania.
- **Sample** – pozwala na próbkowanie zgodnie z zadaniem schematem losowania. Wielkość próby może być określona jako %populacji lub obserwacji. Może być dostosowany do oversamplingu (dobierana próba) lub losowania warstwowego.
- **Time Series** – przekształca dane w szereg czasowy, co pozwala na wykrycie sezonowości i cykliczności zjawiska, które nie byłoby widoczne w tradycyjnych danych.

Sample (sampling) – próbkowanie

- Próbkowanie – to proces wybierania podzbioru ze zbioru wyjściowego (bazy danych) stosowany w sytuacji zbyt dużych zbiorów (ograniczenia zasobów sprzętowych) oraz do podziału zbioru na kilka części np. do oceny stabilności modelu.
- Podstawowe schematy losowania (najczęściej stosowane):
 - Losowanie proste ze zwracaniem lub bez zwracania
 - Losowanie systematyczne
 - N-pierwszych obserwacji
 - Losowanie warstwowe (proporcjonalne)
- Wady i zalety próbkowania
 - Wada: utrata dużej ilości informacji zawartych w danych
 - Wada: niepoprawne zastosowanie schematu losowania (np. losowanie systematyczne do danych cyklicznych) może spowodować zniekształcenie wyników modelowania
 - Zaleta: Znaczna oszczędność czasu i zasobów, możliwa jest analiza nawet w sytuacji niewystarczających zasobów do analizy całego zbioru.

Oversampling – przepróbkowanie

- Losowanie polegające na wybraniu tak samo licznej grupy z każdej z warstw, niezależnie od jej rozmiaru.
- Schemat ten stosuje się najczęściej w sytuacji gdy warstwa reprezentująca interesujące nas zjawisko (np. klienci niewypłacalni w scoringu, klienci nielojalni w analizach „churn”) jest bardzo mało liczna lub nieproporcjonalnie mała w stosunku do pozostałych warstw.
- Wyniki modelowania lepiej odzwierciedlają badane zjawisko pomimo że próba nie jest reprezentatywna.
- Wyniki modelowania muszą zostać skorygowane o poprawkę na tzw. oversampling, zwłaszcza gdy interesują nas rzeczywiste wartości w odniesieniu do wyjściowych proporcji w zbiorze danych.
- Można losować również w proporcji 1:2 albo 1:3 (1:4) jeżeli liczebność warstwy jest zbyt mała aby uzyskać próbę wystarczająco liczną do zastosowania modeli predykcyjnych.

Podział zbiorów w Data Mining – partycjonowanie

- Do testowania estymowanych modeli predykcyjnych stosuje się podział zbioru na trzy podzbiory: treningowy, walidacyjny i testowy:
 - **Zbiór treningowy** (deweloperski) – służy do nauczania modelu na podstawie zależności istniejących w zbiorze, stanowi największą część wyjściowego zbioru (zazwyczaj co najmniej 50%)
 - **Zbiór walidacyjny** – służy do porównania oszacowanych modeli między sobą i wyboru na tej podstawie najlepszej opcji (zazwyczaj ok. 20-25% zbioru wyjściowego)
 - **Zbiór testowy** służy do ostatecznej oceny wybranego modelu, najlepszego wybranego na podstawie próby walidacyjnej (zazwyczaj ok.. 20-25% zbioru wyjściowego).
- Proporcje mogą być inne np. 40%-30%-30% (domyślnym ustawienie w EM)
- Często również rezygnuje się ze zbioru walidacyjnego jeżeli estymuje się tylko jeden typ modelu (proporcja wynosi zazwyczaj 67%-33%) lub gdy liczebność zbioru jest zbyt mała aby dokonać takiego podziału.
- W przypadku gdy liczebność zbioru nie pozwala na podział stosuje się losowanie podróbki ze zbioru i dokonuje modelowania na całym zbiorze a testowania stabilności wyników na wylosowanej podpróbce (wyniki testów są wówczas obciążone o czym należy pamiętać).

Przetrenowanie i niedotrenowanie

A co jeśli skuteczność modelu na próbie walidacyjnej i treningowej istotnie się różni?

- W przypadku, gdy model dużo lepiej dopasował się do próby treningowej, mamy do czynienia z **przetrenowaniem**
- W przeciwnym przypadku mamy do czynienia z **niedotrenowaniem**

Naszym celem jest znalezienie modelu, który w miarę możliwości będzie dobrze dopasowany do próbki uczącej, a jednocześnie umożliwi dobrą generalizację znalezionych reguł.

Explore (eksploracja) i Modify (przekształcenia)

Podstawowe węzły w zakładce **Explore** to:

- **Association** – analiza powiązań, bada współwystępowania zjawisk w danych. Przy uwzględnieniu dodatkowo sekwencji występowania zdarzeń można oprócz współwystępowania zjawisk w danych określić również sekwencję ich wystapień.
- **Cluster** – pozwala na segmentację danych, czyli określenie obserwacji najbardziej podobnych do siebie. Obserwacje najbardziej podobne do siebie są zaszeregowane do tego samego klastra. Identyfikator przynależności do danego klastra może być wykorzystany dalszej analizie.
- **DMDB** – tworzy bazę danych zawierającą statystyki opisowe i czynniki dla zmiennych dyskretnych i ciągłych w importowanym zbiorze danych.
- **Graph Explore** – zaawansowane narzędzie graficzne pozwalające na eksplorację dużych zbiorów danych, ocenę wzorców i trendów oraz obserwacji ekstremalnych. Próbką danych jest pokazywana na wykresach, które mogą być oglądane interaktywnie.
- **Market Basket** – pozwala na analizę danych transakcyjnych, czyli danych o sprzedaży danych artykułów. Pozwala ocenić, jakie konfiguracje jakich artykułów są kupowane najczęściej, najchętniej.
- **MultiPlot** – tworzy wykresy słupkowe i punktowe dla zmiennych objaśniających i zmiennej objaśnianej (zależnej). Kod wygenerowany może być wykorzystany do późniejszego odtworzenia wykresów.
- **Path Analysis** – służy do analizy ścieżek jakie są najczęściej wybierane przez użytkowników stron internetowych, może być też wykorzystany do analizy sekwencji.

Explore (eksploracja) i Modify (przekształcenia)

Podstawowe węzły w zakładce **Explore** cd:

- **SOM/Kohonen** – narzędzie wykorzystujące funkcje wygładzające Kohonena do m.inn. redukcji wymiaru.
- **StatExplore** – wielofunkcyjne narzędzie do badania rozkładów zmiennych i statystyk tych rozkładów w zbiorze danych. Narzędzie wykorzystywane głównie do:
 - wyboru zmiennych do analizy
 - wyznaczenia statystyk rozkładów jednowymiarowych
 - wyznaczenie podstawowych statystyk dla rozkładów z podziałem na klasy definiowane przez zmienną targetową.
 - wyznaczenie miar korelacji dla zmiennych ciągłych.
- **Variable Clustering** – narzędzie do redukcji wymiaru poprzez wybór najlepszej zmiennej reprezentującej dany klaster lub najlepiej reprezentujących klaster obserwacji. Klasteryzacja pozwala na pozbycie się współliniowości, redukuje redundancję, i pomaga wykryć współzależności (strukturę) istniejące w zbiorze danych.
- **Variable Selection** – pozwala ocenić istotność zmiennych w predykcji zmiennej targetowej. Kryterium wyboru jest oparte na statystyce: R-kwadrat lub Chi-kwadrat. R-kwadrat pozwala na usunięcie zmiennych wg hierarchii, zmiennych ze zbyt dużą liczbą braków danych, oraz zmiennych dyskretnych ze zbyt dużą liczbą kategorii. Zmienne nie wchodzą do dalszej analizy (modelowania).

Explore (eksploracja) i Modify (przekształcenia)

Podstawowe węzły w zakładce **Modify** to:

- **Drop** – używany do usunięcia zmiennych ze skorowanego zbioru danych. Zmienne mogą być usunięte poprzez zmianę roli lub manualnie funkcją drop.
- **Impute** – umożliwia zamianę wartości dla obserwacji z brakami danych. Dla zmiennych ciągłych można zamienić braki danych średnią, medianą, środkiem zakresu, wartością wynikającą z rozkładu, oszacowaniem estymatora M bądź wynikiem drzewa decyzyjnego. Dla zmiennych dyskretnych można zamienić braki danych za pomocą najczęściej występującej wartości, wartością wynikającą z rozkładu zmiennej, wynikiem drzewa decyzyjnego lub wartością stałą.
- **Interactive Binning** – opcja służąca do grupowania wartości zmiennej w przedziały. Początkowo wartości są pogrupowane w przedziały wynikające z zadanych kwantyli, które mogą być interaktywnie dzielone lub łączone. Grupowanie może być zastosowane zarówno do zmiennych ciągłych jak i dyskretnych w celu pozbycia się zbyt dużej liczby kategorii lub zwiększenia mocy predykcyjnej grupowanej zmiennej.
- **Principal Component** – wyznacza wartości własne i wektory własne macierzy kowariancji lub korelacji. Główne składowe wyznaczone z wykorzystaniem wektorów własnych stanowią nowe zmienne wejściowe do dalszej analizy. Narzędzie to umożliwia lepszą interpretację zmiennych i redukcję wymiaru.
- **Replacement** – pozwala na łączenie kategorii dla zmiennych dyskretnych lub ich ponowne oznaczenie w celu poprawy własności predykcyjnych modelu.
- **Rules Builder** – otwiera dodatkowe okno pozwalające na tworzenie dodatkowych reguł użytkownika. Przydatne przy określaniu logiki prawdopodobieństw posteriori lub wartości scorów w karcie scoringowej.
- **Transform Variables** – tworzenie nowych zmiennych będących przekształceniem zmiennych istniejących w zbiorze. Funkcja jest użyteczna w celu poprawy dopasowania danych w modelu. Transformacje mogą zmniejszyć różnicowanie danych, pozbyć się współliniowości, poprawić zbieżność do rozkładu normalnego.

Explore (eksploracja) i Modify (przekształcenia)

- Wstępna eksploracja danych
 - wykorzystanie technik wizualnych (wykresy punktowe, histogramy)
 - podstawowe statystyki opisujące zmienne,
 - informacje o rozkładzie zmiennych
 - zależności między zmiennymi
 - problemy z jakością danych (obserwacje odstające, braki danych)
- Usuwanie problemów z danymi
 - obserwacje odstające (outliers) – mogą być wpływowe i niewpływowe, można takie obserwacje usunąć ze zbioru albo zostawić (niewpływowe) lub zmodyfikować np. zastąpić przez skrajną wartość 1 i 99 percentyl.
 - braki danych (missing) – usunięcie rekordu ze zbioru albo zastąpienie braku wartością mediany (średniej) lub regresja względem pozostałych zmiennych.
 - wartości nieprawidłowe - znalezienie błędnego rekordu i usunięcie lub zastąpienie prawidłową wartością

Explore (eksploracja) i Modify (przekształcenia)

- Modyfikacja – przekształcenia zmiennych
 - informacja o innej szczegółowości np. sumowanie zmiennych (obroty za miesiąc dla danych kodowanych dziennie)
 - odzyskanie informacji (np. miesiąc z danych o dacie zdarzenia)
 - funkcja istniejących zmiennych
 - korekta rozkładu (w kierunku rozkładu normalnego) zapewniająca poprawność wnioskowania statystycznego o parametrach
 - Kombinacja kolumn
 - Standaryzacja
 - Przekształcenie logarytmiczne (eliminacja prawej skośności rozkładu)
- Kryteria doboru zmiennych do modelu (wstępna eliminacja)
 - kryterium R^2 (oparte na regresji krokowej), najpierw wybór jednoczynnikowy dla progowej wartości R^2 a następnie krokowa regresja przy progu minR lub maxR poprawa R^2
 - kryterium chi-kwadrat (dla binarnej zmiennej objaśnianej), maksymalizacja statystyki obliczanej na podstawie tablicy kontyngencji 2x2.

Model – modelowanie

Podstawowe węzły w zakładce **Model** to:

- **AutoNeural** – służy do automatycznej konfiguracji sieci neuronowych.
- **Decision Tree** – pozwala na tworzenie drzewa poprzez podziały danych z wykorzystaniem zmiennych nominalnych, porządkowych lub ciągłych. Narzędzie wspiera zarówno interaktywne podziały jak i automatyczne. W przypadku podziałów automatycznych zmienne są rangowane w oparciu o ich wkład do budowy drzewa. Rangowanie może być podstawą selekcji zmiennych do dalszego modelowania. Dodatkowo zmienne binarne mogą być utworzone jako wstęp do dalszego modelowania.
- **Dmin Regression** – przeprowadza regresję na danych ze zmienną zależną binarną lub ciągłą. Regresja w tym węźle jest oparta na metodzie krokowej Forward z wykorzystaniem metody najmniejszych kwadratów. Kryterium selekcji zmiennych oparte jest na największym wkładzie do R-kwadrat modelu. Narzędzie pozwala na włączenie wszystkich interakcji zmiennych dyskretnych (2 stopnia), oraz wykorzystanie zmiennych do identyfikacji nieliniowych zależności zmiennych ciągłych ze zmienną targetową. Narzędzie również grupuje zmienne dyskretne w celu zmniejszenia liczby kategorii. W przypadku zmiennych nominalnych i porządkowych należy jednak wykorzystać węzeł Regression.
- **DMNeural** – kolejne narzędzie do szacowania modeli nieliniowych. Model nieliniowy wykorzystuje główne składowe jako zmienne objaśniające w modelu ze zmienną targetową binarną lub ciągłą.
- **Ensemble** – wykorzystuje oszacowane prawdopodobieństwa (zmienna binarna) lub wartości oczekiwane (zmienna ciągła) dla zmiennej targetowej z kilku modeli do stworzenia nowego modelu, który jest wykorzystywany do scorowania nowych danych. Podstawową metodą modelowania wielokrotnego (multiple). Tworzonych jest kilka modeli (np. sieci neuronowe lub drzewa) z tego samego zbioru treninfgowego a następnie modele są łączone w jeden finalny model.

Model – modelowanie cd.

- **Gradient Boosting** – algorytm podziału danych wg wartości danej zmiennej tak aby zoptymalizować rozkład zmiennej targetowej w powstających przedziałach. Kryterium optymalizacji jest wartość (worth) podziału. Im bardziej zbliżone są wartości zmiennej targetowej wewnątrz danego segmentu tym większa wartość takiego podziału.
- **Least Angle Regression (LARS)** – narzędzie może być wykorzystane zarówno do selekcji (wyboru) zmiennych jak i do dopasowania modelu. Wybór zmiennych odbywa się podobnie jak w mechanizm selekcji Forward.
- **Memory-Based Reasoning (MBR)** – narzędzie do modelowania wykorzystujące algorytm k-najbliższych sąsiedztw do kategoryzacji lub predykcji obserwacji. Pomiar odległości między obserwacjami a wzorcem wykorzystuje odległości euklidesowe.
- **Model Import** – importuje i ocenia model, który został stworzony przez inne narzędzia niż SAS EM. Model taki może być porównany z innymi oszacowanymi w SAS EM.
- **Neural Network** – narzędzie do wytrenowania i walidacji sieci neuronowych z kilkoma warstwami, gdzie wyniki z kolejnej warstwy są wyjściem do następnej.
- **Partial Least Squares** – modelowanie dla zmiennej zależnej ciągłej lub binarnej oparte na procedurze SAS/STAT PLS.
- **Regression** – pozwala na dopasowanie regresji liniowej i logistycznej do danych. Zmienna zależna może być ciągła, binarna lub porządkowa. Jako zmienne objaśniające mogą być włączone zmienne ciągłe lub dyskretne. Metody doboru zmiennych: forward, backward and stepwise. Możliwe jest włączanie interakcji zmiennych.
- **Rule Induction** – pozwala na poprawę klasyfikacji zdarzeń rzadkich w modelowanych danych. Pozwala na stworzenie zmiennych binarnych ze zmiennej targetowej wg częstości wystąpień poszczególnych kategorii zmiennej.
- **TwoStage** – pozwala na modelowanie zmiennych zależnych dyskretnych i ciągłych jednocześnie w jednym modelu. np. binarna default (0-1) i strata z defaultu.

Model – modelowanie

- Podstawowym zadaniem konstrukcji modelu predykcyjnego jest ***stworzenie reguły która połączy zmienne wyjściowe (objaśniające) ze zmienną celu (zależną) na podstawie posiadanych danych (historycznych) tak aby umożliwić podejmowanie decyzji (predykcja wartości zmiennej celu) w przyszłości na podstawie posiadanych informacji (danych)***, np. decyzja kredytowa na podstawie karty scoringowej, decyzja targetu marketingowego na podstawie zachowania klientów. Zmienna celu może być jakościowa lub ciągła.
- Podstawowe typy modeli
 - Regresja liniowa (zmienna celu: ciągła)
 - Regresja logistyczna (zmienna celu: binarna)
 - Drzewa decyzyjne
 - Sieci neuronowe
- Porównanie i wybór odpowiedniego modelu odbywa się na podstawie próby walidacyjnej z wykorzystaniem podstawowych statystyk porównawczych.

Assess – ocena

Podstawowe węzły w zakładce **Assess** to:

- **Cutoff** – narzędzie wspomagające decyzję o zyskowości przyjętego punktu cut-off w modelach dla zmiennej binarnej z wykorzystaniem tabel i wykresów. Węzeł pozwala zminimalizować koszty błędnych decyzji.
- **Decisions** – definiuje profil dla kategorii zmiennej targetowej binarnej pozwalające podjąć optymalne decyzje. Użytkownik definiuje macierz decyzji, określającą koszt błędnej decyzji klasyfikacyjnej.
- **Model Comparison** – zasady porównywania modeli i predykcji pochodzących z różnych narzędzi wykorzystanych do modelowania. Porównanie bazuje na aktualnych lub oczekiwanych zyskach i stratach wynikających z zastosowania modelu. Uzupełnieniem są wykresy typu Lift czy profit/loss.
- **Segment Profile** – daje wgląd w dane poddane segmentacji lub klasteryzacji i pozwala określić czynnik, który najbardziej odróżnia segment od populacji. Narzędzie dostarcza opcji pozwalających na porównanie rozkładów czynników pomiędzy segmentami i w porównaniu do populacji.
- **Score** – pozwala na zarządzanie, edycję, eksport i wykonanie kodu do nadania scorów (punktów) powstałego z oszacowanego modelu. Scoring pozwala na wyznaczenie prawdopodobieństwa targetu na zbiorze w którym nie ma zmiennej targetowej. Scoring jest zaszyty w postaci zwykłego data stepu kodu SAS, który może być wykorzystany dalej w dowolnej aplikacji SAS, niekoniecznie SAS EM. Kod może też być przetłumaczony na kod C lub Java.

Assess – ocena

- Porównanie kilku modeli odbywa się za pomocą zestawu statystyk oceniających jakość modelu predykcyjnego.
- Statystyki:
 - Średni błąd kwadratowy (ASE)
 - Suma kwadratów błędów (SSE)
 - Odsetek błędnych klasyfikacji (Misclassification Rate)
 - Indeks ROC
- Dodatkowo:
 - Statystyka Kołomogorowa-Smirnowa
 - Kryteria Informacyjne (Akaike, Scharz, Bayesian)
 - Absolutny Błąd Maksymalny
- Do oceny binarnych modeli klasyfikujących najlepszą miarą jest:
 - Krzywa ROC (zależność czułości modelu od specyficzności, im bardziej wypukła tym lepiej dla modelu)
 - Cumulative Lift (im większe wartości w pierwszych decylach tym lepszy model)

Assess – ocena

- Dopuszczalne jest również łączenie otrzymanych modeli predykcyjnych w celu poprawy jakości predykcji:
 - Łączenie modeli uśredniające wyniki uzyskane na kilku niezależnych próbkach przy użyciu tej samej metody (np. modelu regresji)
 - Łączenie (uśrednianie wyników) kilku różnych modeli z zastosowaniem różnych typów modelowania na tej samej próbce.
 - Uwaga: należy zawsze sprawdzić jakość modeli które chcemy łączyć w porównaniu z jakością modelu połączzonego (uśrednionego)
- Scoring modeli czyli proces zastosowania wyników modelu (zapisu reguły decyzyjnej) do nowych danych
 - Stworzenie kodu scoringowego (dodatkowy moduł w EM z możliwością eksportu kodu do innych narzędzi)
 - Regularna walidacja modelu i monitoring - ze względu na upływający czas i zmieniająca się populację model musi być regularnie monitorowany i douczany w miarę potrzeb.

Asses – Ocena modeli


Budując model predykcyjny, możemy być zainteresowani osiągnięciem wysokiej skuteczności w:

- Klasyfikacji
- Jakości predykcji
- Rozdzielaniu wybranych grup docelowych (dyskryminacji)

Metody graficzne oceny modeli to:

- Krzywa ROC
- Wykresy (skumulowanej) odpowiedzi:
 - Lift/ Cumulative Lift
 - Gain/ Cumulative Gain
 - Profit/ Cumulative Profit
 - Captured Response/ Cumulative Captured Response

Skuteczność klasyfikacji



Odsetek błędnych klasyfikacji:
(Misclassification rate)


$$\frac{\sum_{i=1}^n I(y_i \neq \hat{y}_i)}{n}$$

Zysk/Strata:
(Profit/Loss)

$$\sum_{i=1}^n \sum_{j=1}^k I_{dj}(i) \cdot z_{dj}$$

- Zysk może być obliczony w momencie, kiedy każdemu scenariuszowi przypiszemy odpowiednią wagę (np. w przypadku binarnej zmiennej objaśnianej istnieją 4 scenariusze: poprawna i niepoprawna klasyfikacja 0 lub 1). Takie wagi przechowywane są w obiekcie nazywanym macierzą decyzyjną. Kolejne wiersze takiej macierzy wyznaczone są przez rzeczywistą wartość zmiennej celu, a kolumny przez możliwe predykcje.
- Zysk obliczany jest poprzez wymnożenie liczności poszczególnych scenariuszy przez wspomniane, odpowiadające im wagi.
- **Przykład:**
- Sprzedajemy produkt o wartości 1000 zł. Koszt zareklamowania tego produktu jednej osobie to 10zł. Założmy, że jesteśmy zainteresowani wytypowaniem osób o dużej skłonności do zakupu tego produktu. Jeśli wytypowana osoba rzeczywiście kupi produkt (poprawnie zaklasyfikowana „1”), zarabiamy 990 zł. Jeśli nie, tracimy 10zł. W pozostałych przypadkach nic nie tracimy, ani nie zyskujemy.
- Założmy, że w próbie walidacyjnej poprawnie wytypowaliśmy 100 chętnych, a do 900 osób wysłaliśmy ofertę nie otrzymując odpowiedzi. 1000 osób nie zostało wytypowanych do wysłania oferty.
- Wtedy $\text{zysk} = 100 \cdot 990 + 900 \cdot (-10) + 1000 \cdot 0 = 90.000 \text{zł}$.

Dokładność predykcji



Błąd średniokwadratowy:
(Mean Squared Error)

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Maksymalny błąd bezwzględny:
(Maximum absolute error)

$$\max_{i=1,..,n} |y_i - \hat{y}_i|$$


Błąd średniokwadratowy jest globalną miarą niedokładności modelu – ocenia, ile wynosi przeciętny kwadrat odchylenia predykcji od rzeczywistej wartości. Maksymalny błąd bezwzględny jest lokalną miarą mówiącą o wartości bezwzględnej największej pomyłki.

Skuteczność klasyfikacji

Statystyka Kołmogorowa-Smirnowa:

$$KS = \max_x |F_0(x) - F_1(x)|$$

Gdzie F_1 i F_0 są empirycznymi dystrybuantami prawdopodobieństw przyporządkowanym obiektom o wartościach zmiennej objaśnianej = 0,1



Im większa różnica w wartościach dystrybuant, tym lepiej model rozdziela dwie badane populacje (0 i 1).

Modele predykcyjne pozwalają szacować prawdopodobieństwo wystąpienia określonego zdarzenia dla pewnych obiektów na podstawie badania obiektów występujących w próbie.

Wówczas można budować i porównywać między sobą różne modele predykcyjne, np. modele regresji logistycznej, sieci neuronowych i drzew decyzyjnych. Każdy z tych rodzajów modeli może występować w kilku wersjach różniących się parametrami i metodą estymacji.

Porównanie modeli ma na celu wybór najlepszego spośród grupy uwzględnionych modeli oraz ocenę jakości (zdolności predykcyjnej) wybranego modelu. Analizę tę najwygodniej przeprowadzać posługując się wykresami.

Przedstawimy dwa rodzaje wykresów:

wykresy wzrostu, zwane powszechnie wykresami lift (*lift charts*) oraz związane z nimi **wykresy pozytywnych odpowiedzi** (*responses*) i „**schwytyanych**” **pozytywnych odpowiedzi** (*captured responses*),
wykres ROC (*received operating characteristic*).

Oba te wykresy są dostępne w Systemie SAS – w procedurach statystycznych i narzędziu eksploracji danych Enterprise Miner.

Wykresy wzrostu - lift

Wykresy wzrostu (*lift charts*) porównują obserwacje w zbiorze walidacyjnym z wynikami otrzymanymi w procesie estymacji modelu na podstawie zbioru treningowego albo porównują różne modele predykcyjne.

Pozwalają ocenić wizualnie jakość dopasowania modelu do danych i oszacować efektywność modelu pod względem trafności przewidywania wartości zmiennej objaśnianej.

Wykresy te wskazują, jak polepszyły się wskaźniki predyktywne uzyskane w wyniku zastosowania oszacowanego modelu w porównaniu z modelem bazowym. **Model bazowy** (*baseline* na wykresie) jest to model zastosowany, gdy nie przeprowadzono żadnego procesu estymacji.

Lift jest stosunkiem prawdopodobieństw warunkowych. Wzór mówi nam, ile razy wzrasta prawdopodobieństwo poprawnego wyniku, gdy zastosujemy dany model predykcyjny w porównaniu z modelem bazowym, czyli bez przeprowadzenia procesu estymacji.

Definicję wskaźnika lift wyraża wzór:

$$lift = \frac{P(\text{wynik} \mid \text{model uzyskany})}{P(\text{wynik} \mid \text{model bazowy})}$$

lift = 1, uzyskany model nie pozwala zwiększyć jakości prognozowania w porównaniu z modelem bazowym.

lift > 1, uzyskany model jest bardziej użyteczny niż model bazowy.

Za pomocą wskaźnika lift można porównywać różne modele.

Konstrukcja grup decylowych

Zmienna objaśniana jest zmienną zerojedyńkową. Wartości 1 interpretujemy jako sukces. (nazywane są też **pozytywnymi odpowiedziami**). Na podstawie oszacowanego modelu, dla każdej obserwacji w zbiorze walidacyjnym obliczamy prawdopodobieństwo sukcesu. Następnie ustawiamy obserwacje malejąco według tych prawdopodobieństw i dzielimy zbiór na 10 równych części - każda część tworzy **grupę decylową** w zbiorze walidacyjnym.

W programie Enterprise Miner decyle są tworzone w odwrotnej kolejności niż to przyjmuje się w statystyce. Obserwacje w pierwszym decylu mają przypisane największe prawdopodobieństwa.

Na wykresach na osi poziomej są zaznaczane decyle (percentyle: 10, 20,...), a na osi pionowej są wykreślane odpowiednie charakterystyki (zależnie od wybranego wykresu). Punkty są łączone liniami i wygładzane.

Wykresy mogą być utworzone w postaci:

- nieskumulowanej**
- skumulowanej**

Przykład konstrukcji wykresu LIFT

Zbiór walidacyjny liczy **1000** obserwacji. Każda grupa decylowa zawiera **100** obserwacji. W zbiorze walidacyjnym jest **200** sukcesów. Rozkładają się one w grupach decylowych: **50, 40, 30, 20, 15, 13, 12, 10, 8, 2**.

Grupa decylowa	Nieskumulowane				Skumulowane			
	Odpowiedzi pozytywne	% response	% captured response	Lift value	Odpowiedzi pozytywne	% response	% captured response	Lift value
1	50	50,0	25,0	2,50	50	50,0	25,0	2,50
2	40	40,0	20,0	2,00	90	45,0	45,0	2,25
3	30	30,0	15,0	1,50	120	40,0	60,0	2,00
4	20	20,0	10,0	1,00	140	35,0	70,0	1,75
5	15	15,0	7,5	0,75	155	31,0	77,5	1,55
6	13	13,0	6,5	0,65	168	28,0	84,0	1,40
7	12	12,0	6,0	0,60	180	25,7	90,0	1,29
8	10	10,0	5,0	0,50	190	23,8	95,0	1,19
9	8	8,0	4,0	0,40	198	22,0	99,0	1,10
10	2	2,0	1,0	0,10	200	20,0	100,0	1,00

Oznaczmy:

N - liczba obserwacji w zbiorze walidacyjnym (1000),

K - liczba sukcesów w zbiorze walidacyjnym (200),

n - liczba obserwacji w grupie decylowej ($N/10=100$),

k - średnia liczba sukcesów przypadająca na jedną grupę decylową ($K/10=20$),

m(j) - liczba pozytywnych odpowiedzi w *j*-tej grupie decylowej, $j = 1, 2, \dots, 10$.

Wówczas możemy utworzyć wykresy zawierające na osi pionowej:

procentowy udział pozytywnych odpowiedzi w poszczególnych grupach decylowych (*% Response*),

odsetek wszystkich pozytywnych odpowiedzi, jakie zawierają poszczególne grupy decylowe (*% Captured Response*),

stosunek liczby pozytywnych odpowiedzi w poszczególnych grupach decylowych do średniej liczby pozytywnych odpowiedzi przypadający na jedną grupę.

Wykresy nieskumulowane

- Procent pozytywnych odpowiedzi

$$\% \text{ Response} = \frac{m(j)}{n}$$

- Procent „schwytanych” odpowiedzi

$$\% \text{ Captured Response} = \frac{m(j)}{K}$$

- Wzrostu „LIFT”

$$\text{Lift Value} = \frac{m(j)}{k}$$

Zatem dla wykresów nieskumulowanych licznik ułamka wynosi zawsze $m(j)$, natomiast mianownik ułamka jest stały dla wszystkich grup decylowych, ale różny dla różnych rodzajów wykresów.

Dla wykresów skumulowanych licznik ułamków zawiera skumulowaną liczbę pozytywnych odpowiedzi $M(j)$,

Gdzie:

$$M(1)=m(1), M(j)=M(j-1)+m(j) \text{ dla } j = 2, \dots, 10.$$

Wykresy skumulowane

- Procent pozytywnych odpowiedzi

$$\% \text{ Response} = \frac{M(j)}{j \cdot n}$$

- Procent „schwytanych” odpowiedzi

$$\% \text{ Captured Response} = \frac{M(j)}{K}$$

- Wzrostu „LIFT”

$$\text{Lift Value} = \frac{M(j)}{j \cdot k}$$

Interpretacja wykresów

W naszym przykładzie linia bazowa jest linią poziomą o wartości:

$$\frac{k}{n} = 20\% \quad \text{dla } \% \text{ Response}$$

$$\frac{k}{K} = 10\% \quad \text{dla } \% \text{ Captured Response}$$

$$\frac{k}{k} = 1 \quad \text{dla Lift Value}$$

Dla wykresów skumulowanych mamy wartości:


$$\frac{j \cdot k}{j \cdot n} = \frac{k}{n} = 20\% \quad \text{dla } \% \text{ Response}$$

$$\frac{j \cdot k}{K} = j \cdot 10\% \quad \text{dla } \% \text{ Captured Response}$$


$$\frac{j \cdot k}{j \cdot k} = 1 \quad \text{dla Lift Value}$$

Interpretacja wykresów

Wykresy nieskumulowane, **Lift Value**



model dobrze dopasowany
duże wartości w początkowych
grupach



model źle dopasowany
wartości bliskie 1
we wszystkich grupach

Krzywa ROC

Krzywa ROC służy do mierzenia mocy dyskryminacyjnej modelu.

Stosowana w przypadku, gdy zmienna objaśniana jest binarna (posiada dwie unikalne wartości)

Wykres przedstawia zależność specyficzności (specifity) od wrażliwości (sensitivity) modelu. Obie te miary mówią o skuteczności klasyfikacji w ramach obu poziomów zmiennej objaśnianej.

Jak powstaje krzywa ROC?


Populacja sortowana jest malejąco wg przewidywanych prawdopodobieństw

Bierzemy pod uwagę górne n% tak powstałego zbioru i obliczamy:

- 1-Specyficzność: stosunek ilości zer w zaznaczeniu do zer całej populacji
- Wrażliwość: stosunek ilości jedynek w zaznaczeniu do jedynek z całej populacji

Powtarzamy tą czynność dla wszystkich n od 0 do 100 i nanosimy punkty na wykres, łącząc je w krzywą ROC

Najlepszą sytuacją jest, gdy krzywa ROC modelu jest jak najbardziej wypukła w kierunku punktu (0,1). Odpowiada to sytuacji, gdzie dwie badane podpopulacje zostały praktycznie idealnie rozdzielone.



Krzywa ROC

Staramy się ocenić szansę wystąpienia pewnego zdarzenia losowego, które może wystąpić lub nie wystąpić. Może to być zdarzenie polegające na

- wystąpieniu opadów deszczu w dniu jutrzejszym,
- niespłaceniu kredytu przez klienta banku,
- pozytywnej odpowiedzi konsumenta na wysłaną listownie ofertę marketingową wysłaną listownie,
- wystąpienia choroby nowotworowej pacjentki zgłaszającej się na badania profilaktyczne.

Zdarzenie losowe jest modelowane przez zmienną zerojedynekową, nazywaną w modelach zmienną objaśnianą i oznaczaną literą Y .

Wartości **1** interpretujemy jako wystąpienie zdarzenia (sukces, **pozytywna odpowiedź**), wartość **0** jako niewystąpienie zdarzenia (niepowodzenie, **negatywna odpowiedź**).

Po oszacowaniu modelu dla każdej obserwacji obliczamy teoretyczne prawdopodobieństwo sukcesu $\hat{P}(Y = 1 | x)$, które pozwala przewidywać sukces lub niepowodzenie dla różnych obserwacji (możemy jednak mylić się w przewidywaniu).

Krzywa ROC - oznaczenia

P - liczba pozytywnych odpowiedzi (sukcesów)

N - liczba negatywnych odpowiedzi (niepowodzeń)

TP - liczba poprawnie przewidywanych sukcesów (*true positive*)

FP - liczba niepowodzeń przewidywanych niepoprawnie jako sukces (*false positive*)

TN - liczba poprawnie przewidywanych niepowodzeń (*true negative*)

FN - liczba sukcesów przewidywanych niepoprawnie jako niepowodzenie (*false negative*)

Przewidywane	Obserwowane		
	Positive	Negative	Total
Positive	<i>TP</i>	<i>FP</i>	<i>TP+FP</i>
Negative	<i>FN</i>	<i>TN</i>	<i>FN+TN</i>
Total	<i>TP+FN=P</i>	<i>FP+TN=N</i>	<i>TP+FP+FN+TN</i>

P - poprawnie lub niepoprawnie przewidywane sukcesy.

N - poprawnie lub niepoprawnie przewidywane niepowodzenia.

Krzywa ROC - błędy klasyfikacji

$$\frac{TP + TN}{P + N}$$

Udział poprawnych kwalifikacji

$$\frac{FP + FN}{P + N}$$

Udział błędnych kwalifikacji

Ostatnia wielkość nazywana jest też **stopą błędnej klasyfikacji** (*misclassification rate, MR*).
Wówczas udział poprawnych klasyfikacji wynosi $1-MR$.

Błędy klasyfikacji – przykład

Stopa błędnej klasyfikacji wynosi tylko 9%. Jednak widać, że spośród 100 chorych pacjentów zaledwie 15% zostało poprawnie zdiagnozowanych, natomiast 85% zostało uznanych za zdrowych. Może to mieć poważne konsekwencje dla tych pacjentów

Przewidywane	Obserwowane		
	Chory	Zdrowy	Razem
Chory	15	5	20
Zdrowy	85	895	980
Razem	100	900	1000

Zastosowany model dobrze ocenia stan pacjentów zdrowych (99,5% poprawnych wskazań), natomiast źle diagnozuje pacjentów chorych (tylko w 15% wykrywa chorobę). Można powiedzieć, że z punktu widzenia celów badania medycznego moc diagnostyczna zastosowanego modelu jest słaba. Potrzebne jest obliczenie stopy błędnej (lub poprawnej) diagnozy osobno dla przypadków sukcesów i niepowodzeń. Błędna prognoza ma bowiem różne konsekwencje w przypadku sukcesów i niepowodzeń.

Moc diagnostyczna

Czułość (*sensitivity*)

miara wykrywania sukcesów

$$c = \frac{TP}{P}$$

Swoistość (*specificity*)

miara wykrywania niepowodzeń

$$s = \frac{TN}{N}$$

1-Swoistość (*1-specificity*)


miara uznawania niepowodzeń jako sukcesy („fałszywe alarmy”)

$$1 - s = \frac{FP}{N}$$

Dobry model powinien mieć **duże wartości c** (skuteczność w wykrywaniu sukcesów) i **duże wartości s** (skuteczność w wykrywaniu niepowodzeń), ale te miary są przeciwstawne (zwiększenie c prowadzi do zmniejszenia s i odwrotnie).

W dobrym modelu 1-s powinna przyjmować małe wartości.

Krzywa ROC



Odkładając

na osi X wielkości 1-swoistość,

na osi Y czułość, otrzymamy wykres krzywej ROC

Punkt podziału

Które wyniki model uznaje jako pozytywne odpowiedzi?

$\hat{P}(Y = 1)$ - prawdopodobieństwo pozytywnej odpowiedzi
(oszacowane przez model)

$\hat{P}(Y = 1) > a$ - przewidujemy sukces (a – próg przyjęcia)

$\hat{P}(Y = 1) < b$ - przewidujemy niepowodzenie (b – próg odrzucenia)

Gdy $a > b$, to istnieje przedział nierozstrzygalności (a, b) .

Na ogół przyjmujemy $a = b = q$.

Punkt podziału

Gdy q jest małe, to często przewidujemy sukcesy (duża **moc przyjęcia**). Poprawnie przewidujemy sukcesy (TP), ale dużo niepowodzeń uznajemy za sukcesy (FP , tzw. fałszywe alarmy).

Gdy q jest duże, to często przewidujemy niepowodzenia (duża **moc odrzucenia**). Poprawnie przewidujemy niepowodzenia (TN), ale dużo sukcesów uznajemy za niepowodzenia (FN).

Graniczne przypadki:

$q = 0$ wszystko przewidujemy jako sukces

$$c = \frac{TP}{P} = 1, \quad s = \frac{TN}{N} = 0, \quad 1 - s = 1 - \frac{TN}{N} = 1$$

$q = 1$ wszystko przewidujemy jako niepowodzenie

$$c = \frac{TP}{P} = 0, \quad s = \frac{TN}{N} = 1, \quad 1 - s = 1 - \frac{TN}{N} = 0$$

Krzywa ROC

Krzywa ROC jest funkcją czułości (na osi pionowej) i 1-swoistości (na osi poziomej). Każdy punkt linii krzywej odpowiada danemu punktowi podziału. Punkty w prawym górnym rogu odpowiadają niskiemu poziomowi q . Punkty w lewym dolnym rogu odpowiadają wysokiemu poziomowi q .


ROC nie zależy od przyjętego punktu podziału. Wykreślane są wskaźniki dla wszystkich punktów podziału. Wybierając dany punkt podziału możemy ustalić dla niego czułość i swoistość modelu.

Wybierając dany punkt podziału możemy ustalić liczbę sukcesów i niepowodzeń przewidywanych przez model, a następnie obliczyć czułość i swoistość modelu. Poziomy czułości i swoistości odpowiadające sobie jest łatwo odczytać z wykresu krzywej ROC.

Dobry model ma krzywą ROC leżącą blisko lewego i górnego brzegu wykresu. Wówczas można znaleźć punkty na krzywej mające duże wartości zarówno czułości jak i specyficzności (np. takie, by $c > 0,8$ i $s > 0,8$).


Losowy model ma krzywą ROC leżącą na przekątnej. Wówczas czułość + specyficzność = 1 dla wszystkich wartości progowych q . Wówczas ustalając wartość $c > 0,8$ nie możemy zapewnić, żeby swoistość była większa niż 0,2.

Krzywe ROC - porównanie




Dobra jakość

Można wybrać punkty podziału dające dobrą czułość i swoistość



Średnia jakość

Możemy wybierać lepszą czułość albo lepszą swoistość



Zła jakość

$\text{Czułość} = 1 - \text{swoistość}$
dla wszystkich punktów podziału

Empiryczna krzywa ROC

Na podstawie konkretnej próby można wyznaczyć tzw. *empiryczną krzywą ROC*.

Wyznaczamy czułość i swoistość dla każdego punktu podziału równego oszacowanemu prawdopodobieństwu, a następnie punkty łączymy odcinkami.

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17
0,04	0,05	0,07	0,08	0,09	0,11	0,16	0,23	0,25	0,26	0,27	0,30	0,32	0,33	0,34	0,36	0,40
0	0	0	0	0	0	0	1	0	0	0	1	0	0	1	0	0
18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34
0,42	0,45	0,48	0,51	0,53	0,57	0,59	0,60	0,63	0,65	0,66	0,70	0,71	0,73	0,74	0,77	0,78
0	1	1	0	1	0	1	1	1	1	1	1	0	1	0	1	1
35	36	37	38	39	40	41	42	43	44	45	46	47	48	49	50	
0,81	0,83	0,84	0,85	0,86	0,88	0,89	0,90	0,91	0,93	0,94	0,95	0,96	0,97	0,98	0,99	
0	1	0	1	0	1	0	1	1	1	0	1	0	1	1	1	

Tablica zawiera przewidywane prawdopodobieństwa sukcesu oraz rzeczywiste wystąpienie zdarzenia dla 50 obserwacji. Dane zostały uporządkowane rosnąco według wartości W . W rzeczywistości wystąpiło 25 sukcesów i 25 niepowodzeń.

Empiryczna krzywa ROC - przykład

Tablice A, B, C zawierają wartości TP , FP , FN i TN odpowiednio dla punktów podziału:

$q = 0,25$,

$q = 0,50$,

$q = 0,75$

Przewid. $q=0,25$	Obserwowane		
	Tak	Nie	Razem
Tak	24	17	41
Nie	1	8	9
Razem	25	25	50

Przewid. $q=0,50$	Obserwowane		
	Tak	Nie	Razem
Tak	20	10	30
Nie	5	15	20
Razem	25	25	50

Przewid. $q=0,75$	Obserwowane		
	Tak	Nie	Razem
Tak	12	6	18
Nie	13	19	32
Razem	25	25	50

czułość = **96%**
swoistość = **32%**

czułość = **80%**
swoistość = **60%**

czułość = **48%**
swoistość = **76%**

poprawnie sklasyfikowano:
64%

70%


62%

Wybierając punkt podziału $q = 0,25$ uzyskujemy bardzo wysoką czułość (96%), ale występuje dużo "fałszywych alarmów" ($1-s = 68\%$).

Dla punktu podziału $q = 0,75$ swoistość wynosi 76%, jednak wykrywanie pozytywnych odpowiedzi wynosi poniżej 50% ($c = 48\%$).

Najlepiej wygląda przyjęcie punktu podziału $q = 0,50$. Wtedy jest poprawnie sklasyfikowanych 70% przypadków.

Empiryczna krzywa ROC - przykład



Dodatkowa zakładka – Utility

Podstawowe węzły w zakładce **Utility Tab** to:

- **Control Point** – pozwala na ograniczenie liczby połączeń w procesie dla danego diagramu.
- **End Groups** – tylko w zestawieniu z węzłem Start Groups, oznaczenie granic zastosowania operacji w procesie w danym diagramie. Czynności są wykonywane między oznaczeniem Start i End Groups.
- **Metadata** – pozwala na modyfikację kolumn w metadanych w określonym punkcie w diagramie. Modyfikacji podlegają atrybuty takie jak: role, poziomy pomiaru, kolejność.
- **Reporter** – używa systemu ODS do tworzenia pliku PDF lub RTF zawierającego informacje o otwartym procesie w diagramie. Pliki mogą być przeglądane i zapisywane.
- **SAS Code** – pozwala na włączenie nowego lub już istniejącego kodu do procesu otwartego w diagramie. Można wykorzystać DATA STEP do stworzenia własnego kodu scoringowego, kodu do łączenia zbiorów. Wynik w postaci gotowych zbiorów mogą być wykorzystane w dalszym procesie i modelowaniu.
- **Start Groups** – wykorzystywany dla danych pogrupowanych, jeżeli pewne procesy mają być wykonane tylko na niektórych grupach a nie na całym zbiorze. Wykorzystywana jest opcja BY.

Credit Scoring

Credit Scoring jest to opcja-zakładka wymagająca dodatkowej licencji.

Podstawowe opcje w zakładce **Credit Scoring** są następujące:

- **Credit Exchange** – pozwala na wymianę danych tworzonych w SAS EM z SAS Credit Risk Management.
- **Interactive Grouping** – tworzy przedziały lub grupuje wszystkie zmienne jakie są w zbiorze wejściowym. Można wykorzystać tą opcję dla zmiennych dyskretnych w celu zmniejszenia liczby kategorii i poprawy mocy predykcyjnej takiej zmiennej. Dodatkowo dla każdej tworzonej grupy (lub przedziału dla zmiennej ciągłej) wyznaczana jest statystyka WOE.
- **Reject Inference** – pozwala na włączenie do modelu również wniosków odrzuconych dla których fakt default jest przypisywany w oparciu o wynik punktowy modelu oszacowanego na wnioskach zaakceptowanych. Tak przetworzone (uzupełnione dane) są wyjściem do ponownego modelowania w oparciu już o wszystkie wnioski.
- **Scorecard** – pozwala na przeskalowanie wyników modelu logitowego (prawdopodobieństw) na zakres punktów określonych przez użytkownika.

Tekst Mining

- Moduł do analizy tekstu (dokumentów tekstowych) to **Text Miner** i jest to dodatkowy software do EM.
- Podstawowe zastosowania Text Minera to:
- W biznesie
 - Analiza reklam konkurencji
 - Analiza reklamacji klientów
 - Analiza zgłoszeń na serwisie pomocy klientom
- W medycynie
 - Transformacja i tłumaczenie zapisów leczenia (głównie graficzne) na informacje dla ubezpieczycieli i dokumentacji technicznych
- Badania ankietowe
 - Analiza komentarzy z badań ankietowych
- Internet
 - Wyszukiwanie i analiza dokumentów na zadany temat
 - Zapisywanie i magazynowanie znalezionych dokumentów
- Wyniki z Text Minera mogą posłużyć do dalszych analiz statystycznych i data miningowych, jak chociażby do znalezienia istotnych dokumentów z szeregu znalezionych plików i do porównywania ich zawartości. Klasteryzacja plików odbywa się na zasadzie podobieństwa pod względem listy słów. W jednej grupie znajdują się najbardziej podobne dokumenty.