

Metody redukcji wymiarowości i selekcji zmiennych

Aneta Ptak-Chmielewska

Instytut Statystyki i Demografii

aptak@sgh.waw.pl

Struktura

- **Metody redukcji wymiarowości i selekcji zmiennych:**
 - analiza składowych głównych
 - selekcja zmiennych – variable selection
 - grupowanie zmiennych – variable clustering

Analiza głównych składowych

- Procedury z zakresu analizy wielowymiarowej służą do badania powiązań (zależności) pomiędzy zmiennymi bez konieczności określania zmiennych zależnych i niezależnych.
- Głównym celem AGS jest otrzymanie niewielkiej liczby liniowych kombinacji zestawu zmiennych wyjściowych, które zachowują tak dużo informacji o zmiennych wyjściowych jak to jest możliwe. Mniejszy zestaw liniowych kombinacji zmiennych może być wykorzystany do dalszych analiz np. do regresji, analizy skupień itd. AGS może być również w pewnym stopniu wykorzystana do wykrycia zależności liniowych pomiędzy zmiennymi.
- Najczęściej bada się liniowe zależności w zbiorze danych. Skupienie uwagi na liniowych powiązaniach wynika z prostoty i łatwości interpretacji.
- Celem analizy jest wytłumaczenie zmienności zbioru danych wielowymiarowych za pomocą nieskorelowanych zmiennych, które są liniowymi kombinacjami oryginalnych zmiennych.
- Nowe zmienne (główne składowe) są uporządkowane ze względu na znaczenie: pierwsza tłumaczy największą część wariancji, druga największa część pod warunkiem nieskorelowania z pierwszą itd.
- AGS ma odpowiedzieć na pytanie czy kilka pierwszych głównych składowych może być użytych do opisu danych z utratą tylko niewielkiej części informacji.
- Redukcja zbioru jako główny cel analizy jest przydatna w uproszczeniu dalszej analizy, np. wizualizacji danych.

Analiza głównych składowych

- Dla zestawu k zmiennych ilościowych można wyznaczyć k głównych składowych. Każda główna składowe jest liniową kombinacją wyjściowych zmiennych ze współczynnikami równymi wektorom własnym macierzy kowariancji lub korelacji.

Własności głównych składowych:

- nowe zmienne są kombinacją liniową starych zmiennych;
- nowe zmienne są nieskorelowane (czyli ortogonalne);
- suma kwadratów współczynników kombinacji liniowej dla nowej zmiennej jest równa 1;
- odpowiednio odwzorowują (przybliżają) zbiór zmiennych wyjściowych,
- pierwsza główna składowa wyjaśnia największy udział wariancji zmiennych wyjściowych

Zapis formalny tak zdefiniowanych nowych zmiennych określanych jako główne składowe jest następujący:

$$PC_i = w_{i1}X_1 + w_{i2}X_2 + \dots + w_{ik}X_k \quad i = 1, 2, \dots, k \quad \sum_{j=1}^k w_{ij}^2 = 1$$

Analiza głównych składowych

- **Współczynniki kombinacji liniowej** stojące przy oryginalnych zmiennych (w_{ij}) są to współrzędne wektorów własnych macierzy korelacji zmiennych wyjściowych jeśli zostały one na początku wystandaryzowane lub macierzy kowariancji jeśli wyjściowe zmienne nie podlegały standaryzacji.
- **Wektory własne** macierzy wyznacza się poprzez wyznaczenie wartości własnych macierzy.
- **Równanie wyznacznikowe** macierzy jest następujące:

$$|\mathbf{R} - \lambda \mathbf{I}| = 0$$

gdzie poszczególne symbole oznaczają:

- $\mathbf{R}$ – macierz korelacji (kowariancji) k zmiennych wyjściowych;
- $\mathbf{I}$ – macierz jednostkowa o wymiarach $k \times k$;
- λ – wektor o wymiarach $k \times 1$;

Analiza głównych składowych

- ▶ Wartości własne stanowią rozwiązanie równania wyznacznikowego. Stanowią one uporządkowany zbiór wartości spełniający:

$$\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_k$$

- ▶ Dla każdej wartości własnej można przypisać wektor własny macierzy o postaci:

$$\mathbf{R}\mathbf{a}_i = \lambda_i \mathbf{a}_i$$

gdzie $\mathbf{a}_i$ jest to wektor własny macierzy korelacji (kowariancji);

- ▶ Wartości składowych tego wektora będą stanowić wartości współczynników stojących przy zmiennych oryginalnych których kombinacja liniowa tworzy nowe zmienne – główne składowe.
- ▶ Korelacja zmiennej i -tej ze składową j -tą wynosi (na podstawie macierzy korelacji nie kowariancji):

$$r_{x_i PC_j} = \sqrt{\lambda_j} a_{ji}$$

Analiza głównych składowych

- Wariancja j-tej głównej składowej jest równa j-tej najwyższej wartości własnej:

$$\text{var}(Y_j) = \lambda_j$$

- Suma wariancji głównych składowych równa jest wariancji zmiennych wyjściowych:

$$\sum_{i=1}^p \lambda_i = \sum_{i=1}^p \text{var}(X_i)$$

- Warto zwrócić uwagę na fakt że utworzona kombinacja liniowa jest zależna od jednostek miary oraz rzędów wielkości poszczególnych zmiennych wyjściowych. Zmienne, których wielkości są duże (a wobec tego również zmienność mierzona np. za pomocą wariancji) będą miały duży udział w tworzeniu głównych składowych. Aby uniknąć tego problemu zaleca się zastąpienie macierzy kowariancji macierzą korelacji

AGS - algorytm

- Znajdujemy wektor w_1 , który maksymalizuje $\text{Var}(w_1^T x)$
- Znajdujemy wektor w_2 , który maksymalizuje $\text{Var}(w_2^T x)$,
przy warunku $\text{Cov}(w_1^T x, w_2^T x) = 0$
- ...
- Znajdujemy wektor a_j , który maksymalizuje $\text{Var}(w_j^T x)$,
przy warunku $\text{Cov}(w_k^T x, a_j^T x) = 0$ dla $k < j$
- Aby wariancja nie zbiegała do nieskończoności przyjmujemy, że wektory a mają długość 1.

AGS – wyznaczenie pierwszej składowej

Σ - macierz kowariancji zmiennej x ,

z wartościami własnymi $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k \geq 0$

$\max_{w_1} \{Var(w_1^T x)\}$ przy $w_1^T w_1 = 1$

$$L = Var(w_1^T x) - \lambda(w_1^T w_1 - 1) = w_1^T \Sigma w_1 - \lambda(w_1^T w_1 - 1)$$

$$\frac{\partial L}{\partial w_1} = 2 \Sigma w_1 - 2\lambda w_1 \text{ zatem } \Sigma w_1 = \lambda w_1$$

Szukany kierunek jest wyznaczony przez wektor własny odpowiadający maksymalnej wartości własnej macierzy kowariancji zmiennej x , gdyż:

$$Var(w_1^T x) = w_1^T \Sigma w_1 = w_1^T \lambda w_1 = \lambda$$

W ten sposób można formalnie udowodnić że wektory własne maksymalizują wariancję (kolejno dla malejących wartości własnych). Przytoczona idea dowodu korzysta z budowy funkcji Lagrangea, chociaż w publikacjach statystycznych jest zazwyczaj podawany dowód przez rozkład sferyczny macierzy kowariancji.

Wybór liczby głównych składowych

1. Dla p zmiennych wyjściowych można wyznaczyć maksymalnie p głównych składowych. Jeśli celem analizy jest zredukowanie liczego zbioru zmiennych to wystarczy wybrać te główne składowe które odtwarzają dużą część zmienności zmiennych wyjściowych (zazwyczaj 70-90%, ew. mniej jeśli liczba obserwacji lub liczba zmiennych wyjściowych jest duża). Uwzględniamy d pierwszych głównych składowych, które wyjaśniają q procent zmienności zmiennych wyjściowych.

$$\frac{\sum_{i=1}^d \lambda_i}{\sum_{i=1}^p \text{var}(X_i)} 100 \geq q$$

2. Nie uwzględniać tych głównych składowych, dla których wartości własne są mniejsze od średniej. Zastosowanie tej metody polega na usunięciu tych składowych które mają mniejszą wariancję niż średnia z wariancji wyjściowych zmiennych.

Wybór liczby głównych składowych

3. Zastosowanie metody opartej na średniej w przypadku gry w analizie zamiast macierzy kowariancji wykorzystano macierz korelacji oznacza opuszczenie tych głównych składowych dla których wartości własne są mniejsze od 1 (symulacje wskazują że bardziej optymalnym progiem jest 0,7)
4. Opuszczenie tych składowych, które mają mniejszy udział w wariancji niż ustalony niski procent (np. 5%) gdyż mogą po prostu reprezentować losową wariancję danych.
5. Analiza głównych składowych jest techniką eksploracyjną i dlatego żadnej z tych metod nie należy traktować jako sztywnych reguł. Należy wybrać te składowe które można sensownie zinterpretować lub wykorzystać w dalszej analizie.

AGS - Wyznaczanie scorów

Wartości punktowe dla głównych składowych wyznaczyć można jako:

$$PC_{i1} = \mathbf{a}'_1 (x_i - \bar{x})$$

$\vdots$

$$PC_{ip} = \mathbf{a}'_p (x_i - \bar{x})$$

wartości scorów wykorzystywane są do aplikacji w regresji jako nowe zmienne.

AGS – przykład dla 2 zmiennych

Mamy pomiary wzrostu najstarszego syna i ojca w 20 rodzinach w centymetrach (x1-wzrost ojca x2-wzrost syna):

Simple Statistics		
	x1	x2
Mean	184.1500000	183.9500000
StD	7.7137949	5.7990471

Covariance Matrix			
		X1	x2
x1	x1	59.50263158	39.90263158
x2	x2	39.90263158	33.62894737

Total Variance	93.131578947
----------------	--------------


Eigenvalues of the Covariance Matrix					Eigenvectors			
	Eigenvalue	Difference	Proportion	Cumulative			PRIN1	PRIN2
1	88.5131600	83.8947410	0.9504	0.9504	x1	x1	0.808828	-.588045
2	4.6184190		0.0496	1.0000	x2	x2	0.588045	0.808828

$$PC1=0.8*x1+0.58*x2$$

$$PC2=-0.58*x1+0.8*x2$$

AGS – przykład dla 2 zmiennych

Na wykresie są zaznaczone obserwacje wraz z osiami wyznaczonymi przez główne składowe:



AGS - zastosowanie

1. Jeżeli mamy dużo zmiennych silnie powiązanych, to możemy naszą analizę uprościć poprzez rozpatrywanie kilku nieskorelowanych ze sobą głównych składowych. Kolejnym głównym składowym nadaje się „etykiety” (umownie) poprzez badanie ich ładunków na poszczególnych zmiennych, gdyż one odpowiadają za wielkość korelacji z tymi zmiennymi (im wyższy współczynnik tym większa korelacja).
2. Wybór podzbioru oryginalnych zmiennych, które zawierają największą część informacji. Wybieramy np. 3 zmienne wyjściowe 1- największy ładunek na PC1, 2- największy ładunek na PC2 itp. ograniczając się do sprawdzenia pierwszych 3-4 gł składowych bo wyjaśniają np. 80% zmienności.
3. Analiza regresji – zbyt dużo zmiennych objaśniających w stosunku do obserwacji lub gdy są one silnie skorelowane (problem współliniowości).
4. Poszukiwanie obserwacji nietypowych, które mogą powodować dodawanie nieistotnych wymiarów.
5. Sprawdzenie czy wyjściowe zmienne pochodzą z wielowymiarowego rozkładu normalnego. Jeżeli główne składowe nie mają rozkładu normalnego to oryginalne zmienne też nie mają.

AGS – zalety i wady

1. Redukcja zbioru zmiennych wyjściowych bez nadmiernego ubytku informacji
2. Uzyskane zmienne są nieskorelowane ale należy pamiętać że główne składowe nie mają interpretacji ekonomicznej.
3. Analizy przeprowadzone na podstawie macierzy kowariancji i korelacji znacznie się od siebie różnią i nie ma prostej metody, która przekształcałaby wyniki z jednej analizy w drugą.
4. Wymogiem stosowania klasycznej metody PCA jest jednorodność zbioru obserwacji (brak obserwacji nietypowych).
5. Jest to technika eksploracyjna, nie przeprowadza się tutaj formalnych testów statystycznych ani nie wyznacza się przedziałów ufności. Zatem nie potrzebne są też sztywne założenia na temat rozkładów zmiennych.
6. Ograniczamy się wyłącznie do liniowych przekształceń wyjściowych zmiennych. A może większą redukcję wymiaru wyjściowego zbioru danych zapewnia przekształcenie nieliniowe.
7. Analiza PCA jest transformacją skorelowanych zmiennych w nowy zbiór zmiennych, które są już nieskorelowane, to nie ma sensu przeprowadzać analizy gdyż znajdziemy składowe które są bardzo zbliżone do wyjściowych zmiennych.

Variable selection – selekcja zmiennych

- R^2 – dla zmiennej zależnej ilościowej, najlepiej ciągłej i zmiennych objaśniających ciągłych.
- Chi-kwadrat – dla zmiennej zależnej binarnej lub dyskretnej z kilkoma kategoriami.
- V-Cramera – ocenia siłę zależności (oparty na chi-kwadrat).

Grupowanie zmiennych – Variable clustering

W eksploracji danych zajmujemy się zazwyczaj obiektami, charakteryzowanymi za pomocą bardzo dużej liczby zmiennych. Liczba ta dochodzi nierzadko do kilkuset. Część z nich wprowadza redundancję informacji, opisując te same lub zbliżone właściwości obiektów.

Utrudnia to prowadzenie analizy danych, np. wykrycie współzależności, która może zachodzić między zmiennymi objaśniającymi a zmienną objaśnianą w budowanym modelu.

Pogrupowanie zmiennych w skupienia może ułatwić analizę dzięki:

- zastąpieniu grupy zmiennych jednym komponentem (*cluster component*) będącym kombinacją liniową tych zmiennych.
- albo przez wybór jednej zmiennej jako reprezentanta grupy zmiennych.

Skupianie zmiennych:

- pozwala zredukować złożoność modeli poprzez zmniejszenie liczby zmiennych biorących udział w analizie,
- pozwala usunąć lub znacznie zredukować współliniowość zmiennych,
- wprowadza większą przejrzystość w wykorzystywanym zbiorze obiektów ukazując w sposób bardziej czytelny związek między zmiennymi objaśniającymi a zmienną objaśnianą,
- skraca czas potrzebny na zbudowanie modelu,
- ułatwia interpretację uzyskiwanych wyników przy niewielkiej utracie informacji.

Grupowanie zmiennych

Dodatkową zaletą grupowania zmiennych jest możliwość budowania oddzielnych modeli, z których każdy uwzględnia inne charakterystyki obiektów, reprezentowane przez odrębne zmienne pochodzące z różnych skupień.

Algorytm grupowania zmiennych został opracowany przez *SAS Institute Inc.* i jest realizowany przez program *SAS Enterprise Miner*

Algorytm umożliwia uzyskiwanie skupień, zarówno rozłącznych, jak i hierarchicznych.

Skupienia zmiennych otrzymane w wyniku zastosowania algorytmu mogą być traktowane jako kombinacje liniowe zmiennych występujących w skupieniu. Każda taka liniowa kombinacja zmiennych jest pierwszą główną składową skupienia.

Podobnie jak w analizie głównych składowych (*PCA*), pierwsza główna składowa jest średnią ważoną zmiennych z tak dobranymi wagami, aby wyjaśnić możliwie najwięcej wariancji.

Jednak w odróżnieniu od metody *PCA* tutaj rozważane składowe mogą być ze sobą skorelowane. W zwykłej metodzie głównych składowych kolejne komponenty (pierwsza, druga itd. składowa) są budowane na podstawie tego samego zbioru zmiennych. W procedurze *Variable Cluster* bierzemy pod uwagę tylko pierwsze składowe główne, ale każda z nich jest budowana na podstawie innych zmiennych.

Dla zbudowania skupień, podobnie jak w analizie głównych składowych, jest wykorzystywana macierz korelacji lub kowariancji zmiennych.

- jeżeli jest wykorzystywana macierz korelacji, wszystkie zmienne są traktowane jako jednakowo ważne,
- jeżeli jest wykorzystywana macierz kowariancji, zmienne o większej wariancji są traktowane jako istotniejsze w przeprowadzanej analizie.

Algorytm grupowania zmiennych

Algorytm skupiania zmiennych szuka takiego podziału zmiennych, aby maksymalizować wariancję, która jest wyjaśniona przez komponenty skupień, zsumowaną po wszystkich skupieniach.

Na ogół wszystkie komponenty skupień wyjaśniają mniej wariancji wszystkich rozważanych zmiennych niż taka sama liczba głównych składowych wyodrębnionych przez *PCA* na podstawie wszystkich zmiennych. Jednak komponenty skupień mają łatwiejszą interpretację.

Algorytm skupiania zmiennych jest **podziałowy**, tzn.

- punktem wyjścia jest zbiór wszystkich zmiennych traktowany jako jedno skupienie
- w kolejnych krokach następuje podział danego skupienia na podzbiory. Podział może być hierarchiczny lub niehierarchiczny.

W algorytmie podziału powtarzane są następujące 3 kroki:

1. Wybierane jest skupienie, które będzie dzielone na dwa podzbiory. Kryterium wyboru jest albo najmniejszy udział wyjaśnionej zmienności przez komponenty skupienia (opcja **Variation Proportion**) albo największa wartość własna odpowiadająca drugiej składowej głównej skupienia (opcja **Maximum Eigenvalue**);
2. Po wybraniu skupienia w kroku 1. są znajduwane dwie pierwsze składowe główne stosując rotację *orthoblique*. Przypisuje się zmienną do tej z dwóch składowych, z którą ma większą wartość kwadratu współczynnika korelacji R^2 . Nowe składowe wyznaczają podział skupienia zmiennych na dwie części.
3. Zmienne są na nowo przyporządkowywane do skupień w ten sposób, żeby maksymalizować wariancję określoną przez składowe skupień. Użytkownik programu może wybrać opcję **Keep Hierarchies** zapewniającą zachowanie struktury hierarchicznej skupień.

Krok 3 zawiera dwa etapy:

- najpierw są obliczane składowe skupień i każda zmienna zostaje przypisana do składowej, z którą ma największą wartość kwadratu współczynnika korelacji (R^2),
- następnie dla każdej zmiennej sprawdza się, czy przypisanie jej do innego skupienia zwiększy wartość wyjaśnionej wariancji. Jeżeli przesunięcie zmiennej do innego skupienia zwiększy wartość wyjaśnionej wariancji, to na nowo obliczane są składowe obu tych skupień, zanim następna zmienna będzie sprawdzana.

Wybór opcji **Keep Hierarchies** ogranicza zmianę przyporządkowania zmiennych do skupień w ten sposób, że podział zbioru może być tylko hierarchiczny. Oznacza to, że jeżeli w danym kroku podzielimy skupienie A na skupienia A1 i A2, to zmienna może przejść tylko z A1 do A2 albo z A2 do A1, ale nie do innych skupień.

Użycie podziału hierarchicznego redukuje czas obliczeń i ułatwia interpretację skupień.

Algorytm kończy się, gdy spełnione zostaną kryteria stopu podane w polu *Stopping Criteria*. Są to:

- osiągnięto maksymalną liczbę skupień podaną w opcji *Maximum Clusters* (domyślnie: liczba wszystkich zmiennych występujących w analizie);
- wartość własna odpowiadająca drugiej składowej głównej przekracza wartość podaną w opcji *Maximum Eigenvalue* (domyślnie: 1);
- osiągnięto zadany udział wariancji wyjaśnionej wybrany w opcji *Variation Proportion* (domyślnie: 0).

Przykład problemu – najlepsze reprezentanty

Jako najlepsze zmienne (*best variables*) przyjmuje się takie zmienne w skupieniach, które mają najmniejszą wartość parametru

$$(1 - R^2)Ratio = \frac{1 - R_G^2}{1 - R_I^2}$$

gdzie

R_G^2 R^2 zmiennej ze składową główną jej skupienia

R_I^2 R^2 zmiennej ze składową główną najbliższego skupienia

W przypadku dobrego skupiania kwadrat współczynnika korelacji zmiennej ze swoją główną składową R_G^2 powinien być duży. O dobrym wyodrębnieniu grup zmiennych świadczy też małe skorelowanie zmiennych z komponentami innych grup, zatem wartość R_I^2 powinna być mała. Z tego wynika, że małe wartości ilorazu

$$\frac{1 - R_G^2}{1 - R_I^2}$$

świadczą o dobrym grupowaniu.

Zmienna o najmniejszej wartości ilorazu jest wysoko skorelowana z komponentem swojej grupy i mało skorelowana z komponentami innych grup. Dlatego zostaje wybrana jako najlepszy reprezentant swojej grupy.