

Modelowanie predykcyjne - regresja logistyczna i liniowa

Aneta Ptak-Chmielewska

Instytut Statystyki i Demografii

aptak@sgh.waw.pl

struktura wykładu

- Modele regresji
- Zmienna binarna: Model logitowy i probitowy
 - Model logitowy – interpretacja parametrów
 - Model logitowy – miary istotności i jakości
 - Model logitowy – miary asocjacji
 - Model logitowy – interakcje
 - Model logitowy – inne zagadnienia
- Wielomianowa regresja logistyczna uporządkowana
- Wielomianowa regresja logistyczna nieuporządkowana
- Model regresji liniowej
 - Założenia modelu
 - Estymacja parametrów
 - Ocena modelu i statystyki modelu
 - Wnioskowane w modelu regresji
- Zasady (metody) selekcji zmiennych do modelu
- Kryterium selekcji modelu

Modele regresji

- W EM wykorzystując węzeł **Regression** można budować modele regresji ze zmienną zależną:
 - binarną (regresja logistyczna)
 - porządkową (wielomianowa regresja logistyczna uporządkowana)
 - nominalną (wielomianowa regresja logistyczna nieuporządkowana)
 - ciągłą (regresja liniowa)
- Określenie typu modelu uwzględnia następujące elementy:
 - typ regresji
 - funkcja łącząca
 - zasady selekcji zmiennych
 - wybór kryterium selekcji modelu.

Zmienna binarna: Model logitowy i probitowy

Prawdopodobieństwo zdarzenia jest wyznaczane w oparciu o funkcję łączącą liniowy predyktor (kombinacja liniowa zm. objaśniających) z prawdopodobieństwem zdarzenia.

$$\log\left(\frac{P(y=1|x)}{1-P(y=1|x)}\right) = \beta'x$$

stąd:

$$P(y=1|x) = \frac{\exp(\beta'x)}{1 + \exp(\beta'x)}$$

Estymowane wartości zawierają się w granicach [0;1] czyli odpowiadają rzeczywistym wartościom prawdopodobieństw.0

Zmienna binarna: Model logitowy i probitowy

W przypadku funkcji łączącej w postaci dystrybuanty rozkładu normalnego standaryzowanego otrzymujemy model probitowy o postaci:

$$P(y = 1|x) = 1 - F(-\beta'x) = F(\beta'x)$$

gdzie:


$$F(\beta'x) = \int_{-\infty}^{\beta'x} \frac{1}{\sqrt{2\pi}} e^{-u^2} du$$

Estymowane wartości zawierają się w granicach [0;1] czyli odpowiadają rzeczywistym wartościom prawdopodobieństw.

Model logitowy

Interpretacja parametrów

- Wpływ jednostkowej zmiany zmiennej objaśniającej x_i na zmianę prawdopodobieństwa sukcesu jest nieliniowy i zależy od „początkowego” p_i



$$\frac{\partial p_i}{\partial x_i} = \beta p_i (1 - p_i)$$

- Zmiana X_i ceteris paribus wpływa liniowo na logarytm ilorazu szans
- $odds\ ratio(X_i) = \exp(\beta_i)$ wyraża przyrost ryzyka względnego w wyniku działania x_i
- $\exp(\beta_i) > 1 \rightarrow X_i$ działa stymulująco na default

np. dla zmiennej płeć: $\beta_i = 0.81$

$\rightarrow odds\ ratio = \exp(\beta_i) = 2.25$

$\rightarrow$ iloraz ryzyka względnego default wzrasta o 125% przy jednostkowej zmianie X , czyli w grupie mężczyzn ($X=1$) w porównaniu z grupą kobiet ($X=0$)

Interpretacja parametrów

Przykładowa interpretacja:

Stała = -0.7628 $\Rightarrow \exp(\text{stała}) = 0.466 \Rightarrow$ Gdy wszystkie inne zmienne przyjmują wartość zero, szansa $Y=1$ względem $Y=0$ wynosi 46%

$X1='A' = 1.7958 \Rightarrow \exp = 6.024 \Rightarrow$ Przy ustalonych wartościach pozostałych zmiennych, $X1='A'$ ma sześciokrotnie wyższe szanse $Y=1$, niż $X1 \sim 'A'$

Oczywiście współczynników nieistotnych nie należy interpretować!!!

Interpretujemy zwykłe współczynniki, ale do porównania siły wpływu zmiennych ciągłych używamy współczynników standaryzowanych

Model logitowy – miary istotności i jakości

Testy istotności

- Test ilorazu wiarygodności (likelihood ratio) – porównuje wartość logarytmu funkcji wiarygodności dla modelu pełnego (zawierającego wszystkie zmienne) oraz zredukowanego (z usuniętą zmienną X_i)

$$LR = -2(\ln L_0 - \ln L_1)$$

- Test Walda

$$\left(\frac{\beta_i}{std(\beta_i)} \right)^2 \Rightarrow as\chi^2$$

Miary jakości

- Uogólniony R^2

L – statystyka testowa ilorazu wiarygodności

$$R^2_G = 1 - \exp\left(-\frac{L}{n}\right)$$

- Max-rescaled R^2

✓ Uogólniony R^2 podzielony przez max wartość

- Współczynnik ilorazu wiarygodności

$$LRI = 1 - \frac{\ln L}{\ln L_0}$$

Model logitowy – miary asocjacji

Miary asocjacji oparte na parach obserwacji

- Dla wszystkich par obserwacji $(Y1, Y2)=(0, 1)$ wyznaczane są $(p1, p2)$ na podstawie modelu
- Para zgodna (concordant) jeżeli $p1 < p2 \rightarrow C$
- Para niezgodna (discordant) jeżeli $p1 > p2 \rightarrow D$
- Para powiązana (tied) jeżeli $p1 = p2 \rightarrow T$

$$Tau - a = \frac{C - D}{N}$$

$$Sommer's - D = \frac{C - D}{C + D + T}$$

$$Gamma = \frac{C - D}{C + D}$$

$$c = \frac{C + 0.5T}{C + D + T} = 0.5(1 + Somer's D)$$





Pole pod
krzywą ROC

Selekcja zmiennych objaśniających

- Dobór zmiennych opieramy wyłącznie na testach, gdy:
 - mamy za mało obserwacji, by oszacować model ze wszystkimi
 - wiele zmiennych niesie podobną informację
- Modelowanie od ogólnego do szczególnego „ręcznie”
 - jeśli mamy mało zmiennych i dużo czasu ;)
 - jeśli mamy dużo braków danych
- Metody automatycznej selekcji zmiennych **selection =**
 - **backward** – zaczyna od wszystkich, usuwa kolejno najmniej istotne (test Walda)
 - **forward** – wprowadza kolejno od tej, która generuje największe chi-kwadrat testu ilorazu wiarygodności między modelem bez i ze zmienną
 - **stepwise** – jak forward, ale po każdym wprowadzeniu sprawdza, czy jakaś zmienna nie przestała być istotna; kończy, gdy usunie ostatnio wprowadzoną
 - **score** – szuka modeli z najwyższą wiarygodnością przy kolejnych liczbach zmiennych objaśniających (czasochłonne!)
 - Online Doc -> Proc Logistic -> Details->Effect Selection Methods
- Przy metodach backward, forward i stepwise należy wskazać:
 - Poziom istotności dla wprowadzenia zmiennej (**slentry**)
 - Poziom istotności dla usunięcia zmiennej (**slstay**)

Jeśli używamy procedur krokowych, obserwacje mające brak danych na którejkolwiek ze zmiennych są wykluczane raz na zawsze


Interakcje



Interakcja występuje wtedy, gdy wpływ jednej zmiennej zależy od innej zmiennej.

Efekt płci na prawdopodobieństwo bezrobocia różni się w zależności od wieku. Przyczyną jest to, że młoda kobieta może zajść w ciążę, co nie jest na rękę potencjalnemu pracodawcy.

W modelu należałoby uwzględnić płeć, wiek i ich interakcję: młoda kobieta



Interakcje

komórka
referencyjna

	$X_1=0$	$X_1=1$
$X_2=0$	OR ₀₀ =1	OR ₁₀
$X_2=1$	OR ₀₁	OR ₁₁

$$\ln(Odds) = a + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$$

	$X_1=0$	$X_1=1$
$X_2=0$	1	2
$X_2=1$	3	4

$$OR_{01} \cdot OR_{10} < OR_{11}$$

$$\beta_3 < 0$$

Efekt łączny mniejszy, niż
złożenie efektów
indywidualnych

	$X_1=0$	$X_1=1$
$X_2=0$	1	2
$X_2=1$	3	6

$$OR_{01} \cdot OR_{10} = OR_{11}$$

$$\beta_3 = 0$$

Efekt łączny równy złożeniu
efektów indywidualnych

	$X_1=0$	$X_1=1$
$X_2=0$	1	2
$X_2=1$	3	8

$$OR_{01} \cdot OR_{10} > OR_{11}$$

$$\beta_3 > 0$$

Efekt łączny większy, niż
złożenie efektów
indywidualnych

Interakcje

- Interakcja zmiennych jakościowych to iloczyny każda z każdą wszystkich zmiennych 0-1 utworzonych dla ich kategorii
 - Komórką referencyjną jest iloczyn logiczny ich kategorii referencyjnych
 - Trudno interpretowalne dla zmiennych kodowanych inaczej niż do kategorii referencyjnej
- Interakcja zmiennej binarnej (X_b) ze zmienną jakościową, bądź ciągłą (X_c) – odrębny zestaw parametrów zmiennej X_c dla grup wyróżnianych przez X_b
 - w grupie $X_b=0 \rightarrow \beta_1$, a grupie $X_b=1 \rightarrow \beta_1 + \beta_3$
- Interakcja zmiennych ciągłych to ich iloczyn – możliwość uchwycenia wpływu nieliniowego
- Uwaga! Interakcja zmiennych jakościowych bardzo często oznacza pojawienie się w modelu kroskategorii o bardzo niskiej częstości i prawie jednopunktowym rozkładzie zmiennej objaśnianej

Model logitowy – inne zagadnienia

Inne problemy

- Zbieżność algorytmu numerycznego
- Zjawisko (quasi) kompletnej separacji – np. gdy uwzględniamy zmienną jakościową, która dla jednego z poziomów ma takie same wartości Y (0 lub 1)
- Współliniowość – trudno uzyskać oszacowania oddzielnego wpływu zmiennych skorelowanych na zmienną niezależną
 - oszacowania są mniej efektywne chociaż nadal nieobciążone;
 - negatywne konsekwencje współliniowości nie dotyczą innych zmiennych w modelu

Wielomianowa regresja logistyczna uporządkowana

- Model dla zmiennej zależnej dyskretnej ale porządkowej.
- Funkcją łączącą jest logit skumulowany (cumulative logits).
- Np.

$$\log\left(\frac{P(Y = 2)}{1 - P(Y = 2)}\right) \quad \log\left(\frac{P(Y = 1) + P(Y = 2)}{1 - \{P(Y = 1) + P(Y = 2)\}}\right)$$

- Logit dla Y=1 lub 2 będzie większy niż logit dla Y=2 o stałą wartość (>0) dla wszystkich obserwacji (własność proporcjonalności).
- Model taki jest określany jako model regresji logistycznej z funkcją łączącą skumulowanych logitów.

Wielomianowa regresja logistyczna nieuporządkowana

- Dla zmiennej zależnej nominalnej bez ustalonego porządku.
- Np. dla Y przyjmującego 4 kategorie: A B C D model przyjmuje postać:

$$P(Y = D|X) = \frac{\exp(\alpha_0 + \beta_0 X)}{1 + \exp(\alpha_0 + \beta_0 X) + \exp(\alpha_1 + \beta_1 X) + \exp(\alpha_2 + \beta_2 X)}$$

$$P(Y = C|X) = \frac{\exp(\alpha_1 + \beta_1 X)}{1 + \exp(\alpha_0 + \beta_0 X) + \exp(\alpha_1 + \beta_1 X) + \exp(\alpha_2 + \beta_2 X)}$$

$$P(Y = B|X) = \frac{\exp(\alpha_2 + \beta_2 X)}{1 + \exp(\alpha_0 + \beta_0 X) + \exp(\alpha_1 + \beta_1 X) + \exp(\alpha_2 + \beta_2 X)}$$

$$P(Y = A|X) = \frac{1}{1 + \exp(\alpha_0 + \beta_0 X) + \exp(\alpha_1 + \beta_1 X) + \exp(\alpha_2 + \beta_2 X)}$$

- Tak zdefiniowany model określany jest jako model regresji logistycznej z funkcją łączącą typu uogólniony logit.

Model regresji liniowej

Zapis macierzowy modelu regresji jest następujący:

$$y = X\beta + \varepsilon$$

gdzie:

X – jest macierzą $n \times k$, wiersze są obserwacjami a kolumny zmiennymi niezależnymi;
pierwsza kolumna macierzy to zazwyczaj wektor jedynek wykorzystywany do wyznaczenia wyrazu wolnego;

β - jest wektorem $k \times 1$ nieznanych parametrów;

ε - jest wektorem $n \times 1$ nieznanych błędów oszacowań, tzw. reszt modelu

Założenia modelu

Idealną sytuacją dla modelu jest kiedy wartości zmiennych niezależnych są wynikiem eksperymentu (kontrolowane). W sytuacji kiedy nie jest to spełnione testy stosowane do oceny modelu muszą być interpretowane warunkowo z uwzględnieniem realizowanych wartości zmiennych.

Pozostałe założenia są następujące:

1. Forma modelu jest prawidłowa, wszystkie istotne zmienne zostały do modelu włączone.
2. Pomiar zmiennych nie jest obarczony systematycznym błędem.
3. Brak współliniowości zmiennych objaśniających.
4. Wartość oczekiwana składnika losowego (reszt) wynosi 0. $E(\varepsilon)=0$
5. Wariancja składnika resztowego jest stała i wynosi σ^2 .
6. Reszty są nieskorelowane pomiędzy obserwacjami. $\text{Cov}(\varepsilon_i, \varepsilon_j)=0$
7. Do weryfikacji hipotez dodatkowo zakłada się rozkład reszt dany jest rozkładem normalnym $\varepsilon \Rightarrow N(0,1)$

Założenia modelu cd.

Jeśli model spełnia podstawowe założenia wówczas estymatory uzyskane metodą najmniejszych kwadratów są najlepszymi liniowymi nieobciążonymi estymatorami (BLUE best linear unbiased estimates) czyli posiadają najmniejszą wariancję spośród wszystkich estymatorów nieobciążonych i dają liniową funkcję względem zmiennej zależnej.

Jeśli dodatkowo założenie o normalności rozkładu reszt jest spełnione wówczas:

1. Statystyki otrzymane w modelu posiadają odpowiednie rozkłady do testowania hipotez .
2. Oszacowania parametrów mają rozkład normalny.
3. Sumy kwadratów odchyłeń mają rozkłady proporcjonalne do rozkładu chi-kwadrat, przynajmniej przy odpowiednich hipotezach. $\sum \varepsilon_i^2 \sim \chi^2$
4. Stosunek oszacowań do ich błędów ma rozkład t-Studenta przy odpowiednich hipotezach. $\alpha/S(\alpha) \sim T\text{-Studenta}$
5. Stosunek sum kwadratów odchyłeń mają rozkład F przy odpowiednich hipotezach.

Estymacja parametrów modelu

Wartości parametrów są otrzymywane poprzez rozwiązanie równania:

$$(\mathbf{X}' \mathbf{W} \mathbf{X}) \mathbf{b} = \mathbf{X}' \mathbf{W} \mathbf{y}$$

gdzie:

$\mathbf{W}$ - macierz diagonalna zawierająca obserwowane wagi na przekątnej.

stąd:

$$\mathbf{b} = (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' \mathbf{W} \mathbf{y}$$

Wariancja składnika resztowego jest następująca:

$$s^2 = MSE = \frac{SSE}{n-k} = \frac{1}{n-k} \sum_{i=1}^n w_i (y_i - x_i \mathbf{b})^2$$

Oszacowania parametrów są nieobciążone:

$$E(\mathbf{b}) = \beta$$

$$E(s^2) = \sigma^2$$

Błędy standardowe ocen (oszacowań) są wyznaczane jako:

$$STDERR(b_i) = \sqrt{(\mathbf{X}' \mathbf{W} \mathbf{X})_{ii}^{-1} s^2}$$

$$(\mathbf{X}' \mathbf{W} \mathbf{X})_{ii}^{-1} \text{ jest } i\text{-tym elementem przekątnej} \quad (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1}$$

Ocena jakości modelu

Ocena istotności parametrów modelu odbywa się za pomocą statystyki t o rozkładzie t-Studenta przy założeniu prawdziwości hipotezy zerowej mówiącej o tym że β_i wynosi 0:

$$t = \left[\frac{(b_i)}{STDERR(b_i)} \right]$$

Program SAS podaje wartość poziomu istotności czyli prawdopodobieństwa że wartość bezwzględna z t będzie wyższa niż otrzymana. Jeśli wartość poziomu istotności będzie mała (niższa od przyjętego krytycznego np. 0,05) wówczas należy H_0 odrzucić.

Współczynnik determinacji liniowej R^2 mierzy stopień w jakim zmienność danych jest wyjaśniona przez model:

$$R^2 = 1 - \left[\frac{SSE}{TSS} \right]$$

gdzie:

SSE – sum of squares for error czyli suma kwadratów odchyłeń dla błędu;

TSS – skorygowana całkowita suma odchyłeń

Skorygowany współczynnik determinacji liniowej R^2 – skorygowany od liczbę parametrów jest wyznaczany jako:

$$ADJRSQ = 1 - \left[\frac{n-i}{n-p} \right] (1 - R^2)$$

gdzie:

n – liczba obserwacji; p – liczba parametrów;
 $i=1$ jeśli występuje wyraz wolny $i=0$ jeśli nie występuje.

Ocena jakości modelu

Miary tolerancji i inflacji wariancji mierzą siłę powiązań pomiędzy zmiennymi niezależnymi w modelu:

$$VIF = \frac{1}{TOL}$$

Jeżeli wszystkie zmienne są niezależne do siebie nawzajem obie miary przyjmują wartość 1. Jeśli zmienna jest blisko związana z innymi zmiennymi to tolerancja zbiega do 0 a inflacja wariancji do nieskończoności (duża wartość).

TOL czyli tolerancja jest to $1-R^2$ wynikający z regresji wszystkich zmiennych niezależnych na daną zmienną niezależną.

VIF jest przekątną macierzy $(\mathbf{X}'\mathbf{W}\mathbf{X})^{-1}$ jeśli $(\mathbf{X}'\mathbf{W}\mathbf{X})$ jest skalowane do formy korelacji ($1/1-R^2$). Wartość VIF nie powinna przekraczać 10.

Interpretacja parametrów i statystyk w modelu

Interpretacja parametrów modelu

Z eksperymentu kontrolowanego. Jeśli model został oszacowany z zadowalającą precyzją wówczas parametry regresji mogą być interpretowane jako: średnia zmiana zmiennej zależnej przy zmianie zmiennej niezależnej o jednostkę zakładając iż pozostałe zmienne są stałe i brak jest interakcji pomiędzy zmiennymi.

Z wartości obserwowanych. Nie można interpretować jako średniej zmiany o jednostkę bo zmiana o jednostkę nie zależy od nas, nie jest wynikiem eksperymentu i nie możemy na nią wpływać. Wartości parametrów mogą być interpretowane jako: oczekiwana różnica wpływu na zmienną zależną dwóch obserwacji różniących się o jednostkę w zmiennej niezależnej, przy założeniu iż te obserwacje mają takie same wartości pozostałych zmiennych niezależnych.

Porównanie parametrów. Porównanie bezpośrednio parametrów w modelu może mieć miejsce tylko jeśli zmienne są wyrażone w tych samych jednostkach. Przydatna jest standaryzacja zmiennych lub standaryzacja sprowadzająca zakres wartości zmiennych do tego samego przedziału np.0-1.

P-value. Wartość p-values nie zawsze jest dobrą miarą istotności parametrów. Często w małej próbie lub w przypadku występowania korelacji pomiędzy zmiennymi niezależnymi parametr może mieć wysoką wartość p-value (czyli nieistotny) podczas gdy faktycznie posiada dużą wagę w regresji. Odwrotnie nieistotny współczynnik może mieć niską wartość p-value w dużej próbie i występowaniu korelacji pomiędzy zmiennymi. Więcej informacji niosą przedziały ufności dla parametrów ale są obciążone zniekształceniami wynikającymi z błędów pomiaru. Założenia dotyczące p-value rzadko są spełnione.

R² jest interpretowany jako proporcja wariancji zmiennej zależnej która może być wyjaśniona regresją zmiennych niezależnych. Inaczej $\sqrt{1 - R^2}$ określa stopień w jakim błąd standardowy predykcji jest zredukowany poprzez wprowadzenie zmiennych niezależnych do modelu. Interpretacja może być zniekształcona jeśli nie mamy do czynienia z próbą losowaną tylko dobieraną. Lepszą miarą do eksperymentów jest średni błąd modelu niż R^2 . Dla modeli bez wyrazu wolnego R^2 nie posiada interpretacji.

Błędy w zmiennych niezależnych i w zmiennej zależnej. Oszacowane wartości parametrów są bardzo wrażliwe na błędy wynikające z pomiaru zmiennych. Interpretujemy parametry wynikające ze zmierzonych wartości zmiennych a nie z wartości faktycznych których nie znamy. Wartości i istotności oszacowań parametrów i modelu są bardzo wrażliwe na występowanie outliersów, stąd ważne jest sprawdzenie ich występowania przed przystąpieniem do estymacji.

Wnioskowanie statystyczne w modelu regresji

$H_0: \mathbf{L}\boldsymbol{\beta} = \mathbf{c}$ - hipoteza o współ-liniowości w modelu

gdzie: $\mathbf{L}$ jest wymiaru $q \times k$; $\boldsymbol{\beta}$ jest wymiaru $k \times 1$; $\mathbf{c}$ jest wymiaru $q \times 1$

Test jest postaci:

$$F = [(SS(\mathbf{Lb} - \mathbf{c})/q)/(s^2)]$$

$$SS(\mathbf{Lb} - \mathbf{c}) = (\mathbf{Lb} - \mathbf{c})' (\mathbf{L}(\mathbf{X}'\mathbf{W}\mathbf{X}) - \mathbf{L}')^{-1} (\mathbf{Lb} - \mathbf{c})$$

Statystyka ma rozkład F z q i dfe stopniami swobody gdzie dfe są to stopnie swobody dla błędu składnika resztowego

Zasady (metody) selekcji zmiennych do modelu

- **FORWARD** – selekcja „wprzód” w pierwszym kroku dopasowuje najlepszy model z jedną zmienną objaśniającą, następnie dobiera zmienną o najmniejszej wartości p-value (wynik z testu oceniającego istotność zmiennej) i kontynuuje proces do momentu aż pośród pozostałych zmiennych nie ma takiej zmiennej dla której p-value jest poniżej ustalonego progu (Entry Significance Level). Zmienna włączona do modelu pozostaje w nim niezależnie od zmiany istotności w późniejszych krokach.
- Dla zmiennej zależnej binarnej – wyznacza test oparty na Chi-kwadrat.
- Dla zmiennej zależnej ciągłej – jako kryterium przyjmuje się redukcję sumy kwadratów reszt wynikającą z włączenia danej zmiennej, w pierwszej kolejności włączana jest zmienna dająca największą redukcję. Miarą redukcji jest test F i p-value spełniające zadana wartość.

Zasady (metody) selekcji zmiennych do modelu

- **BACKWARD** – selekcja „wstecz” najpierw konstruuje model w oparciu o wszystkie zmienne a następnie odrzuca tą o największej wartości p-value (najmniej istotna) i powtarza ten proces aż wszystkie zmienne w modelu mają p-value poniżej pewnego określonego progu (Stay Significance Level). Zmienna raz usunięta nie wraca już do modelu.
- Dla zmiennej zależnej binarnej – wykorzystywany jest test istotności Chi-kwadrat, przy każdym kroku jest wyznaczany test Walda dla każdej charakterystyki (zmiennej) w modelu.
- Dla zmiennej zależnej ciągłej – zamiast statystyki Chi-kwadrat walda wyznaczana jest statystyka F. Wyznaczone wartości F dla każdej zmiennej w modelu to częściowe statystyki F ponieważ są skorygowane na efekty już włączonych do modelu zmiennych (typ 3 analiz) czyli wkład do SS modelu ze względu na daną zmienną przy założeniu że wszystkie pozostałe zmienne są już w modelu (dla porównania typ 2 analiz uwzględnia wpływ na SS danej zmiennej w zależności od kolejności włączenia tej zmiennej do modelu).

zasady (metody) selekcji zmiennych do modelu

- **STEPWISE** – selekcja „krokowa” jest ulepszeniem selekcji „wprzód”, różnica polega na tym że w selekcji krokowej zmienna która zostaje dodana do modelu niekoniecznie tam zostaje. Na każdym kroku testowane są zarówno przydatności zmiennych będących już w modelu jak i istotność tych jeszcze nie włączonych.
- Dla zmiennej zależnej binarnej – podobnie jak poprzednie metody oparta na Chi-kwadrat i statystyce Walda.
- Dla zmiennej zależnej ciągłej – wykorzystuje statystykę F w połączeniu z wartością R^2 w kroku forward a statystykę częściową F w kroku backward.

Kryterium selekcji modelu

- Dla zmiennej zależnej binarnej miarą błędu całego modelu jest:

$$-2\text{Log}L = -2\sum [y_i \log(\hat{\pi}_i(x_i)) + (1 - y_i) \log(1 - \hat{\pi}_i(x_i))]$$

Dla zmiennej ciągłej jest to suma kwadratów odchyleń między wartością teoretyczną a empiryczną.

- Kryterium informacyjne Akaika (AIC) – do porównywania zupełnie różnych modeli.

$$AIC = -2\text{Log}L + 2(k + s)$$

(k – liczba poziomów zmiennej zależnej, s – liczba zmiennych objaśniających)

- Kryterium Bayesowskie Schwarza (SBC)

$$SBC = -2\text{Log}L + (k + s)\ln n$$

(n – liczba obserwacji)

Im niższa wartość kryterium AIC lub SBC tym lepszy model.

- Błąd Walidacji – wartość błędu modelu oszacowana na zbiorze walidacyjnym, im niższa wartość tym lepszy model.
- Błąd klasyfikacyjny Walidacji – błąd klasyfikacji wyznaczony na zbiorze walidacyjnym, czyli liczba błędnych klasyfikacji w stosunku do ogółem liczebności zbioru walidacyjnego. Jako błędną klasyfikację uznajemy obserwację dla której model przewidywał np. 0 a rzeczywista wartość zmiennej zależnej wynosiła 1 i odwrotnie.

Kryterium selekcji modelu

- Błąd Cross-walidacji – do wyznaczenia błędu wykorzystuje się zbiór treningowy. Ze zbioru wyłączana jest 1 obserwacja a następnie model jest re-estymowany na pozostałych ($n-1$) obserwacjach. Na podstawie tak oszacowanego modelu jest określana prognozowana wartość zmiennej zależnej dla wyłączonej obserwacji a następnie czynność jest powtarzana dla kolejnych obserwacji a różnica jest podstawą do wyznaczenia błędu (wg -2LogL dla zmiennej binarnej $n=1$, lub jako kwadrat różnic dla zmiennej ciągłej)
- Błąd klasyfikacyjny Cross-walidacji – podobny mechanizm jak w błędzie Cross-walidacji ale wyznaczany jest zamiast błędu wskaźnik błędnych klasyfikacji, przyjmując porównanie do maksymalnej wartości prawdopodobieństwa otrzymanego z modelu.
- Zysk/strata Walidacji – oparta na macierzy zysku zdefiniowanej przez użytkownika. Zysk/strata jest wyznaczana na zbiorze walidacyjnym. Na podstawie macierzy zysku określana jest potencjalna decyzja: np 0 lub 1 a następnie po decyzji wyznaczany jest faktyczny zysk/strata a różnica między faktycznym zyskiem a potencjalnym zyskiem jest sumowana na całym zbiorze walidacyjnym. Wybierany jest model o najwyższym zysku całkowitym.
- Zysk/strata – podobnie jak dla kryterium Zysk/strata Walidacji ale wyniki oparte są na zbiorze treningowym.
- Zysk/strata Cross-walidacji. - mechanizm podobny jak dla błędu klasyfikacji Cross-walidacji ale z uwzględnieniem sumy różnic między potencjalnym zyskiem a faktycznym zyskiem jako kryterium wyboru.