

Modelowanie predykcyjne - drzewa decyzyjne i lasy losowe

Aneta Ptak-Chmielewska

Instytut Statystyki i Demografii

aptak@sgh.waw.pl

struktura wykładu

- Drzewo decyzyjne – definicje
- Model drzewa decyzyjnego
- Wyznaczanie jakości drzewa „Worth of a Tree”
- Rola zbioru: treningowego, walidacyjnego i testowego
- Budowa drzewa decyzyjnego w EM
- Przykład drzewa dla zmiennej targetowej binarnej
- Korekta na Oversampling
- Alternatywne zastosowania
- Zalety i wady drzew.
- Lasy losowe

Drzewo decyzyjne – definicje

- Drzewo decyzyjne: hierarchiczna segmentacja (podział) danych.
- Korzeń: element główny, obejmujący cały wyjściowy zbiór danych.
- Węzeł (node): segment lub sub-segment powstały poprzez podział danych wg reguły zbudowanej na podstawie zmiennych objaśniających. Segment, który jest poddawany podziałowi na subsegmenty jest określany jako węzeł-rodzic (lub węzeł pośredni) a subsegmenty jako węzły-dzieci.
- Gałąź: węzeł z dalszymi subsegmentami.
- Liść (grupa): końcowy segment, który już nie podlega podziałowi. Każda obserwacja ze zbioru wyjściowego jest przyporządkowana do jednego tylko do jednego liścia końcowego.
- Drzewo decyzyjne zawiera pośrednie węzły i końcowe liście, natomiast model drzewa decyzyjnego zawiera tylko liście końcowe do predykcji lub klasyfikacji danych.

Drzewa decyzyjne

- Występuje zmienna objaśniana (*target variable*)
- **Drzewo regresyjne** – zmienna objaśniana jest zmienną ilościową
- **Drzewa klasyfikacyjne** – zmienna objaśniana jest zmienną jakościową (binarną lub wielopoziomową)
- W celu podzielenia zbioru obiektów dokonujemy kolejnych podziałów zakresu zmienności cech (zmiennych) opisujących te obiekty
- Proces podziału wygodnie jest przedstawić graficznie w postaci drzewa
- Drzewo jest grafem spójnym, nie zawierającym cyklu, a więc takim, w którym istnieje tylko jedna droga między dwoma różnymi **wierzchołkami** nazywanymi również **węzłami**
- Wierzchołek początkowy drzewa, z którego wychodzą przynajmniej dwie krawędzie, nazywamy **korzeniem drzewa**
- Wierzchołki końcowe, z których nie wychodzą żadne krawędzie, nazywamy **liśćmi**
- Najdłuższą drogę między korzeniem a dowolnym liściem nazywamy **głębokością drzewa**

Model drzewa decyzyjnego

- Klasyczny model drzewa decyzyjnego, dla zmiennej targetowej binarnej, zawiera następujące elementy (wszystkie elementy są szacowane na podstawie zbioru treningowego):
 - Definicje węzłów, lub zasady przyporządkowania każdej obserwacji ze zbioru wyjściowego do liścia końcowego,
 - Prawdopodobieństwa (posteriori) dla każdego liścia końcowego, określone jako proporcje wystąpień zdarzenia modelowanego dla zmiennej targetowej binarnej w każdym liściu końcowym,
 - Przypisanie poziomu zmiennej targetowej w modelu (zmiennej zależnej) do każdego liścia końcowego. Reguła decyzyjna może być oparta na maksymalizacji zysków, minimalizacji kosztów lub minimalizacji błędu klasyfikacji.
- W przypadku zmiennej zależnej ciągłej dla liścia końcowego określana jest wartość oczekiwana zmiennej a model określany jest jako drzewo regresyjne.
- Drzewo decyzyjne w odróżnieniu od regresji logistycznej binarnej nie zawiera żadnych równań ani współczynników opiera się tylko na regułach podziału do podziału zbioru danych na rozłączne grupy. Jako oszacowane prawdopodobieństwa wykorzystywane są prawdopodobieństwa posteriori dla każdego liścia.
- Reguły wygenerowane przez model mogą posłużyć do predykcji danych bez zmiennej targetowej (wynikiem będą decyzje binarne).


Wyznaczanie jakości drzewa „Worth of a Tree”

- Do wyznaczania wartości drzewa wykorzystać można dowolny zbiór: walidacyjny, testowy, lub inny. Wykorzystuje się w tym celu tylko liście drzewa.
- W EM wykorzystywany jest zbiór walidacyjny do porównania efektywności drzew różnych rozmiarów i wyboru najlepszego. W przypadku zbioru testowego wyniki pozwalają porównać kilka różnych modeli między sobą.
- Miary wykorzystywane do oceny wartości drzewa w EM są następujące:
 - Decision: maksymalizacja zysków z wykorzystaniem macierzy zysku lub minimalizacja kosztów z wykorzystaniem macierzy kosztów.
 - Average Squared Error: średnia z kwadratów różnic między przewidywanym wynikiem i rzeczywistymi wartościami zmiennej targetowej (bardziej odpowiednie dla zmiennej ciągłej).
 - Missclassification: minimalizacja błędu klasyfikacji (liczby błędnych klasyfikacji).
 - Lift: udział faktycznych zdarzeń w $n\%$ górnych obserwacji uporządkowanych względem prawdopodobieństw oszacowanych w modelu dla każdej obserwacji w stosunku do ogółem udziału zdarzeń w całym zbiorze.
- Postępowanie jest dwustopniowe:
 - Przyporządkowanie obserwacji zgodnie z regułą do danego liścia, wyznaczenie wartości miary dla każdego liścia i sumy dla wszystkich liści,
 - Wyznaczenie wartości miary jakości drzewa uśrednionej dla wszystkich liści. Suma np₀ zysków jest dzielona przez liczbę obserwacji w całym drzewie.

Rola zbioru: treningowego, walidacyjnego i testowego

- Do budowy modelu drzewa decyzyjnego konieczne są co najmniej dwa zbiory. Opcjonalnie trzeci zbiór do niezależnej oceny efektywności modelu.
- Proporcje podziału zbioru na trzy podzbiory zależą od wielkości zbioru wyjściowego. Typowy podział to: 40,30,30 albo przy mniejszych zbiorach: 50,25,25.
- Training data set (zbiór treningowy) jest wykorzystywany w celu:
 - Określenie zasad segmentacji/przyporządkowania obserwacji do liści drzewa (definicja węzłów)
 - Wyznaczenia posteriori prawdopodobieństw dla każdego liścia drzewa na podstawie proporcji zdarzeń zmiennej zależnej w każdym końcowym liściu.
 - Przyporządkowanie decyzji do każdego liścia.
- Validation Data (zbiór walidacyjny) wykorzystywany jest do przycinania drzewa i w ten sposób do znalezienia drzewa optymalnego (najlepszego). Drzewo wyjściowe (maksymalne) jest przycinane i na każdym kroku jest liczona wartość danego drzewa, w efekcie końcowym na podstawie wartości wybierane jest optymalne drzewo.
- Test data (zbiór testowy) służy do niezależnej oceny finalnego modelu i/lub porównania modelu drzewa decyzyjnego do innego modelu zbudowanego dla tych samych danych.

Metoda rekurencyjnego podziału



Metoda rekurencyjnego podziału

Tworzenie drzewa klasyfikacyjnego odbywa się na podstawie zbioru uczącego, w którym przynależność obiektów do poszczególnych klas jest znana. Algorytm:

1. Mając dany zbiór obiektów S sprawdź, czy należą do tej samej klasy; jeżeli tak, to zakończ.
2. W przeciwnym razie rozważ wszystkie możliwe podziały zbioru S na dwa rozłączne podzbiory S_1 i S_2 .
3. Wybierz podział, który daje dwa najbardziej różniące się podzbiory, czyli podział, który najbardziej zmniejsza zróżnicowanie badanego zbioru.
4. Zakończ, jeżeli spełnione jest kryterium stopu; jeżeli nie, to przejdź do 1 przyjmując jako S kolejno zbiory S_1 i S_2 .

Opracowano wiele algorytmów szczegółowych realizujących metodę rekurencyjnego podziału, różnią się one:

- sposobem wyboru cech, w oparciu o które następuje podział,
- postacią funkcji oceniającej jakość podziału (tzw. miary zanieczyszczenia – *impurity*),
- kryterium zakończenia podziału (kryterium stopu),
- sposobem traktowania brakujących danych (brakujące dane mogą tworzyć odrębną kategorię albo być zastąpione wartościami imputowanymi).

Metoda rekurencyjnego podziału

Przycinanie drzew

- algorytm działa tak długo, aż uzyskane podzbiory są jednorodne ze względu na zmienną zależną. Prowadzi to na ogół do drzew o dużej złożoności (głębokości), w skrajnych przypadkach zbiór n -elementowy zostaje podzielony na n podzbiorów jednoelementowych (mamy wtedy n liści),
- ze względów praktycznych godzimy się, aby uzyskane podzbiory były mniej jednorodne, ale bardziej liczne,
- polega to na łączeniu podzbiorów w ten sposób, aby błąd klasyfikacji nie zwiększał się znacząco - jest to tzw. przycinanie drzewa (*pruning*).

Kryterium stopu

Proces budowy drzewa zostaje zakończony na poziomie danego węzła, gdy spełniony jest jeden z warunków (kryterium stopu):

- wszystkie obiekty węzła mają jednakową wartość zmiennej zależnej,
- została osiągnięta maksymalna dopuszczalna głębokość drzewa,
- liczba obiektów w węźle jest mniejsza niż przyjęta minimalna liczba obiektów,
- podział węzła doprowadziłby do utworzenia węzła podrzędnego o liczebności mniejszej niż przyjęta minimalna liczba obiektów w węźle.

Budowa początkowego drzewa

- Dla zmiennej zależnej binarnej oraz przy założeniu że podział jest binarny czyli zawsze na dwie grupy algorytm podziału polega na wyborze podziału o najwyższej jakości podziału z zestawu wszystkich możliwych podziałów dla danej zmiennej objaśniającej:
- Krok 1:
 - Najlepszy punkt podziału dla każdej zmiennej objaśniającej jest wybierany, krokowo jest sprawdzana jakość podziału na grupy przy zastosowaniu wybranej miary jakości podziału. Np. sprawdzane są podziały dla zmiennej wiek: czy lepszy będzie podział na grupy: ≤ 19 i > 19 czy lepszy ≤ 20 i > 20 itd.
- Krok 2:
 - Wybierany jest najlepszy z podziałów z zestawu najlepszych podziałów dokonanych w kroku 1. Dokonywany jest podział, tworzony jest w ten sposób węzeł.
- Proces powtarza się dla każdego węzła, różne zmienne mogą być wybierane dla różnych węzłów.

Pomiar jakości podziału

- Podstawowe sposoby pomiaru jakości podziału dla zmiennych zależnych binarnych lub dyskretnych z kilkoma kategoriami to:
 - Stopień separacji osiągnięty przez podział (mierzony p-vale testu Chi-kwadrat Pearsona)
 - Stopień redukcji zanieczyszczenia osiągnięty przez podział (mierzony redukcją Entropii lub Giniego).
- Dla zmiennej zależnej ciągłej, jakość podziału jest mierzona testem F do oceny stopnia separacji węzłów dzieci.

Pomiar jakości podziału – zmienna zależna dyskretna

- Stopień separacji osiągnięty przez podział (mierzony p -value testu Chi-kwadrat Pearsona)
- Miarą oceniającą jak różne są węzły rodzice od węzłów dzieci i węzły dzieci między sobą pod kątem struktury klas jest miara określana jako: *Logworth*. Wyznaczenie tej miary odbywa się następująco:

- Wyznaczenie statystyki Chi-kwadrat wg wzoru:

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^2 \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}}$$

- Wyznaczenie wartości p -value dla statystyki Chi-kwadrat
- Wyznaczenie *Logworth* wg wzoru:

$$\text{Logworth} = -\log_{10}(p\text{-value})$$

- Im wyższa wartość *Logworth* czyli mniejsza wartość p -value tym lepszy jest podział.

Test Chi-kwadrat - przykład

- Przykładowo dokonujemy podziału węzła rodzica (100 obserwacji: 10 responders '1' i 90 non-responders '0') na dwa węzły dzieci (po 50 obserwacji w każdym: węzeł A:9 responders i węzeł B: 1 responder)

- Tablica kontyngencji przyjmuje postać:

	Węzeł A	Węzeł B
responders	9	1
non-responders	41	49

- H0 zakłada że węzły dzieci mają taką samą proporcję responders vs non-responders jak węzeł rodzic, czyli hipotetycznie układ powinien być następujący:

	Węzeł A	Węzeł B
responders	5	5
non-responders	45	45

- Chi-kwadrat wynosi więc:

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^2 \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}} = \frac{(4)^2}{5} + \frac{(-4)^2}{45} + \frac{(-4)^2}{5} + \frac{(4)^2}{45} = 7,1$$

- Stąd p-value dla Chi-kwadrat=7,1 wynosi: 0,0076655 oraz Logworth wynosi: $\log_{10}(p\text{-value})=2,11546$
- Węzły dzieci różnią się więc istotnie co do proporcji 0 vs 1 w stosunku do węzła rodzica.

Pomiar jakości podziału – zmienna zależna dyskretna

- Stopień redukcji zanieczyszczenia osiągnięty przez podział (mierzony redukcją Entropii lub Giniego). Zanieczyszczenie węzła jest rozumiane jako stopień heterogeniczności w odniesieniu do proporcji kategorii zmiennej zależnej. Wyróżnia się dwie podstawowe miary zanieczyszczenia:

1. Indeks zanieczyszczenia **Giniego**

$$i(p) = 1 - p_1^2 - p_0^2$$

- gdzie p_0 jest to udział 0 natomiast p_1 to udział 1 czyli zdarzeń.
- czyli prawdopodobieństwo że dowolne losowo wybrane elementy są różne co do wartości zmiennej zależnej (0 lub 1).
- dla zmiennej zależnej binarnej Gini upraszcza się do postaci: $2p_1(1-p_1)$
- Gini przyjmuje wartości od 0 (czysty węzeł) do $\frac{1}{2}$ czyli po równo 0 i 1.

2. Entropia

$$i(p) = -\sum_{i=0}^1 p_i \log_2(p_i)$$

- Dla zmiennej binarnej
- Im wyższa wartość wskaźnika tym wyższa heterogeniczność danego węzła.
- Węzeł z równą proporcją 0 i 1 ma wartość Entropii równą 1. czysty węzeł ma wartość Entropii 0.

Pomiar jakości podziału – zmienna zależna ciągła

- Stopień separacji mierzony jest testem F natomiast jakość takiego podziału jest mierzona wartością *Logworth* opartą na p-value z przeprowadzonej analizy wariancji.

$$SS_{between} = \sum_{i=1}^2 n_i (\bar{y}_i - \bar{y})^2$$

- gdzie $\bar{y}_i$ jest średnią wartością zmiennej targetowej dla węzła dziecka, natomiast $\bar{y}$ jest średnią dla węzła rodzica.

$$SS_{within} = \sum_{i=1}^2 \sum_{j=1}^{n_i} (\bar{y}_{ij} - \bar{y}_i)^2$$

- gdzie y_{ij} jest wartością zmiennej targetowej dla j-tego rekordu dla i-tego węzła dziecka.

- Statystyka F ma rozkład F-Snedecora z 1 i n-2 stopniami swobody. Na podstawie tej statystyki wyznaczane jest p-value i Logworth zgodnie z wzorem: $-\log_{10}(p\text{-value})$

$$F = \left(\frac{SS_{between}/(2-1)}{SS_{within}/(n-2)} \right)$$

Opcje korygujące p -value (domyślnie w EM)

- **Korekta Benferroniego** – przy dokonywaniu podziałów, uwzględnienia faktu że nie wszystkie zmienne objaśniające mają taką samą liczbę kategorii. Zmienne objaśniające mogą być binarne, dyskretne z dużą liczbą kategorii lub ciągłe pogrupowane w klasy. W przypadku zmiennych z dużą liczbą kategorii wartość p -value będzie skorygowana przy wyznaczaniu Logworth

$$\text{Logworth}_i = -\log(m \cdot p\text{-value})$$

- m liczba podziałów dla zmiennej, stąd zmienna binarna będzie rozpatrywana na równi ze zmienną która przyjmuje 10 kategorii.
- Korekta w EM uwzględniona jest w opcji ‘Time of Kass Adjustment’
- **Korekta ścieżki** – uwzględnia liczbę podziałów w danej ścieżce od korzenia do aktualnego liścia będącego wynikiem podziału. W tej korekcie p -value jest mnożone przez tzw. multiplikator ścieżki. Im więcej podziałów miało miejsce w danej ścieżce tym bardziej restrykcyjne p -value jest dla kolejnego podziału. Zwiększenie p -value powoduje zmniejszenie *Logworth*. Dla binarnych podziałów multiplikator wynosi 2^d gdzie d jest ścieżką aż do aktualnego węzła. *Logworth* jest skorygowany wówczas o: $d \log_{10}(2)$.
- Korekta ścieżki ogranicza nadmierny rozrost drzewa, powodując że kolejne podziały nie są istotne.

Zasady zatrzymania podziału drzewa

- Poziom istotności – ustawiając krytyczny poziom odcięcia p -value można kontrolować wielkość drzewa i dalsze podziały gałęzi. Do zadanego p -value wyznaczany jest *Logworth* i stanowi on punkt odcięcia do dalszych podziałów. Jeżeli dla danego węzła żadna ze zmiennych objaśniających nie ma wartości *Logworth* powyżej lub co najmniej równej ustawionej wartości wówczas podział jest zatrzymywany.
- Poziom istotności skorygowany – krytyczna wartość p -value jest ustawiona z uwzględnieniem p -value skorygowanego na wielkość ścieżki. Rozmiar drzewa z uwzględnieniem p -value skorygowane jest mniejszy niż dla p -value nieskorygowanego.
- Wielkość liścia – ustawienie minimalnej wielkości liścia końcowego drzewa. Np. 100, jeżeli wielkość liścia po podziale jest mniejsza wówczas taki podział nie dokonuje się i dalszy podział jest zatrzymywany.
- Wielkość podziału – ustawienie krytycznej wielkości dla węzła, jeżeli wielkość całego węzła jest zbyt mała to podział nie następuje. Domyślne ustawienie jest na dwukrotność wielkości liścia.
- Maksymalna wielkość ścieżki podziałów – ustalenie maksymalnej długości ścieżki czyli generacji węzłów. Węzeł-korzeń to generacja 0. Domyślna wartość to 6.

Przycinanie drzewa

- Po zbudowaniu drzewa z zastosowaniem wybranej metody zatrzymania podziału należy drzewo tak uzyskane przyciąć do właściwego rozmiaru.
- Przycinanie odbywa się etapami, najpierw obcina się 1 podział i sprawdza wszystkie możliwe kombinacje drzew, wybiera się z nich najlepsze, następnie przycina się kolejny podział i sprawdza najlepsze drzewo pozbawione już dwóch podziałów, itd. aż do samego korzenia.
- Na każdym etapie przycinania wybiera się drzewo o największym średnim proficie lub accuracy lub lift a następnie porównuje między sobą i wybiera ostatecznie jedno z nich biorąc pod uwagę przyjęte kryteria jak i stopień skomplikowania (rozmiar) drzewa. Profit dla danego pod-drzewa wyznacza się w oparciu o zbiór walidacyjny.
- Alternatywnie może być zastosowane kryterium: minimalizacji kosztów, minimalizacji błędu klasyfikacji, minimalizacji średniego błędu lub maksymalizacja liftu.
- Wraz ze wzrostem liczby liści profit drzewa będzie początkowo zwiększał się ale po osiągnięciu pewnego punktu nie będzie już widać przyrostu a nawet może nastąpić jego spadek. Punkt ten wskazuje na optymalną wielkość drzewa.

Kryteria przycinania drzewa


- Porównanie profitu średniego i ogólnego powstałego jako suma profitów dla wszystkich liści może różnić się przy różnej wielkości drzew. Średni profit to profit ogółem podzielony na liczbę obserwacji. (zbiór walidacyjny).
- Kryterium błędnych klasyfikacji lub accuracy. Przyjmuje się że punktem dodatnim jest poprawna decyzja klasyfikacyjna, za błędną jest 0 punktów. Na tej podstawie wyznaczany jest błąd klasyfikacji dla każdego rodzaju drzewa (wszystkie wielkości pod-drzew).
- W przypadku drzew ze zmienną zależną ciągłą stosuje się średni błąd kwadratowy. Suma kwadratów odchyleń obliczana jest jako różnica między średnią (wyznaczona na zbiorze treningowym) a wartościami dla zmiennej wyznaczonymi na zbiorze walidacyjnym. Dla każdego drzewa i pod-drzewa wyznaczana jest ważona średnia kwadratów odchyleń dla poszczególnych liści.

$$\sum_{t=1}^T \frac{n_t}{n} \left[\frac{1}{n_t} \sum_{i=1}^{n_t} (y_{it} - \bar{y}_t)^2 \right]$$

Przykład drzewa dla zmiennej targetowej binarnej


- Problem marketingowy: do klientów wysłano ankietę zachęcającą do kupna nowego ubezpieczenia, jeżeli respondent odeśle ankietę wówczas może skorzystać z dodatkowej zniżki. Początkowo wysyłano ankiety do wszystkich klientów, ale ze względu na niską odpowiedzialność zdecydowano zawęzić targetową grupę w celu minimalizacji kosztów.
- Zmienna zależna (target) przyjmuje dwie wartości:
 - 1 gdy respondent odesłał ankietę
 - 0 gdy respondent nie odesłał ankiety
- Zastosowane charakterystyki objaśniające (input):
 - Dochód (poniżej 3 tys., 3 tys. i więcej)
 - Wiek (poniżej 30 lat, 30 lat i więcej)
 - Płeć (kobieta, mężczyzna)
- Łącznie grupa ankietowana liczyła 12.516. Dokonano podziału na próbę treningową 7.152 oraz walidacyjną 5.364.

Zbiór treningowy



- Na podstawie drzewa decyzyjnego można wyznaczyć zasady definiujące liście drzewa:
 - Liść 1: jeżeli wiek jest mniejszy niż 30 lat i jest to kobieta wówczas respondent trafia do grupy 1 czyli liścia 1.
 - Liść 2: jeżeli wiek mniejszy niż 30 lat i jest to mężczyzna wówczas respondent trafia do grupy 2 czyli liścia 2.
 - Liść 3: jeżeli wiek wynosi 30 lat i więcej a dochód mniej niż 3 tys. wówczas respondent trafia do grupy 3 czyli liścia 3.
 - Liść 4: jeżeli wiek wynosi 30 lat i więcej a dochód 3tys i więcej wówczas respondent trafia do grupy 4 czyli liścia 4.
- Na podstawie udziału odpowiedzi pozytywnych na ankietę w każdym liściu ustala się *posteriori* prawdopodobieństwo reakcji pozytywnej na ankietę dla respondentów znajdujących się w tej grupie.
- Dokonuje się decyzji czy będzie to zaklasyfikowanie do grupy 1 czy do grupy 0 na podstawie prawdopodobieństw *posteriori* i na podstawie macierzy profitów. Wszystkie rekordy w jednym liściu mają przypisana taką samą decyzję klasyfikacyjną. Zakładając więc trafną decyzję 1 jako +10zł a błędną decyzję 1 jako -1zł, pozostałe decyzje jako 0 mamy:
 - Węzeł 2: $\text{dec}(1)=10\text{zł} \cdot 0,08 + (-1) \cdot 0,92 = -0,12$ $\text{dec}2=0 \cdot 0,08 + 0 \cdot 0,92 = 0$ więc decyzja (0)
 - Węzeł 3: $\text{dec}(1)=10\text{zł} \cdot 0,113 + (-1) \cdot 0,887 = 0,243$ $\text{dec}2=0 \cdot 0,113 + 0 \cdot 0,887 = 0$ więc decyzja (1)
 - Węzeł 4: $\text{dec}(1)=10\text{zł} \cdot 0,07 + (-1) \cdot 0,93 = -0,23$ $\text{dec}2=0 \cdot 0,07 + 0 \cdot 0,93 = 0$ więc decyzja (2)
 - itd.

Zbiór walidacyjny



- Szukanie optymalnego drzewa odbywa się poprzez wyznaczenie profitu dla wszystkich pod-drzew przyjmując macierz profitów (poprawna decyzja 1 +10zł, niepoprawna decyzja 1 -1zł, pozostałe 0zł). Profit dla poszczególnych węzłów jest następujący:
 - Węzeł 1 (decyzja 1): $560 \cdot 10 + 4804 \cdot (-1) = 796 \text{pln}$
 - Węzeł 2 (decyzja 0): $202 \cdot 0 + 2114 \cdot 0 = 0 \text{pln}$
 - Węzeł 3 (decyzja 1): $358 \cdot 10 + 2690 \cdot (-1) = 890 \text{pln}$
 - Węzeł 4 (decyzja 0): $72 \cdot 0 + 1004 \cdot 0 = 0 \text{pln}$
 - Węzeł 5 (decyzja 0): $130 \cdot 0 + 1110 \cdot 0 = 0 \text{pln}$
 - Węzeł 6 (decyzja 1): $177 \cdot 10 + 1448 \cdot (-1) = 322 \text{pln}$
 - Węzeł 7 (decyzja 1): $181 \cdot 10 + 1242 \cdot (-1) = 568 \text{pln}$.
- W zależności od przycięcia powstaną drzewa o następującym proficie:

Podsumowanie			
drzewo	Liczba liści	profit	suma
korzeń	1	796	796
Węzły: 2 i 3	2	0+890	890
Węzły: 3,4 i 5	3	890+0+0	890
Węzły: 2,6 i 7	3	0+322+568	890
Węzły: 4,5,6 i 7	4	0+0+322+568	890

Korekta na Oversampling

- Do predykcji zdarzeń rzadkich wykorzystuje się zmodyfikowany zbiór zawierający wszystkie zdarzenia czyli $\text{target}=1$ oraz wylosowane rekordy dla $\text{target}=0$. Zabieg jest określany jako oversampling.
- Model wymaga korekty oszacowanych prawdopodobieństw ze względu na niezrównoważoną próbę za pomocą *prior* prawdopodobieństw.
- Skorygowane prawdopodobieństwa wynoszą więc:

$$(P_1)_{\text{skorygowana}} = \frac{P_1(\pi_1/p_1)}{P_0(\pi_0/p_0) + P_1(\pi_1/p_1)} \quad (P_0)_{\text{skorygowana}} = \frac{P_0(\pi_0/p_0)}{P_0(\pi_0/p_0) + P_1(\pi_1/p_1)}$$

- gdzie:

p_1, p_2 proporcja $\text{target}=1$ i $\text{target}=0$ dla całej populacji

P_1, P_2 proporcja $\text{target}=1$ i $\text{target}=0$ dla próby niezrównoważonej

π_1, π_2 oszacowane w modelu prawdopodobieństwo dla $\text{target}=0$ i $\text{target}=1$

Przykłady zastosowań

- Do oceny lojalności klientów czyli do predykcji ryzyka odejścia klienta (churn analysis), np. w telekomunikacji lub w bankowości (detalicznej).
- Do segmentacji rynku klientów względem wyróżnionego kryterium.
- Do oceny ryzyka niewywiązywania się ze swoich zobowiązań klienta w banku (choć częściej stosuje się tu analizę dyskryminacyjną i model regresji logistycznej)

Alternatywne zastosowania

Wysoki stopień elastyczności drzew decyzyjnych powoduje, że mają one szereg zastosowań na różnych etapach analizy danych:

- Selekcja istotnych zmiennych – drzewa decyzyjne automatycznie dobierają najistotniejsze zmienne, sprawdzając ich istotność w określonych obszarach. Co więcej, istotność ta obejmuje zależności nieliniowe, więc wyjście z modelu może być wejściem dla np. sieci neuronowej.
- Konsolidacja zmiennych dyskretnych – często dla łatwości interpretacji lub po prostu zaoszczędzenia zasobów niezbędnych do budowy modelu, jesteśmy zainteresowani znalezieniem podobnych do siebie poziomów zmiennej dyskretnej i połączenia ich w grupy:
- Dyskretyzacja zmiennych ciągłych - przekształcenia zmiennych w modelu regresji umożliwiają dostosowanie go do zależności nieliniowych. Dyskretyzacja przeprowadzana automatycznie przez drzewa decyzyjne jest jedną z takich transformacji.
- Uzupełnianie braków danych - umożliwia uzupełnienie braków danych na podstawie wartości pozostałych zmiennych.
- Objaśnianie modeli złożonych (np. sieci neuronowe) – decyzje generowane przez złożone modele mogą być aproksymowane przez funkcję schodkową, generowaną przez drzewo decyzyjne. Mechanizm takiego działania obejmuje:
 - budowa złożonego modelu,
 - ustawienie statusu zmiennej opisującej decyzje modelu na status zmiennej objaśnianej
 - budowa zestawu drzew decyzyjnych modelującego tą zmienną i wybór takiego, który osiągnie możliwie najmniejszy odsetek błędnych klasyfikacji na próbie walidacyjnej.

Zalety i wady drzew decyzyjnych

- Zalety:
 - Łatwość interpretacji i wizualizacji danych
 - Odporne na istnienie braków danych (missings)
 - Automatycznie dobiera zmienne istotne dla modelu
 - Dopasowuje się do zależności nieliniowych
- Wady:
 - Drzewa decyzyjne są często niestabilne (duże znaczenie podziału zbiorów)
 - W każdym z podziałów włączana jest jednocześnie tylko jedna zmienna objaśniająca
 - Konieczna jest duża próba ucząca żeby drzewo było stabilne
 - Przybliżanie zmiennej objaśnianej funkcją schodkową (przybliżanie prawdopodobieństwa posteriori)

Lasy losowe

- jedna z najlepszych procedur analityki predykcyjnej,
- implementacja algorytmu agregacji bootstrap'owej,
- pojedynczy klasyfikator w postaci drzewa klasyfikacyjnego,
- schemat algorytmu:
 - wylosowanie ze zwracaniem prób bootstrap'owych,
 - na każdej próbie buduje się drzewo, przy czym w każdym węźle losuje się m z p atrybutów i stosuje się przyjętą regułę podziału,
 - drzewo budowane bez przycinania,
 - dana obserwacja jest zaklasyfikowana do tej klasy, do której większość drzew je zaklasyfikowała,
- własności:
 - można stosować do dużych zbiorów danych,
 - nadają się do zbiorów o dużym wymiarze zmiennych (tzn. atrybutów),
 - wbudowany mechanizm oceny prawdopodobieństwa błędnej klasyfikacji (estymator nieobciążony).
- Jest to aktualnie jedna z najskuteczniejszych, obok SVM oraz boostingu, metod klasyfikacji.
- Oprócz klasyfikacji lasy losowe mogą być wykorzystane w regresji oraz analizie przeżycia.

Lasy losowe

Lasy losowe są uznawane za jedna z najlepszych metod klasyfikacji.

Algorytm Random Forest bardzo dobrze nadaje się do badania próby, gdzie wektor obserwacji jest dużego wymiaru.

Ich dodatkową zaletą jest możliwość użycia nauczonego lasu losowego do innych zagadnień niż tylko do klasyfikacji. Przykładowo, na podstawie drzew z lasu można wyznaczyć ranking zmiennych, a tym samym określić, które zmienne mają lepsze właściwości predykcyjne.

Podczas generowania drzew zbiór wejściowy zostaje podzielony na dwa podzbiory: treningowy oraz zbiór OOB (out-of-bag), który składa się z ok. $\frac{1}{3}$ obserwacji. Zbiór OOB służy do estymacji błędów klasyfikacji oraz istotności poszczególnych zmiennych. Błąd predykcji OOB pokazuje ile elementów ze zbioru testowego nie zostało przyporządkowanych poprawnie do ich właściwych klas. Jest on różnicą między wszystkimi elementami znajdującymi się w macierzy trafności, a elementami znajdującymi się poza przekątną macierzy.

Jak działa algorytm Random Forest?

1. Losujemy ze zwracaniem z n -elementowej próby uczącej n wektorów obserwacji. Na podstawie takiej pseudopróby stworzone zostanie drzewo.
2. W każdym węźle podział odbywa się poprzez wylosowanie bez zwracania m spośród p atrybutów, następnie w kolejnym węźle k spośród m atrybutów itd ($p \geq m \geq k$) (parametr m jest jedynym elementem algorytmu, który trzeba ustalić, wartość dająca dobre wyniki dla modeli decyzyjnych to około $m = \sqrt{p}$, dla modeli regresyjnych $m/3$).
3. Proces budowania drzewa bez przycinania trwa, jeżeli to możliwe do momentu uzyskania w liściach elementów z tylko jednej klasy.

Proces klasyfikacji

1. Dany wektor obserwacji jest klasyfikowany przez wszystkie drzewa, ostatecznie zaklasyfikowany do klasy, w której wystąpił najczęściej.
2. W przypadku elementów niewylosowanych z oryginalnej podpróby, każdy taki i -ty element zostaje poddany klasyfikacji przez drzewa, w których budowie nie brał udziału. Taki element zostaje następnie przyporządkowany klasie, która osiągnięta była najczęściej (w ten sposób zaklasyfikowane zostały wszystkie elementy z oryginalnej próby).

Algorytm Random Forest wykorzystuje indeks Giniego, który służy jako podstawowe kryterium oceny jakości podziału węzła w drzewie decyzyjnym. Wzrost wartości współczynnika oznacza wzrost nierówności rozkładu. Zatem w rankingu należy wybrać klasę charakteryzującą się najniższym współczynnikiem Giniego.

Bugging

- Koncepcja **Bugging** polega na budowie ekspertów dla podzbioru zadań. W tym przypadku, ze wszystkich problemów do rozwiązania losowany jest ze zwracaniem podzbiór problemów a następnie dla tego podzbioru szukany jest ekspert.
- W algorytmie tym z całego zbioru danych uczących losowany jest podzbiór (losowanie ze zwracaniem) i dla tego podzbioru budowany jest model predykcyjny, następnie po raz kolejny ze zwracaniem losowany jest inny podzbiór wektorów i dla niego budowany jest kolejny model.
- Całość powtarzana jest k krotnie a na koniec wszystkie zbudowane modele użyte są do głosowania.
- Posiadanie B niezależnych zbiorów treningowych jest rzadko spotykanym luksusem. Z tego też powodu nazwa **bagging** rozwija się jako **bootstrap aggregating**. Czyli w celu uzyskania wielu prób uczących losujemy ze zwracaniem pseudopróby bootstrapowe z naszego jedynego zbioru treningowego.
- Za uogólnienie podejścia typu bagging możemy uznać losowe lasy: używają one zarówno bootstrapowych pseudoprób losowych do konstrukcji klasyfikatora, jak również losują pewien podzbiór cech, na podstawie którego klasyfikator jest budowany.

Boosting

- Metoda **boostingu** uznawana za kuzyna metody baggingu pozwala poradzić sobie w odwrotnej sytuacji: naszym celem jest agregacja wielu stabilnych, ale słabo wydolnych klasyfikatorów (ang. Weak learner).
- Zdolności klasyfikacyjne słabych uczniów są niewielkie – prawdopodobieństwo poprawnej klasyfikacji niewiele przekracza $1/2$.
- Główny pomysł polega na tym, żeby w procesie iteracyjnym obserwacjom przypisywać wagi, które sugerują słabym uczniom, na których przykładach powinni się skoncentrować w kolejnym podejściu do zadania klasyfikacji.
- Ostateczna decyzja o klasyfikacji obserwacji podejmowana jest przez głosowanie większościowe.
- Główną własnością boostingu jest umiejętność zmniejszenia błędu treningowego: grupa słabych uczniów działa razem jako mocny uczeń.
- Co ważniejsze błąd maleje wykładniczo szybko, co jest bardzo ważne w zastosowaniach praktycznych.
- Dodatkową zaletą jest fakt, że algorytmom boostingu nie grozi przeuczenie (ang. overfitting).