

Modelowanie predykcyjne - sieci neuronowe

Aneta Ptak-Chmielewska


Instytut Statystyki i Demografii

aptak@sgh.waw.pl

struktura wykładu

- Model sieci neuronowych – definicje
- Rodzaje i budowa neuronów
- Schemat modelu sieci neuronowych
- Funkcje matematyczne w neuronach
 - Funkcje łączące
 - Funkcje transformujące
- Domyślna architektura sieci
- Jednokierunkowa sieć wielowarstwowa MLP – MultiLayer Perception)
- MLP oraz Sieć z bezpośrednimi połączeniami
- MLP z dwiema warstwami ukrytymi
- Uczenie sieci neuronowej
- Algorytmy optymalizacyjne
- Zalety i wady sieci neuronowych
- Wnioski

Bodziec – reakcja (układ deterministyczny)



W XIX wieku sformułowano teorię opisującą podstawowe pojęcia dla funkcjonalnego opisu systemu nerwowego.

System nerwowy składa się z komórek nerwowych (neuronów), które komunikują się ze sobą poprzez przekazywanie sygnałów.

Komórki nerwowe są połączone ze sobą tworząc skomplikowaną sieć.

Każdy neuron jest pojedynczą komórką, która może odbierać sygnały elektrochemiczne, przetwarzać je i rozsyłać do innych komórek.

Pojemność ludzkiego mózgu szacuje się na 10^{11} neuronów.

Na jeden neuron przypada średnio kilka tysięcy połączeń.

Cztery tygodnie po zapłodnieniu embrión wytwarza pół miliona neuronów na minutę. W ciągu następnych tygodni te komórki przemieszczają się do mózgu i łączą między sobą (około 2 miliony połączeń na sekundę)

To daje około 10^{15} połączeń między neuronami.

Rodzaje neuronów

Neurony wstępujące (czuciowe) – odbierają bodźce od narządów zmysłów i przekazują informację do ośrodkowego układu nerwowego.

Neurony pośredniczące – zajmują się integracją (kojarzeniem) docierających informacji i podejmowaniem decyzji dotyczących sposobów reagowania.

Neurony zstępujące przekazują informację z systemu nerwowego do odpowiednich narządów zmysłu i gruczołów.

W 1949 roku Donald Hebb w pracy *The Organization of Behavior* zasugerował, że zachowanie się synaps może być modyfikowane przez uczenie.

Bodźce przychodzące ze świata zewnętrznego powodują wzrost aktywności neuronów, co wpływa na wzrost powiązań synaptycznych między pobudzanymi neuronami.

Uczenie powoduje, że niektóre synapsy są „wzmocnione”, a inne „uśpione”.

Powyższa idea stała się podstawą konstrukcji sztucznych sieci neuronowych.

W budowie sztucznych sieci neuronowych wykorzystuje się modele matematyczne neuronów, których działanie w pewnym uproszczeniu odpowiada działaniu neuronów biologicznych.

dendrytom biologicznych sieci neuronowych odpowiadają **wejścia**, które są połączone z wyjściami innych neuronów,

synapsom odpowiadają pewne liczby zwane **wagami połączeń**, które pełnią rolę parametrów wpływających na działanie neuronów.

Podobnie jak w systemie biologicznym wagi połączeń są zmieniane w zależności od otrzymywanej informacji. To zapewnia zdolność kojarzenia faktów czyli uczenia sieci.

Modele sieci neuronowych

Mimo wielu uproszczeń, sztuczne sieci neuronowe charakteryzują się cechami zarezerwowanymi dotychczas dla organizmów żywych.

- zdolność uczenia się, dzięki której sieć neuronowa potrafi nauczyć się prawidłowych reakcji na określone bodźce,
- umiejętność abstrakcji tj. zdolność uogólniania zdobytej wiedzy,
- odporność na uszkodzenia, gdyż sieć neuronowa potrafi działać poprawnie nawet gdy część jej elementów jest uszkodzona.
- Odporność na zaszumione i niedokładne dane wejściowe.

Modele sieci neuronowych stosuje się, gdy:

- nie znamy formuły matematycznej wiążącej zmienną zależną ze zmiennymi objaśniającymi (zależność ta jest nieliniowa),
- predykcja jest ważniejsza niż wyjaśnianie zależności między zmiennymi,
- mamy dużo obserwacji, dla których znamy wartości zmiennej objaśnianej i zmiennych objaśniających.

Model sieci neuronowych – definicje


- Modele sieci neuronowych wykorzystują funkcje matematyczne do mapowania danych wejściowych (zmiennych) na dane wynikowe.
- W przypadku zmiennej zależnej binarnej wynikiem z modelu są prawdopodob. zdarzenia „1” i „0”. Dla zmiennej zależnej dyskretnej z większą liczbą kategorii wynikiem modelu będą prawdopodob. wystąpienia poszczególnych kategorii jakie przyjmuje zmienna. Dla zmiennej ciągłej będzie to wartość oczekiwana.
- Model sieci neuronowych może być rozumiany jako złożony model nieliniowy w którym transformacja zmiennych, tworzenie zmiennych złożonych i estymacja modelu (oszacowanie wag) wykonywane są jednocześnie przy zachowaniu minimalizacji określonej funkcji błędu.
- Model sieci neuronowych składa się z warstw a każdą warstwę tworzą jednostki zwane neuronami. Każda jednostka wykorzystuje dane wejściowe z poprzedniej warstwy i wyznacza dane wynikowe, które są podstawą (danymi wejściowymi) do kolejnej warstwy.
- Warstwa pierwsza jest warstwą wejściową, a końcowa warstwą wynikową (target), pomiędzy nimi mogą być warstwy pośrednie tzw. ukryte, tworzące kalkulacje pośrednie za pomocą funkcji warstw ukrytych (łączących-‘combination function’ i transformujących-‘activation function’).
- Funkcje dla warstwy wynikowej nie mogą być przypadkowe, muszą być powiązane z celem modelowania, np. dla zmiennej binarnej będzie to transformacja logistyczna, powodująca że wynikiem końcowym będą prawdopodob. wystąpienia ‘0’ i ‘1’.

Kilka możliwych zastosowań sieci neuronowych

rozpoznawanie i generowanie mowy,
przewidywanie wskaźników finansowych,
optymalizacja procesów chemicznych,
rozpoznawanie obiektów i wykrywanie złóż,
identyfikacja komórek nowotworowych,
wykrywanie anomalii w chromosomach,
określanie ryzyka przedsięwzięć,
automatyczne rozpoznawanie ręcznego pisma,
rozwiązywanie problemów optymalizacyjnych,
takich jak problem komiwojażera,
usuwanie szumów w analizie szeregów
czasowych.
przewidywanie kursów walut,
prognozy giełdowe,
ocena ryzyka inwestycji,
ocena reakcji rynku,
selekcja policjantów z uwagi na skłonność do
nieetycznego zachowania,


powoływanie przysięgłych,
przewidywanie napraw drogowych,
diagnozy lekarskie,
przewidywanie wyników wyścigów konnych,
przewidywanie wybuchów na Słońcu
prognoza pogody,
sprawdzanie jakości produktów
synteza mowy,
rozpoznawanie mowy,
rozpoznawanie pisma,
sprawdzanie podpisu,
automatyczne sterowanie,
wybór składników karmy dla kurcząt,
poszukiwanie złota,
badanie zanieczyszczeń powietrza.

Opis zależności między zmiennymi




Po wprowadzeniu na wejściu wartości zmiennych objaśniających sieć powinna przewidywać wartość zmiennej objaśnianej

Klasyfikacja wzorcowa obiektów




Po wprowadzeniu na wejściu informacji o klasyfikowanym obiekcie sieć powinna określić, do której klasy należy obiekt

Badanie struktury obiektów



Po wprowadzeniu na wejściu informacji o klasyfikowanym obiekcie sieć powinna podać szereg informacji o jego strukturze. To pozwala podzielić obiekty na jednorodne grupy

Analiza szeregów czasowych




Po wprowadzeniu na wejściu informacji pochodzących z okresu bieżącego i okresów wcześniejszych sieć powinna przewidywać wartość zmiennej objaśnianej w przyszłości

warstwa wejściowa

ukryta warstwa 1

ukryta warstwa 2

warstwa wynikowa



Schemat modelu sieci neuronowych z 2 warstwami ukrytymi

W jaki sposób neuron przetwarza informację przychodzącą do niego?

Pobudzenie neuronu p jest liniową funkcją sygnałów wejściowych z wagami połączeń jako współczynnikami (*combination function*)

$$p = w_1x_1 + w_2x_2 + \dots + w_nx_n = \sum_{i=1}^n w_i x_i$$

Sygnał wyjściowy y jest zależny od całkowitego pobudzenia neuronu, transformowanego przez **funkcję aktywacji** f . Pozwala to wprowadzić nieliniowość.

$$y = f(p) = f\left(\sum_{i=1}^n w_i x_i\right)$$

Funkcje matematyczne w neuronach

- Funkcje łączące (combination function) – tworzące wejściowe przekształcenie do każdego neuronu. Przekształceniem domyślnym jest kombinacja liniowa.

$$\eta_j = w_{01j} + \sum_{i=1}^p w_{i1j} x_i$$

- Funkcje transformujące (activation function) – tworzące przekształcenie wyjściowe z każdego neuronu. Przekształceniem domyślnym dla zmiennej zależnej binarnej jest przekształcenie logistyczne.

$$P(y = 1) = \frac{1}{1 + \exp[-(w_0 + w_1 H_1 + w_2 H_2 + w_3 H_3)]}$$

- Architektura sieci tworzy kombinacja funkcji łączących i transformujących. Architektura może być domyślna lub określona przez użytkownika.

Funkcje łączące

Dostępne typy funkcji łączących:

- ADD $\eta_j = \sum_{i=1}^p x_i$ dla wartości wystandaryzowanych
- LINEAR $\eta_j = w_{01j} + \sum_{i=1}^p w_{i1j} x_i$ gdzie w są wagami, różnymi dla każdego neuronu w warstwie
- EQSLOPES $\eta_j = w_{01j} + \sum_{i=1}^p w_{i1} x_i$ gdzie w są wagami ale takimi samymi dla każdego neuronu w warstwie
- EQRADIAL $\eta_j = -b^2 \sum_{i=1}^p (w_{ij} - x_i)^2$ b nie różni się w poszczególnych neuronach
- EHRADIAL $\eta_j = -b_j^2 \sum_{i=1}^p (w_{ij} - x_i)^2$ b może różnić się
- EWRADIAL $\eta_j = f \log(\text{abs}(a_j)) - b^2 \sum_{i=1}^p (w_{ij} - x_i)^2$ f to liczba połączeń do neuronu
- EVRADIAL $\eta_j = f \log(\text{abs}(b_j)) - b_j^2 \sum_{i=1}^p (w_{ij} - x_i)^2$
- XRADIAL $\eta_j = f \log(\text{abs}(a_j)) - b_j^2 \sum_{i=1}^p (w_{ij} - x_i)^2$

Funkcje transformujące - aktywacji


Dostępne typy funkcji transformujących:

- Arc Tan $H_j = (2/\pi)\tan^{-1}(\eta_j)$
- Elliot $H_j = \frac{\eta_j}{1+|\eta_j|}$
- Hyperbolic Tangent $H_j = \tanh(\eta_j)$
- Logistic $H_j = \frac{1}{1+\exp(-\eta_j)}$
- Gauss $H_j = \exp(-0,5 \cdot \eta_j^2)$
- Cosine $H_j = \cos(\eta_j)$
- Sine $H_j = \sin(\eta_j)$
- Exponential $H_j = \exp(\eta_j)$
- Square $H_j = \eta_j^2$
- Reciprocal $H_j = \frac{1}{\eta_j}$
- Softmax $H_j = \frac{\exp(\eta_j)}{\sum_{k=1}^3 \exp(\eta_k)}$

Funkcja aktywacji progowa

$$f(p) = \begin{cases} 1, & \text{gdy } p > 0 \\ 0, & \text{gdy } p \leq 0 \end{cases}$$


Odpowiada to przekazaniu otrzymanego sygnału (gdy $f = 1$) lub nie (gdy $f = 0$)



Funkcja aktywacji liniowo-progowa

Zakres zmian wartości funkcji jest ograniczony przez wartości progowe α i β (przyjmujemy $\alpha < \beta$). Sygnały mniejsze lub większe od wartości progowych nie powodują żadnych dalszych zmian wartości funkcji, natomiast między wartościami progowymi funkcja aktywacji zmienia się w sposób liniowy.


$$f(p) = \begin{cases} 1, & \text{gdy } p > \beta \\ \frac{p - \alpha}{\beta - \alpha}, & \text{gdy } \alpha \leq p \leq \beta \\ 0, & \text{gdy } p < \alpha \end{cases}$$



Funkcja logistyczna

$$f(p) = \frac{1}{1 + \exp(-\beta \cdot p)}$$


Przyjmuje wartości z przedziału otwartego $(0; 1)$, gdzie parametr β decyduje o kształcie funkcji w pobliżu zera.



Funkcja tangens hiperboliczny

$$f(p) = \tanh p = \frac{\exp(p) - \exp(-p)}{\exp(p) + \exp(-p)}$$

Przyjmuje wartości z przedziału $[-1; 1]$



Inne funkcje aktywacji

W programie SAS Enterprise Miner używane są jeszcze inne funkcje aktywacji, m. in.

- identyczność - $f(p) = p$,
- wykładnicza - $f(p) = \exp(p)$
- softmax - będąca uogólnieniem funkcji logistycznej,
- Gauss - $f(p) = \exp(-p^2)$,
- odwrotność (reciprocal) - $f(p) = 1/p$,
- Elliot - $f(p) = p/(1+|p|)$

Domyślne funkcje aktywacji dla warstwy wyjściowej

W programie Enterprise Miner domyślne funkcje aktywacji dla warstwy wyjściowej zależą od skali pomiaru zmiennej objaśnianej (*target*).

Skala pomiaru	Funkcja aktywacji
Interval	identyczność
Ordinal	logistyczna
Nominal	softmax


Domyślna architektura Sieci

Podstawowe typy architektury ustawione domyślnie:

	Funkcja łącząca	Funkcja transformująca
MLP (multilayer perception)	LINEAR	Tanh Arctanh Logistic Elliot (sigmoid S-shape)
ORBFEQ (Ordinary Radial Basis Function with Equal Widths)	EQRADIAL	Exponential
ORBFUN (Ordinary Radial Basis Function with Unequal Widths)	EHRADIAL	Exponential
ORBFEW (Ordinary Radial Basis Function with Equal Widths and Unequal Heights)	EWRADIAL	Exponential
NRBFEQ (Normalized Radial Basis Function with Equal Widths and Heights)	EQRADIAL	Softmax
NRBFEH (Normalized Radial Basis Function with Equal Heights and Unequal Widths)	EHRADIAL	Softmax
NRBFEW (Normalized Radial Basis Function with Equal Widths and Unequal Heights)	EWRADIAL	Softmax
NRBFEV (Normalized Radial Basis Function with Equal Volumes)	EVRADIAL	Softmax
NRBFUN (Normalized Radial Basis Function with Unequal Widths and Heights).	XRADIAL	Softmax

MLP

- Najpopularniejszą architekturą wśród sieci neuronowych jest perceptron wielowarstwowy (MLP – Multi Layer Perceptron)
- MLP składa się z trzech rodzajów warstw:
 - Wejściowej - zawierającej jeden neuron dla każdej zmiennej objaśniającej
 - Ukrytej - przekształcającej ważoną kombinację liniową wejść określoną funkcją gładką
 - Wyjściowej - zbierającej i łączącej wyniki z warstwy ukrytej w celu otrzymania ostatecznej predykcji



MLP oraz Sieć z bezpośrednimi połączeniami

$$E(y) = g\left(w_0 + \sum_{i=1}^n w_i g_i\left(w_{oi} + \sum_{j=1}^m w_{ji} x_j\right)\right)$$

MLP – każdy neuron w warstwie ukrytej otrzymuje sygnał będący liniową kombinacją wartości zmiennych objaśniających. Następnie wartości te są przekształcane przy użyciu funkcji aktywacji i wysyłane z odpowiednimi wagami do warstwy wyjściowej. Tam po raz kolejny są sumowane i ostatecznie przekształcane funkcją g .

$$E(y) = g\left(w_0 + \sum_{i=1}^n w_i g_i\left(w_{oi} + \sum_{j=1}^m w_{ji} x_j\right) + \sum_{k=1}^m d_k x_k\right)$$

Sieć z bezpośrednimi połączeniami – jest rozszerzeniem poprzedniego przypadku o zwykłą liniową kombinację zmiennych wejściowych. Większe możliwości tej sieci wiążą się z m nowymi parametrami do wyestymowania ($d_1, \dots, d_m$).

MLP z dwiema warstwami ukrytymi

$$E(y) = g \left(w_0 + \sum_{i=1}^k w_i g_{2i} (w_{20i} + \sum_{j=1}^n w_{1ji} g_{1i} (w_{10j} + \sum_{h=1}^m w_{hj} x_j)) \right)$$

- Dodanie kolejnej warstwy wprowadza zestaw kolejnych $n \cdot k$ parametrów do wyestymowania. Złożoność sieci wzrasta do stopnia, który umożliwia modelowanie zależności nieciągłych.
- W teorii sieć MLP z jedną warstwą ukrytą może modelować dowolną zależność ciągłą. Sieć z dwiema warstwami może modelować zależności dyskretne
- Liczba neuronów, które powinny być umieszczone w warstwie ukrytej, jest zagadnieniem bez jednoznacznej odpowiedzi.
- Jedną z doświadczalnie wypróbowanych zasad jest umieszczenie $\sim 2 \cdot k$ (k -liczba zmiennych objaśniających) neuronów w pierwszej warstwie ukrytej.
- Metodą prób i błędów można badać zależności złożoności architektury sieci od jej skuteczności.

Radialne funkcje bazowe (RBF)

Alternatywą dla standardowych funkcji aktywacji są radialne funkcje bazowe (Radial Basis Functions):

- ORBF (Ordinary RBF) – używają wykładniczych funkcji aktywacji, tworząc zbiór dzwonów Gaussa w wyestymowanych lokalizacjach
- NRBF (Normalized RBF) – tworzą wyjście z danego neuronu w oparciu o unormalizowaną kombinację dzwonów Gaussa

Zwykła sieć ORBF przypomina standardowy model MLP, przy czym zamiast sigmoidalnych funkcji aktywacji mamy do czynienia z dzwonami Gaussa scentrowanymi w punktach z próbki. Ponieważ takie funkcje są radialnie symetryczne, zaleca się standaryzację danych przed budową sieci tak, aby każdy z wymiarów charakteryzował się tą samą wariancją.

Zastosowanie funkcji ORBF może spowodować powstanie modelu, w którym zbiór powstałych uwypukleń będzie miał zbyt lokalny charakter, przez co powstała funkcja nie będzie wystarczająco wygładzona. Jednym z rozwiązań tego problemu jest zastosowanie normalizowanych funkcji RBF (NRBF)

W sieci NRBF problem lokalności ominięty jest przez nałożenie ograniczenia mówiącego, że wyjścia z poszczególnych neuronów warstwy ukrytej muszą się sumować do 1.

Jednym z rozwiązań tego problemu jest zastosowanie normalizowanych funkcji RBF (NRBF)


Funkcje ORBF

XRADIAL – najbardziej elastyczny wariant radialnych funkcji bazowych, charakteryzujący się największą ilością parametrów do estymacji. Jeśli dysponujemy k zmiennymi oraz h neuronami w warstwie ukrytej, konieczna jest estymacja $h(k+3)$ parametrów.

EQRADIAL – najmniej elastyczny wariant, wymagający jednak estymacji najmniejszej ilości parametrów ($h(k+1)+1$).

EWRADIAL – równe szerokości dzwonów – $h(k+2)+1$ parametrów do wyestymowania

EHRADIAL – równe wysokości dzwonów – $h(k+2)$ parametrów



Uczenie sieci neuronowej

- *uczenie sieci* polega na modyfikacji wartości wag wszystkich połączeń między neuronami w ten sposób, że sieć przyjmuje pożądane wartości wyjściowe dla określonych danych wejściowych,
- o działaniu sieci decyduje struktura połączeń neuronów i wartości wag tych połączeń,
- proces uczenia polega na kolejnych modyfikacjach wag. Wynika z niego też modyfikacja topologii sieci, ponieważ sieć z zerowymi wagami między dwoma neuronami oznacza brak połączenia, a neuron z wejściowymi i wyjściowymi wagami równymi zero oznacza neuron zbędny, który może być usunięty ze struktury sieci.

Przebieg procesu uczenia sieci jest następujący:

- najpierw nadaje się wszystkim wagom wartości początkowe (w sposób z góry ustalony lub losowy), ale tak aby nie faworyzować żadnego połączenia,
- następnie sieć wykonuje postawione zadanie i na podstawie otrzymanego wyniku wartości wag są zmieniane.

W zależności od rodzaju informacji o ocenie zadania wykonanego przez sieć wyróżniamy:

- *uczenie pod nadzorem* (z nauczycielem), gdzie dostarczana jest informacja o poprawnych odpowiedziach,
- *uczenie ze wzmocnieniem* gdzie nie podaje się poprawnej odpowiedzi, lecz jedynie ocenę wyniku, np. "dobrze" lub "źle,,; ten tryb uczenia naśladuje ludzki proces uczenia się,
- *uczenie bez nadzoru* (bez nauczyciela), w którym nauczyciel nie bierze udziału w nauczaniu, a sieć sama wykrywa wzajemne zależności w danych wejściowych.

Skuteczność uczenia zależy od wyboru wzorców ze względu na ich reprezentatywność.

Uczenie nadzorowane

- sieć neuronowa analizuje ciąg dostarczanych na wejściu przykładów (zwanymi faktami) i jednocześnie otrzymuje informację, jaki jest poprawny wynik dla każdego przykładu,
- sieć stara się odgadnąć powiązania między danymi wejściowymi a znanym wynikiem,
- na podstawie odstępstw wyników sieci od znanych wartości na wyjściu dokonywana jest korekta wag w ten sposób, aby zredukować różnice do możliwie małych wartości.

Modyfikacja wag

Modyfikacja wag połączeń jest przeprowadzana iteracyjnie zgodnie z zależnością:

Zmienianie wartości wag jest zatrzymywane, jeżeli działanie sieci uznamy za właściwe lub przekroczona zostanie z góry założona maksymalna liczba iteracji ($tmax$).

$$w^{t+1} = w^t + \Delta w^t$$

w^{t+1} - nowa waga (w $t+1$ iteracji)

w^t - dotychczasowa waga (w t -tej iteracji)

Δw^t - wartość, o jaką należy zmienić wagę w danej chwili uczenia

Reguła delta

Jeżeli oznaczymy symbolem d - wartość wymaganej odpowiedzi neuronu, a symbolem y - wartość sygnału wyjściowego neuronu, to możemy obliczyć błąd odpowiedzi

Na podstawie obliczonego błędu jest wyznaczana wartość

gdzie

$$\delta^* = d - y$$

$$\Delta w = \eta \cdot \delta \cdot p$$

η jest współczynnikiem uczenia,

$$\delta = \delta^* \cdot f'(p)$$

f' jest pochodną funkcji aktywacji.

Współczynnik uczenia η

Określa szybkość, z jaką następuje modyfikowanie wartości wag.

- jeżeli wartość współczynnika uczenia jest zbyt duża, to zmiany wag będą zwiększać błąd w następnych iteracjach i uczenie nie będzie możliwe (sieć będzie zbyt intensywnie reagować na kolejne bodźce wejściowe),
- jeżeli wartość będzie zbyt mała, to uczenie będzie przebiegać powoli,
- współczynnik uczenia jest wspólny dla wszystkich wag,
- w trakcie procesu uczenia wartości współczynnika są zmieniane.

Algorytm propagacji wstecznej

Celem algorytmu jest zmniejszenie błędu odpowiedzi sieci nie tylko dla jednego wzorca, ale dla wszystkich wzorców wejściowych.

$$Q = \frac{1}{2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Oblicza się błąd **Q**, zwany *błędem średniokwadratowym* (SSE - Sum Squared Error)

y_i wartości oczekiwane na wyjściu neuronu

$\hat{y}_i$ wartości wyznaczone z sieci

n liczba wzorców

Algorytm propagacji wstecznej

Propagacja wsteczna polega na obliczaniu gradientu błędu dla neuronów wcześniejszych warstw. Najpierw koryguje się wagi prowadzące do warstwy wyjściowej, potem wagi prowadzące do warstwy poprzedzającej ją, aż osiągniemy pierwszą warstwę. Pozwala to na wyznaczenie wartości wszystkich wag połączeń.

Możliwe są dwie wersje algorytmu:

- wczytaj cały zbiór danych, modyfikuj wagi, wczytaj cały zbiór danych, modyfikuj wagi itd.,
 - wczytaj jedną obserwację, modyfikuj wagi, wczytaj jedną obserwację, modyfikuj wagi itd..
- Pierwsza z tych metod jest mniej zalecana, gdyż jest powolna i nieefektywna.

Ocena błędu dla zmiennej binarnej i ciągłej

1. Kryterium maksymalnej wiarygodności (Kryterium wiarygodności sumuje logarytmy prawdopodobieństw „1” dla punktów będących rzeczywiście „1” oraz logarytmy prawdopodobieństw „0” dla punktów będących rzeczywiście „0”.)

– najbardziej powszechne w przypadku **binarnej zmiennej objaśnianej**:

$$\sum_{i=1}^n (y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)) = \sum_{i|y=1}^{n_1} \ln(p_i) + \sum_{i|y=0}^{n_0} \ln(1 - p_i)$$

2. Miary błędu w przypadku **zmiennej objaśnianej ciągłej**.

W zależności od rozkładu zmiennej objaśnianej stosuje się różne miary błędu, które pozwalają na wiarygodną ocenę jakości dopasowania modelu. Dla rozkładów silnie odbiegających od normalnego konieczna jest modyfikacja standardowego kryterium SSE (suma kwadratów odchyleń).

<u>Rozkład zmiennej</u>	<u>Miara błędu</u>
NORMALNY	$E = (y - f(w))^2$
POISSON	$E = 2[\ln(y/f(w)) - (y - f(w))]$
GAMMA	$E = 2[\ln(y/f(w)) - (y/f(w)) + 1]$

Algorytmy optymalizacyjne

Wspólną cechą algorytmów optymalizacyjnych używanych do znajdowania optymalnych wag w sieciach jest iteracyjny charakter działania:

Za każdym razem, kiedy kolejna obserwacja przechodzi przez sieć, sprawdzana jest bieżąca wartość kryterium błędu i uruchamiane jest poszukiwanie minimum tego kryterium w funkcji wag sieci. Istnieje szereg różnych algorytmów optymalizacyjnych przeznaczonych do problemów o różnych rozmiarach. Wybrane metody to: Quasi-Newton, Levenberg-Marquardt, algorytm sprzężonych gradientów.

Uczenie sieci może być przerywane, gdy:

- wartość funkcji błędu stabilizuje się lub zaczyna wzrastać
- wartości wyestymowanych wag nie zmieniają się
- osiągnięto maksymalną zamierzoną liczbę iteracji lub czas uczenia

Sieci neuronowe – zalety i wady

Zalety:

- Dopasowują się do dowolnie złożonych zależności nieliniowych
- Dzięki różnym funkcjom aktywacji mogą modelować zmienną o dowolnej skali pomiarowej
- Gotowa zależność umożliwia szybki scoring nowych danych

Wady:

- Nieodporne na braki danych i często na obserwacje odstające
- Długi czas uczenia
- Trudne w interpretacji!

Główną wadą sieci neuronowych jest bardzo trudna interpretacja znalezionej zależności (choć możliwa jest wspomniana już aproksymacja sieci drzewami decyzyjnymi lub regresyjnymi). Nawet jednak jeśli wymagania biznesowe uniemożliwiają zastosowanie sieci, warto użyć ich chociażby jako punktu odniesienia dla oceny innych metod.

Wnioski

- sieć neuronowa nie wyjaśnia, jaka jest zależność funkcyjną między zmiennymi objaśniającymi (wejściowymi) a zmienną wynikową.
- pozwala jednak dokonywać predykcji albo zidentyfikować przynależność obiektu do danej klasy.
- nie jest wymagane spełnienie założeń o naturze rozkładu zmiennych, jak to jest w przypadku stosowania modeli ekonometrycznych, np. metod regresji liniowej lub logistycznej.