

Rozpoznawanie wzorców

Analiza koszykowa

Aneta Ptak-Chmielewska

Instytut Statystyki i Demografii

aptak@sgh.waw.pl

struktura wykładu

- Wielowymiarowe metody segmentacji
- Analiza skupień:
 - Cele analizy skupień
 - Odwzorowanie obiektów w przestrzeni n – wymiarowej
 - Normalizacja
 - Metryka przestrzeni
 - Metody grupowania
 - Ustalanie liczby skupień w metodzie k-średnich
 - CCC Cubic Clustering Criterion
 - Segmentacja zbiorów eliptycznych
- Metoda SOM/Kohonena
- Analiza asocjacji
 - Reguły asocjacyjne – oznaczenia
 - Przykład
 - Format danych
 - Charakterystyki reguł asocjacyjnych
 - Algorytm apriori
- Analiza sekwencji

Wielowymiarowe metody segmentacji


- **Segmentacja ze zmienną wynikową (klasyfikacja)**
 - Analiza dyskryminacji
 - Regresja logistyczna
 - Drzewa klasyfikacyjne
 - Sieci neuronowe z nauczycielem
- **Segmentacja bez zmiennej wynikowej (grupowanie)**
 - Analiza skupień
 - Sieci neuronowe bez nauczyciela
- **Analiza skupień**
 - jest techniką wielowymiarową pozwalającą wykrywać współzależności między obiektami,
 - związana jest ściśle z zagadnieniami klasyfikowania i porządkowania otaczającej nas rzeczywistości

Cele analizy skupień





- **Eksploracja danych**
 - Kontrola danych
 - Poszukiwanie obiektów nietypowych (odstających)
 - Wykrycie wewnętrznej struktury obiektów
 - Wykrywanie współzależności między zmiennymi
- Typologia
 - Weryfikacja istniejącej typologii
 - Propozycje klasyfikacji obiektów
- Redukcja danych
 - Agregacja danych
 - Wybór reprezentantów grup

Odwzorowanie obiektów w przestrzeni n - wymiarowej

- Obiekt opisany za pomocą n zmiennych $X_1, X_2, \dots, X_n$ przedstawiamy jako punkt $x=(x_1, \dots, x_n)$ w przestrzeni n -wymiarowej
- Celem podziału na grupy jest, aby obiekty podobne (reprezentowane przez punkty znajdujące się blisko siebie w przestrzeni) znalazły się w tej samej grupie, a obiekty niepodobne (reprezentowane przez punkty leżące w dużej odległości w przestrzeni) znalazły się w różnych grupach
- np. podział na 5 skupień:
- Problemy do rozstrzygnięcia:
 - Jak odwzorować obiekty w przestrzeni?
 - Jakie zmienne wybrać?
 - Jak normalizować zmienne ilościowe?
 - Jak mierzyć odległości między obiektami?
 - Jaką metodę grupowania zastosować?
 - Ile grup spodziewamy się odkryć?



Możliwe rozkłady obiektów



Normalizacja

- Normalizacja ma na celu doprowadzenie obiektów lub zmiennych do porównywalnych wielkości. Problem ten dotyczy zmiennych mierzonych w różnych jednostkach (np. sztuki, czas, waluta).

Przykład

- Rozważmy 3 obiekty i dwie zmienne: wiek osoby mierzony w latach i jej dochód mierzony w złotych lub tys. zł.

Zmienna ->	X	Y1	Y2
	Wiek	Dochód	Dochód
Osoba	(w latach)	(w zł)	(w tys. zł)
A	35	12000	12,0
B	37	6700	6,7
C	45	7000	7,0

- **Przekształcenia liniowe zmiennych**
$$f(x) = \frac{x - A}{B} \quad B \neq 0$$
- Współczynnik A nie wpływa na odległości między obiektami
- Współczynnik B pełni rolę czynnika skalującego.
- Szczególnie ważnym rodzajem przekształcenia jest:
- **standaryzacja** $A = \bar{x} \quad B = s_x$
- **normalizacja** $A = \min(X) \quad B = \max(X) - \min(X)$

Metryka przestrzeni

- Odległość euklidesowa

$$d(O_1, O_2) = \sqrt{\sum_{i=1}^m (x_{1j} - x_{2j})^2}$$

- Odległość Minkowskiego
Jej szczególnymi przypadkami są:

$$d(O_1, O_2) = \left(\sum_{j=1}^m |x_{1j} - x_{2j}|^p \right)^{1/p}$$

- odległość miejska (p=1)
- odległość euklidesowa (p=2)
- odległość Czebyszewa (p=∞)

$$d(O_1, O_2) = \max_{j=1, \dots, m} |x_{1j} - x_{2j}|$$



- ponadto kwadrat odległości euklidesowej

$$d(O_1, O_2) = \sum_{i=1}^m (x_{1j} - x_{2j})^2$$

Metody grupowania

- **Hierarchiczne**
tworzą drzewa binarne
- **Optymalizacyjno-iteracyjne**
poprawiają wstępny podział w kolejnych iteracjach na podstawie danej funkcji kryterium
- **Obszarowe**
wykrywają obszary o dużej gęstości
- **Pozostałe**
np. tworzą skupienia nierozłączne, niezupełne, rozmyte


Metody hierarchiczne




Metody aglomeracyjne

1. Najbliższego sąsiedztwa (*Single linkage, Nearest neighbor*)
2. Najdalszego sąsiedztwa (*Complete linkage, Furthest neighbor*)
3. Mediany (*Median clustering*)
4. Środka ciężkości (*Centroid clustering*)
5. Średniej odległości wewnątrz skupień (*Average linkage within groups*)
6. Średniej odległości między skupieniami (*Average linkage between groups*)
7. Minimalnej wariancji Warda (*Ward's method*)


Porównanie sposobu wyznaczania odległości między skupieniami w wybranych metodach aglomeracyjnych




metoda najbliższego sąsiedztwa




metoda najdalszego sąsiedztwa




metoda mediany



metoda środka ciężkości



metoda średniej grupowej



metoda Warda

Metody optymalizacyjno-iteracyjne (k -średnich)

1. Ustalamy liczbę grup (k)
2. Wybieramy (w sposób losowy lub ustalony z góry) k punktów przestrzeni, stanowiących tzw. załączki środków ciężkości skupień (*cluster seeds*)
3. Każdy z obiektów ($i=1,\dots,n$) przydzielamy do grupy o najbliższym dla niego środku ciężkości
4. Dla ($j=1,\dots,k$) obliczamy nowe środki ciężkości jako średnie arytmetyczne wszystkich obiektów należących do danej grupy
5. Powtarzamy kroki 3 i 4 aż do chwili, gdy nie następują przesunięcia obiektów między grupami
6. Jednocześnie obliczana jest funkcja błędu podziału - ogólna suma kwadratów odległości wewnątrzgrupowych liczonych od środków ciężkości grup, tzn.

$$F = \sum_{j=1}^k \sum_{O_i \in S_j} d(O_i, M_j)^2$$

gdzie d jest odległością euklidesową.

W praktyce proces jest zbieżny po kilku lub kilkunastu iteracjach. Ponieważ w ogólności algorytm nie musi być zbieżny, ustala się maksymalną liczbę iteracji (L).

Metoda k -średnich - przykład

Iteracja 1

Ustalamy załóżki środków ciężkości skupień. Arbitralnie (lub losowo) wybieramy dwa elementy – punkty (1; 1) i (2; 1). Pozostałe elementy przyporządkowujemy do najbliższych środków ciężkości skupień.




Iteracja 2

Skupienie 1 ma 3 elementy. Skupienie 2 ma 5 elementów. Wyznaczono środki ciężkości skupień. Jeden obiekt leży bliżej środka ciężkości innego skupienia

Iteracja 3

Obiekt przeszedł ze skupienia 2 do skupienia 1. Teraz oba skupienia mają po 4 elementy. Wyznaczono nowe środki ciężkości skupień. Wszystkie punkty leżą najbliżej środków ciężkości swoich skupień. Algorytm kończy się

Mamy 8 elementów, które chcemy podzielić na $k=2$ skupienia



Ustalanie liczby skupień w metodzie k-średnich

Liczbę skupień wybiera się na podstawie przesłanek merytorycznych albo szacuje się je metodami hierarchicznymi. Można dokonać obliczeń dla wszystkich wartości k z ustalonego przedziału:

$$k_{\min} \leq k \leq k_{\max}$$

Możliwe są różne podejścia:

1. Arbitralny sposób np. przyjmuje się współrzędne pierwszych k obiektów (nie zawierające braków danych) jako załączki środków ciężkości .
2. Losowy wybór środków ciężkości, przy czym może to być losowy wybór k obiektów ze zbioru danych albo losowy wybór k punktów przestrzeni niekoniecznie pokrywających się z położeniem obiektów.
3. Wykorzystanie algorytmu optymalizującego w pewien sposób położenie początkowych środków ciężkości np. przez uwzględnianie k obiektów leżących daleko względem siebie.
4. Przyjęcie jako początkowych środków ciężkości uzyskanych na podstawie podziału otrzymanego inną metodą, głównie jedną z metod hierarchicznych.

CCC Cubic Clustering Criterion

CCC jest jedną z metod szacowania liczby skupień w algorytmach analizy skupień. opartych na minimalizacji wewnątrzgrupowej sumy kwadratów (*within-cluster sum of squares*). Do takich metod należy metoda minimalnej wariancji Warda (*Ward's method*) i metoda k -średnich (k -means)

Idea metody polega na porównaniu obserwowanej wartości współczynnika R^2 z aproksymacją wartości oczekiwanej $E[R^2]$ dla próby wylosowanej z rozkładu jednostajnego. Wzór obliczeniowy został skorygowany o empirycznie wyznaczony mnożnik zapewniający stabilizację wariancji

Dodatkowo wartości współczynnika CCC oznaczają, że obserwowana wartość R^2 jest większa niż należało oczekiwać, gdyby obiekty zostały wylosowane z rozkładu jednostajnego, zatem prawdopodobnie zbiór badanych obiektów można podzielić na różniące się od siebie skupienia

Badając zależność wartości CCC od liczby skupień uzyskanych w zastosowanej metodzie grupowania można oszacować optymalną liczbę skupień, na które da się podzielić zbiór obiektów.

Metoda CCC została opracowana przez SAS Institute

CCC Cubic Clustering Criterion

Metoda CCC jest oparta na porównaniu wartości oczekiwanej współczynnika R^2 tj. $E[R^2]$, gdy spełniona jest hipoteza zerowa, że dane pochodzą z rozkładu jednostajnego, z zaobserwowaną w próbie wartością R^2 .

K jest pewnym współczynnikiem stabilizującym wariancję, wyznaczonym empirycznie za pomocą symulacji Monte Carlo (brane były pod uwagę różne liczby obserwacji n , zmiennych p i skupień q).

H_0 (hipoteza zerowa) - obiekty zostały wylosowane z tego samego rozkładu jednostajnego na hiperprostokątście;

H_a (hipoteza alternatywna) - obiekty zostały wylosowane z różnych sferycznych rozkładów normalnych o jednakowej wariancji, przy czym prawdopodobieństwa wyboru obiektu z poszczególnych rozkładów były takie same.

$$CCC = \ln \left(\frac{1 - E(R^2)}{1 - R^2} \right) \cdot K \quad K = \frac{\sqrt{\frac{np^*}{2}}}{(0,001 + E(R^2))^{1,2}}$$

p^* jest tu największą liczbą całkowitą mniejszą niż liczba skupień

CCC Cubic Clustering Criterion

Uwagi o interpretowaniu wartości CCC

- Zmienne użyte w analizie skupień nie powinny być silnie skorelowane ze sobą. Jeżeli występują silne korelacje, to należy zredukować liczbę zmiennych lub użyć analizy czynnikowej w celu zastąpienia zmiennych przez pewną liczbę ortogonalnych składowych (innych zmiennych).
- Liczba poszukiwanych skupień nie powinna być duża w porównaniu z liczbą obiektów, tak aby skupienia nie zawierały zbyt małej liczby obiektów. Ponadto, jeżeli w zbiorze danych są obiekty nietypowe (*outliers*), to należy je wyeliminować z analizy. O istnieniu obiektów nietypowych mogą świadczyć bardzo niskie wartości CCC.
- Warto oglądać wartości CCC na wykresie, jako funkcję zależną od liczby skupień. Należy wybierać liczbę skupień, dla której CCC ma maksimum globalne lub lokalne maksima, najlepiej o wartości większej niż 2 lub 3 (dodatnie wartości w przedziale od 0 do 2 należy traktować ostrożnie).
- Występowanie wielu maksimów lokalnych może świadczyć, że obiekty mają strukturę hierarchiczną. Można wtedy wybrać liczbę skupień odpowiadającą jednemu z maksimów biorąc również pod uwagę inne względy merytoryczne związane z celem grupowania.
- Jeżeli wszystkie wartości CCC są ujemne albo CCC maleje wraz ze wzrostem liczby skupień, to prawdopodobnie mamy do czynienia z rozkładem jednomodalnym lub bardzo spłaszczonym na brzegach.
- Jeżeli wartości CCC systematycznie rosną wraz ze wzrostem liczby skupień, to prawdopodobnie rozkłady nie są sferyczne (występują łańcuchy).
- CCC nie jest odpowiednim kryterium jeżeli skupienia znacznie odbiegają od sferycznych (są podłużne, nieregularne). Wówczas zaleca się użyć metody Wonga lub Lane'a, zamiast metody Warda.

Historia segmentacji

Root-Mean-Square Total-Sample Standard Deviation = 0.145425

Obrazuje odległość wszystkich obserwacji od środka ciężkości zbioru

Root-Mean-Square Distance Between Observations = 0.5817

Obrazuje średnią odległość między obserwacjami

$$\text{semipartial } R^2 = \frac{B_{KL}}{T} = \frac{W_M - W_K - W_L}{\sum_{i=1}^n \|x_i - \bar{x}\|}$$

$$C_M = C_K \cup C_L$$

$$W_K = \sum_{i \in C_K} \|x_i - \bar{x}_K\|$$

$$R^2 = 1 - \left(\frac{P_G}{T}\right)$$

$$P_G = \sum W_J - \text{po segm. z poziomu } G$$


Cluster History						
NCL	Clusters Joined		FREQ	SPRSQ	RSQ	T i e
5	CL8	CL13	366	0.0494	.538	
4	CL10	CL6	403	0.0574	.480	
3	CL4	CL7	679	0.0673	.413	
2	CL5	CL9	642	0.0811	.332	
1	CL2	CL3	1321	0.3317	.000	

Metoda SOM/Kohonena




- SOM (Self Organizing Maps) – jest kolejną metodą grupowania bez nadzoru (algorytm udoskonalony przez Kohonena w latach 80-tych).
- Algorytm tworzy odwzorowanie w przestrzeni wartości zmiennych wyjściowych na dwuwymiarową siatkę. Ważne aby liczba rekordów była większa niż liczba krutek w siatce (czyli większa niż liczba zadeklarowanych skupień).
- Każda obserwacja dostaje swoją reprezentację w siatce punktów (tzw. neuronów) przy pomocy odpowiedniego odwzorowania (1)
- Neurony otaczające obszar, do którego wpadła obserwacja, zacieśniają swoje położenie wokół punktu a proces jest kontynuowany dla wszystkich pozostałych obserwacji (2)
- W wyniku tego algorytmu otrzymujemy siatkę na której bliskość neuronów (skupień) odpowiada bliskości w przestrzeni wartości zmiennych wejściowych.
- Zasadniczą różnicą w porównaniu do metody k-średnich jest to, że w SOM odległość między skupieniami jest wyznaczona w oparciu o siatkę a nie przestrzeń wejściową.
- Wyniki mogą być zaburzone z powodu różnych skal pomiaru więc należy pamiętać o standaryzacji zmiennych przed analizą.

Metoda SOM/Kohonena

1.



2.



Im ciemniejszy kolor tym liczniejsze skupienie

Algorytm Kohonena

- $x_t = [x_{t1}, x_{t2}, \dots, x_{tm}]$ oznacza wektor wejściowy,
- m – liczba zmiennych
- $w_{.j} = [w_{1j}, w_{2j}, \dots, w_{mj}]$ – wagi połączeń neuronów wejściowych z j -tym neuronem wyjściowym. Początkowe wagi są ustalone, np. wybrane losowo.
- Ustalmy neuron wejściowy x . Dla każdego neuronu wyjściowego w oblicza się wartość funkcji decyzyjnej (*scoring function*). Jest to odległość $d(w, x) = ||w - x||$. Najczęściej bierze się odległość euklidesową.

$$d(w_{.i}, x_t) = \sqrt{\sum_{i=1}^m (w_{ij} - x_{ti})^2}$$

Algorytm Kohonena

- Neuron wyjściowy, dla którego funkcja decyzyjna ma najmniejszą wartość staje się neuronem wygrywającym (J). Jego wagi są najbardziej podobne do współrzędnych x .
- Identyfikuje się wszystkie neurony j z otoczenia neuronu wygrywającego, określone przez rozmiar sąsiedztwa $R(t)$, gdzie t - oznacza numer epoki trenowania.
- Modyfikuje się wagi neuronów z otoczenia neuronu J według wzoru:

$$w'_{ij} = w_{ij} + \eta(t) \cdot (x_{*i} - w_{ij})$$

- $\eta(t)$ – nazywamy współczynnikiem uczenia (*learning rate*).
- $0 < \eta(t) < 1$
- Początkowe wartości $\eta(t)$ są ustalane (blisko 1) i są zmniejszane (liniowo lub geometrycznie) po każdej epoce.
- Również wartość rozmiaru sąsiedztwa $R(t)$ jest zmniejszana po każdej epoce.
- Proces iteracyjny zatrzymuje się, gdy są spełnione warunki „stopu”.

Algorytm Kohonena - przykład

- Zbiór danych zawiera dwie zmienne: wiek i dochód. Są one normalizowane do przedziału $[0; 1]$
- Rozważmy cztery rekordy:
 - $x_{11}=0.8$ $x_{12}=0.8$ osoba starsza z dużym dochodem
 - $x_{21}=0.8$ $x_{22}=0.1$ osoba starsza z małym dochodem
 - $x_{31}=0.2$ $x_{32}=0.8$ osoba młodsza z dużym dochodem
 - $x_{41}=0.1$ $x_{42}=0.1$ osoba młodsza z małym dochodem
- Niech topologia sieci ma rozmiar 2×2 (4 neurony wyjściowe)
- Ustalmy początkowe wagi:

– Neuron 1:	$w_{11}=0.9$	$w_{21}=0.8$	$\eta(0) = 0.5$
– Neuron 2:	$w_{12}=0.9$	$w_{22}=0.2$	$R(0) = 0$, tzn. tylko dla
– Neuron 3:	$w_{13}=0.1$	$w_{23}=0.8$	neuronu wygrywającego
– Neuron 4:	$w_{14}=0.1$	$w_{24}=0.2$	są zmieniane wagi.

- Rywalizacja
- Obliczamy odległość między pierwszym wektorem $(x_{11}, x_{12}) = (0.8, 0.8)$ a neuronami:
 - 1: $(w_{11}, w_{21}) = (0.9, 0.8)$
 - 2: $(w_{12}, w_{22}) = (0.9, 0.2)$
 - 3: $(w_{13}, w_{23}) = (0.1, 0.8)$
 - 4: $(w_{14}, w_{24}) = (0.1, 0.2)$.

$$d(w_1, x_1) = \sqrt{(0.9 - 0.8)^2 + (0.8 - 0.8)^2} = 0.1$$

$$d(w_2, x_1) = \sqrt{(0.9 - 0.8)^2 + (0.2 - 0.8)^2} = 0.61$$

$$d(w_3, x_1) = \sqrt{(0.1 - 0.8)^2 + (0.8 - 0.8)^2} = 0.7$$

$$d(w_4, x_1) = \sqrt{(0.1 - 0.8)^2 + (0.2 - 0.8)^2} = 0.92$$

Rywalizację wygrał neuron 1, gdyż jego wagi są najbardziej podobne do pierwszego rekordu wejściowego

- **Adaptacja**
- Modyfikujemy wagi połączeń z neuronem wyjściowym 1.

$$w'_{ij} = w_{i1} + 0.5 \cdot (x_1 - w_{i1})$$

Dla *wiek*:

$$w'_{11} = w_{11} + 0.5 \cdot (x_{11} - w_{11}) = 0.9 + 0.5 \cdot (0.8 - 0.9) = 0.85$$

Dla *dochód*:

$$w'_{21} = w_{21} + 0.5 \cdot (x_{12} - w_{21}) = 0.8 + 0.5 \cdot (0.8 - 0.8) = 0.8$$

Wagi są kierowane w kierunku rekordu wejściowego. Pozostałe wagi nie są tu zmieniane. To pozwoli neuronowi 1 jeszcze bardziej przyciągać rekordy osób starszych o dużych dochodach.

- Rywalizacja

- Obliczamy odległość między drugim wektorem $(x_{21}, x_{22}) = (0.8, 0.1)$ a neuronami:
 - 1: $(w_{11}, w_{21}) = (0.85, 0.8)$
 - 2: $(w_{12}, w_{22}) = (0.9, 0.2)$
 - 3: $(w_{13}, w_{23}) = (0.1, 0.8)$
 - 4: $(w_{14}, w_{24}) = (0.1, 0.2)$.

$$d(w_1, x_2) = \sqrt{(0.85 - 0.8)^2 + (0.8 - 0.1)^2} = 0.78$$

$$d(w_2, x_2) = \sqrt{(0.9 - 0.8)^2 + (0.2 - 0.1)^2} = 0.14$$

$$d(w_3, x_2) = \sqrt{(0.1 - 0.8)^2 + (0.8 - 0.1)^2} = 0.99$$

$$d(w_4, x_2) = \sqrt{(0.1 - 0.8)^2 + (0.2 - 0.1)^2} = 0.71$$

Dla drugiego rekordu rywalizację wygrał neuron 2.

- **Adaptacja**
- Modyfikujemy wagi połączeń z neuronem wyjściowym 2.

$$w'_{ij} = w_{i2} + 0.5 \cdot (x_2 - w_{i2})$$

Dla *wiek*:

$$w'_{12} = w_{12} + 0.5 \cdot (x_{21} - w_{12}) = 0.9 + 0.5 \cdot (0.8 - 0.9) = 0.85$$

Dla *dochód*:

$$w'_{22} = w_{22} + 0.5 \cdot (x_{22} - w_{22}) = 0.8 + 0.5 \cdot (0.1 - 0.2) = 0.15$$

Wagi połączeń z neuronem 2 są kierowane w kierunku drugiego rekordu wejściowego. Waga w_{22} jest zmniejszana.

- Rywalizacja
- Obliczamy odległość między trzecim wektorem $(x_{31}, x_{32}) = (0.2, 0.9)$ a neuronami:
 - 1: $(w_{11}, w_{21}) = (0.85, 0.8)$
 - 2: $(w_{12}, w_{22}) = (0.85, 0.15)$
 - 3: $(w_{13}, w_{23}) = (0.1, 0.8)$
 - 4: $(w_{14}, w_{24}) = (0.1, 0.2)$

$$d(w_1, x_3) = \sqrt{(0.85 - 0.2)^2 + (0.8 - 0.9)^2} = 0.66$$

$$d(w_2, x_3) = \sqrt{(0.85 - 0.2)^2 + (0.15 - 0.9)^2} = 0.99$$

$$d(w_3, x_3) = \sqrt{(0.1 - 0.2)^2 + (0.8 - 0.9)^2} = 0.14$$

$$d(w_4, x_3) = \sqrt{(0.1 - 0.2)^2 + (0.2 - 0.9)^2} = 0.71$$

Dla trzeciego rekordu rywalizację wygrał neuron 3.

- **Adaptacja**
- Modyfikujemy wagi połączeń z neuronem wyjściowym 3.

$$w'_{ij} = w_{i3} + 0.5 \cdot (x_3 - w_{i3})$$

Dla *wiek*:

$$w'_{13} = w_{13} + 0.5 \cdot (x_{31} - w_{13}) = 0.1 + 0.5 \cdot (0.2 - 0.1) = 0.15$$

Dla *dochód*:

$$w'_{23} = w_{23} + 0.5 \cdot (x_{32} - w_{23}) = 0.8 + 0.5 \cdot (0.9 - 0.8) = 0.85$$

Wagi połączeń z neuronem 3 są kierowane w kierunku trzeciego rekordu wejściowego.

- Rywalizacja
- Obliczamy odległość między czwartym wektorem $(x_{41}, x_{42}) = (0.1, 0.1)$ a neuronami:
 - 1: $(w_{11}, w_{21}) = (0.85, 0.8)$
 - 2: $(w_{12}, w_{22}) = (0.85, 0.15)$
 - 3: $(w_{13}, w_{23}) = (0.15, 0.85)$
 - 4: $(w_{14}, w_{24}) = (0.1, 0.2)$.

$$d(w_1, x_4) = \sqrt{(0.85 - 0.1)^2 + (0.8 - 0.1)^2} = 1.03$$

$$d(w_2, x_4) = \sqrt{(0.85 - 0.1)^2 + (0.15 - 0.1)^2} = 0.75$$

$$d(w_3, x_4) = \sqrt{(0.1 - 0.15)^2 + (0.85 - 0.1)^2} = 0.75$$

$$d(w_4, x_4) = \sqrt{(0.1 - 0.1)^2 + (0.2 - 0.1)^2} = 0.1$$

Dla czwartego rekordu rywalizację wygrał neuron 4.

- **Adaptacja**
- Modyfikujemy wagi połączeń z neuronem wyjściowym 4.

$$w'_{ij} = w_{i4} + 0.5 \cdot (x_4 - w_{i4})$$

Dla *wiek*:

$$w'_{14} = w_{14} + 0.5 \cdot (x_{41} - w_{14}) = 0.1 + 0.5 \cdot (0.1 - 0.1) = 0.1$$

Dla *dochód*:

$$w'_{24} = w_{24} + 0.5 \cdot (x_{42} - w_{24}) = 0.2 + 0.5 \cdot (0.1 - 0.2) = 0.15$$

Wagi połączeń z neuronem 4 są kierowane w kierunku czwartego rekordu wejściowego.

- Po zakończeniu pierwszej epoki:

- Początkowe wagi:

- Neuron 1: $w_{11}=0.9$ $w_{21}=0.8$
- Neuron 2: $w_{12}=0.9$ $w_{22}=0.2$
- Neuron 3: $w_{13}=0.1$ $w_{23}=0.8$
- Neuron 4: $w_{14}=0.1$ $w_{24}=0.2$

Można zmniejszyć $\eta(t)$

- Końcowe wagi:

rozpoznaje:

- Neuron 1: $w_{11}=0.85$ $w_{21}=0.8$ osoby starsze o dużych dochodach
- Neuron 2: $w_{12}=0.85$ $w_{22}=0.15$ osoby starsze o małych dochodach
- Neuron 3: $w_{13}=0.15$ $w_{23}=0.85$ osoby młodsze o dużych dochodach
- Neuron 4: $w_{14}=0.1$ $w_{24}=0.15$ osoby młodsze o małych dochodach

Analiza asocjacji

- Analiza asocjacji służy do badania współwystępowania wydarzeń, umożliwiając odpowiedzi na pytania: czy zaistnienie jakiegoś zdarzenia wpływa na wzrost prawdopodobieństwa innego zdarzenia?
- Nazywana również analizą koszykową, ponieważ często służy do badania koszyka klienta, a konkretniej sprawdzania, które produkty lub usługi sprzedają się najlepiej razem?
- Analiza asocjacji polega na identyfikacji współzależności cech. Umożliwia wykrycie logicznych reguł występujących między zmiennymi w zbiorze danych. Analiza polega na identyfikacji pozycji, które występują razem.
- Znana jest też pod nazwą **analiza koszykowa** (*market basket analysis*).
- Słowo *koszykowa* odnosi się do wózka w supermarkecie, do którego klienci wrzucają wybrane towary

Analiza asocjacji

Założmy, że badamy regułę:

„Kupno produktu A pociągga za sobą kupno produktu B”

W analizie asocjacji stosujemy Cztery podstawowe miary:

Wsparcie (Support): częstość występowania badanej reguły wśród wszystkich przypadków.
 $(\text{suma transakcji zawierających produkt A i B}) / (\text{suma wszystkich transakcji})$

Zaufanie (Confidence): częstość tej reguły wśród transakcji zawierających pierwszy produkt.
 $(\text{suma transakcji zawierających produkt A i B}) / (\text{suma transakcji zawierających A})$

Oczekiwane zaufanie (Expected Confidence): ogólny odsetek transakcji zawierających produkt B.
 $(\text{suma transakcji zawierających produkt B}) / (\text{suma wszystkich transakcji})$

Korelacja asocjacyjna (Lift): nieunormowana miara wskazująca, czy możemy mówić o prawdziwości reguły. Wartość większa od 1 wskazuje na prawdziwość reguły, podczas gdy wartość mniejsza od 1 na jej nieprawdziwość.
 $\text{Zaufanie} / \text{Oczekiwane zaufanie}$

Analiza asocjacji

Zbadajmy, czy możemy wnioskować istnienie reguły łączącej posiadanie produktów A i B na podstawie następującej tabeli dwudzielczej (7000 klientów, posiadających różne kombinacje A i B):

A	B		
	NIE	TAK	razem
NIE	2200	2800	5000
TAK	1000	1000	2000
razem	3200	3800	7000

Dla reguły $A \Rightarrow B$:


Wsparcie = $1000/7000 = 0.14$

Zaufanie = $1000/2000 = 0.50$

Ocz. Zaufanie = $3800/7000 = 0.54$

Podniesienie (Lift):

$0.50/0.54 = 0.92 < 1$



BRAK ZALEŻNOŚCI

Analiza asocjacji - problemy

- Jakie produkty są kupowane najczęściej razem?
- Które produkty nigdy nie są kupowane razem?
- Jakie jest prawdopodobieństwo, że klienci, którzy kupili produkt A, kupią również produkt B?

Reguły asocjacyjne

- Dzięki odkryciu współzależności między cechami możemy stworzyć reguły postaci: jeżeli cecha A towarzyszy określonemu zdarzeniu, to cecha B towarzyszy temu zdarzeniu z określonym prawdopodobieństwem (np. 90%).
- Reguły asocjacyjne (*association rules*) mają postać:

Jeżeli A, to B

Jeżeli [**poprzednik**], to [**następnik**]

(przyjmuje się, że zbiory A i B są rozłączne)

Przykład

Jeżeli klient **kupił kawę i śmietankę**, to **kupił ciastka**

Zapisujemy to w postaci

[Kawa & Śmietanka] → [Ciastka]

Jeżeli transakcja pasuje do reguły, tzn. spełnione są warunki poprzednika i następnika, to mówimy, że reguła zawiera określoną transakcję (transakcja wspiera określoną regułę asocjacyjną)

Przykład

- Miejscowy rolnik ma przydrożne stoisko z warzywami i sprzedaje następujące artykuły:

- Klienci zjeżdżają na bok drogi i kupują różne kombinacje artykułów,

(np. {brokuły, zielona papryka, kukurydza}).

i_1	Szparagi
i_2	Fasola
i_3	Brokuły
i_4	Kukurydza
i_5	Zielona papryka
i_6	Kabaczki
i_7	Pomidory

Przykład

- W ciągu jednego popołudnia dokonano 14 transakcji.

Uwaga

W analizie koszykowej nie interesuje nas, jaką ilość towaru klient kupił. Ważne jest tylko, czy kupił dany towar, czy nie.

T_1	brokuły, zielona papryka, kukurydza
T_2	szparagi, kabaczki, kukurydza
T_3	kukurydza, pomidory, fasola, kabaczki
T_4	zielona papryka, kukurydza, pomidory, fasola
T_5	fasola, szparagi, brokuły
T_6	kabaczki, szparagi, fasola, pomidory
T_7	Pomidory, kukurydza
T_8	brokuły, pomidory, zielona papryka
T_9	kabaczki, szparagi, fasola, pomidory
T_{10}	fasola, kukurydza
T_{11}	zielona papryka, brokuły, fasola, kabaczki
T_{12}	szparagi, fasola, kabaczki
T_{13}	kabaczki, kukurydza, szparagi, fasola
T_{14}	kukurydza, zielona papryka, pomidory, fasola, brokuły

Format danych

Występują dwa formaty danych:

Macierzowy

Transakcja	Szparagi	Fasola	Brokuły	Kukurydza	Zielona papryka	Kabaczki	Pomidory
T ₁	0	0	1	1	1	0	0
T ₂	1	0	0	1	0	1	0
T ₃	0	1	0	1	0	1	1
T ₄	0	1	0	1	1	0	1
T ₅	1	1	1	0	0	0	0
T ₆	1	1	0	0	0	1	1
T ₇	0	0	0	1	0	0	1
T ₈	0	0	1	0	1	0	1
T ₉	1	1	0	0	0	1	0
T ₁₀	0	1	0	1	0	0	0
T ₁₁	0	1	1	0	1	1	0
T ₁₂	1	1	0	0	0	1	0
T ₁₃	1	1	0	1	0	1	0
T ₁₄	0	1	1	1	1	0	1

Wiersz zawiera transakcję. Kolumny dotyczą towarów.

Macierz zawiera **1**, gdy dany towar wchodzi do koszyka,

0 – gdy nie wchodzi

Transakcyjny

Wymagane są dwie kolumny:

- identyfikator transakcji,
- pozycja (zakupiony towar).

Ten sam identyfikator transakcji może występować wiele razy.
W kolumnie towaru każdy wiersz zawiera tylko jedną pozycję.

EM SAS wymaga, aby dane były zapisane w formacie transakcyjnym.

Transakcja	Artykuł
T ₁	brokuły
T ₁	zielona papryka
T ₁	kukurydza
T ₂	szparagi
T ₂	kabaczki
T ₂	kukurydza
T ₃	kukurydza
T ₃	pomidory
.....	
T ₁₄	fasola
T ₁₄	brokuły

Charakterystyki reguł asocjacyjnych

$$\mathbf{A \rightarrow B}$$

- Wsparcie reguły (*support*)

$$\frac{n(A \cap B)}{N} = P(A \cap B)$$

- Ufność reguły (*confidence*)

$$\frac{n(A \cap B)}{n(A)} = P(B | A)$$

- Przyrost (*lift*)

$$\frac{ufnosc}{P(B)} = \frac{P(B | A)}{P(B)}$$

N – liczba wszystkich transakcji, $n(X)$ – liczba transakcji zawierających X .

Charakterystyki reguł asocjacyjnych

- Analitycy mogą preferować reguły, które mają duże wsparcie i dużą ufność.

$$\mathbf{A} \rightarrow \mathbf{B}$$

- **Mocne reguły** są to takie reguły, dla których wsparcie i ufność są większe niż pewne ustalone wartości minimalne.
- Jeżeli towary **B** są nabywane często, ufność każdej reguły $\mathbf{A} \rightarrow \mathbf{B}$ będzie duża. Wtedy należy rozważać przyrosty.

- Przyrost jest większy niż 1, gdy

$$P(B | A) > P(B)$$

Oznacza to, że gdy klient zakupi towar **A**, to wzrasta prawdopodobieństwo zakupu towaru **B**.

Algorytm Apriori

Najpopularniejszy algorytm generowania reguł asocjacyjnych **Apriori** został zaproponowany w pracy [R. Agrawal i R. Srikant, 1993].

Apriori jest algorytmem iteracyjnym. W każdej iteracji znajduje się zbiory o rozmiarach 2, 3... (liczba towarów w regule) i sprawdza się, czy są one częste.

Częstość zbioru zdarzeń (towarów) A jest to liczba transakcji zawierająca dany zbiór: $n(A)$.

Zbiór A jest częsty, gdy występuje w transakcjach przynajmniej pewną ustaloną minimalną liczbę razy Φ .

Przyjmijmy np. $\Phi = 4$.

Oznaczmy:

F_k - zbiór częstych koszyków o liczbie towarów k ,

C_k – zbiór koszyków o liczbie towarów k .

Tworzenie reguł asocjacyjnych odbywa się w dwóch etapach:

- Znajdź wszystkie zbiory częste (dla ustalonego Φ).
- Na podstawie częstych zdarzeń utwórz reguły asocjacyjne, które spełniają warunek minimalnego wsparcia i poziomu ufności.

Algorytm Apriori

Tworzenie zbiorów częstych:

- **łączenie** – do zbioru C_k wstawiamy takich par $A, B \in F_{k-1}$ które mają wspólne $k-2$ początkowych elementów.

$$A \cup B$$

Niech $F_2 = \{ab, ac, ad, ae, bc, bd, be\}$

Wówczas

$C_3 = \{abc, abd, abe, acd, ace, ade, bcd, bce, bde\}$.

$F_2 = \{ab, ac, ad, ae, bc, bd, be\}$

$C_3 = \{abc, abd, abe, acd, ace, ade, bcd, bce, bde\}$

- **obcinanie** - usuwamy z C_k zbiory, których nie wszystkie podzbiory $(k-1)$ -elementowe są w F_{k-1} .

(np. tu możemy usunąć acd , bo cd nie znajduje się w F_{k-1}). Po obcięciu mamy $C_3 = \{abc, abd, abe\}$.

- **usuwanie** - usuwamy z C_k zbiory, które nie są częste i otrzymujemy zbiór F_k .

Analiza sekwencji

- Jest rozszerzeniem analizy asocjacji o wymiar czasowy
- Odpowiada na pytanie typu: Jeżeli w zeszłym miesiącu klient kupił produkt A to czy w bieżącym miesiącu prawdopodobne jest że kupi produkt B?
- Wymaga zdefiniowania zmiennej pełniącej rolę znacznika czasu.